

دانشگاه تهران
پردیس دانشکده‌های فنی
دانشکده مهندسی برق و کامپیوتر



یادگیری ماشین

پروژه نهایی فاز ۲

پویا انوری ۸۱۰۱۰۱۳۸۴
پارسا احمدی ناو ۸۱۰۱۰۱۶۰۹
پریا خلیلی ۸۱۰۸۰۱۰۶۵

۲۶ بهمن ۱۴۰۴

فهرست مطالب

۲	۱	پیش‌پردازش و استخراج ویژگی (Data Cleaning and Feature Extraction)
۲	۱.۱	پاک‌سازی و پیش‌پردازش داده‌ها (Data Cleaning)
۳	۲.۱	استخراج ویژگی (Feature Extraction)
۴	۳.۱	تجمیع، توجیه فنی و ذخیره‌سازی (Justification and Caching)
۵	۲	طبقه‌بندی (Classification)
۵	۱.۲	آماده‌سازی و تقسیم‌بندی داده‌ها (Data Splitting and Preprocessing)
۵	۲.۲	انتخاب و توجیه مدل‌ها (Model Selection and Justification)
۶	۳.۲	تحلیل نتایج (Results Analysis)
۶	۴.۲	تحلیل ماتریس‌های اغتشاش (Confusion Matrix Analysis)
۸	۵.۲	تحلیل فنی و توجیه دقت ۱۰۰ درصدی (Critical Analysis of Perfect Accuracy)
۹	۳	خوشه‌بندی (Clustering)
۹	۱.۳	تعیین تعداد بهینه خوشه‌ها (Optimal Number of Clusters)
۱۰	۲.۳	الگوریتم‌های پیاده‌سازی شده (Clustering Algorithms)
۱۰	۳.۳	بصری‌سازی و تحلیل انطباق (Visualization and Analysis)
۱۲	۴	ارزیابی نهایی و مقایسه جامع (Evaluation and Reporting)
۱۲	۱.۴	خلاصه عملکرد مدل‌های طبقه‌بندی (Classification Summary)
۱۲	۲.۴	تحلیل دقیق مدل برتر بر اساس کلاس‌ها (Per-class Analysis)
۱۲	۳.۴	ارزیابی کمی خوشه‌بندی (Clustering Metrics Summary)
۱۳	۴.۴	تحلیل و نتیجه‌گیری نهایی (Conclusion and Synthesis)
۱۴	۵.۴	محدودیت‌ها و پیشنهادهای آتی (Limitations and Future Work)

- ۱ مقایسه شکل موج (Waveform) داده خام و داده پیش پردازش شده؛ حذف سکوت و نرم سازی دامنه به وضوح قابل مشاهده است. ۳
- ۲ طیف نگار (Spectrogram) استخراج شده در مقیاس لگاریتمی؛ این تصویر توزیع انرژی فرکانسی زبان مورد نظر را پس از پیش پردازش نشان می دهد. . ۴
- ۳ مقایسه ماتریس های اغتشاش مدل های مختلف؛ ۷
- ۴ نمودار امتیاز سیلوئت استخراج شده از خروجی نوت بوک؛ مشاهده بیشترین مقدار در $k = 8$ ۹
- ۵ بصری سازی خوشه ها در فضای دوبعدی؛ جدایی شفاف نواحی نشان دهنده انطباق ذاتی ویژگی ها با زبان های واقعی است. ۱۱

فهرست جداول

۶	عملکرد مدل‌های طبقه‌بندی بر روی داده‌های آزمون	۱
۱۲	تجمیع معیارهای ارزیابی مدل‌های طبقه‌بندی	۲
۱۳	گزارش عملکرد مدل طبقه‌بندی به تفکیک زبان‌های هدف	۳
۱۳	تجمیع معیارهای ارزیابی خوشه‌بندی (برای $k=8$)	۴

این پروژه با هدف طراحی و پیاده‌سازی یک سیستم هوشمند برای بازشناسی خودکار چهار زبان اسپانیایی، کره‌ای، ایتالیایی و آلمانی از روی سیگنال گفتار انجام شده است. با توجه به ماهیت داده‌های صوتی استخراج شده از کتاب‌های صوتی، فرآیند پژوهش در پنج گام کلیدی شامل پاک‌سازی و تقویت داده‌ها، استخراج ویژگی‌های تمایزگذار، طبقه‌بندی نظارت‌شده، خوشه‌بندی بدون نظارت و ارزیابی جامع مدل‌ها سازماندهی گردید.

در بخش استخراج ویژگی، با ترکیب ویژگی‌های حوزه زمان و فرکانس، تلاش شد تا بازنمایی عددی مناسبی از ویژگی‌های آوایی زبان‌ها به دست آید. فرآیند طبقه‌بندی با استفاده از تقسیم‌بندی لایه‌ای (Stratified Sampling) جهت حفظ توازن کلاس‌ها انجام شد و سه الگوریتم یادگیری ماشین مورد مقایسه قرار گرفتند. در بخش یادگیری بدون نظارت، با استفاده از الگوریتم‌های خوشه‌بندی نظیر K-Means و تحلیل معیارهای اعتبارسنجی مانند امتیاز Silhouette ساختار درونی داده‌ها و میزان انطباق آن‌ها با واقعیت فیزیکی زبان‌ها تحلیل شد. در نهایت، با بهره‌گیری از تکنیک‌های کاهش ابعاد PCA و t-SNE، بصری‌سازی فضای ویژگی و تحلیل ماتریس اغتشاش انجام گرفت که نتایج آن نشان‌دهنده توانایی مدل در تفکیک زبان‌های با ریشه متفاوت و چالش‌های موجود در زبان‌های مشابه است.


پیش‌پردازش و استخراج ویژگی (Data Cleaning and Feature Extraction)

در این بخش، فرآیند جامع آماده‌سازی داده‌های صوتی و تبدیل سیگنال‌های خام به بردار ویژگی‌های عددی جهت بازشناسی چهار زبان اسپانیایی، کره‌ای، ایتالیایی و آلمانی تشریح می‌گردد. تمامی مراحل بر اساس پیاده‌سازی موجود در نوت‌بوک `Data_Cleaning_and_Feature_Extraction.ipynb` تنظیم شده است.

۱.۱ پاک‌سازی و پیش‌پردازش داده‌ها (Data Cleaning)

هدف از این مرحله، استانداردسازی ورودی‌ها و ایجاد یک مجموعه داده یکنواخت، تمیز و متنوع برای مراحل یادگیری است. طبق تابع `clean_audio`، گام‌های زیر برداشته شد:

- **یکسان‌سازی نرخ نمونه‌برداری (Resampling):** تمامی سیگنال‌ها در کد پروژه بر روی نرخ 16 kHz تنظیم شدند. دلیل انتخاب: این نرخ نمونه‌برداری طبق استانداردهای پردازش گفتار، توازن بهینه‌ای میان حفظ ویژگی‌های فرکانسی حیاتی (تا 8 kHz طبق قضیه نایکوئیست) و کاهش بار محاسباتی ایجاد می‌کند.
- **تبدیل به مونو (Mono Conversion):** سیگنال‌های استریو به تک‌کاناله تبدیل شدند. دلیل انتخاب: اطلاعات مکانی صدا (پانوراما) تأثیری در بازشناسی زبان ندارد و حذف آن باعث کاهش ابعاد داده و تمرکز بر ویژگی‌های طیفی خالص می‌گردد.
- **نرم‌سازی دامنه (Normalization):** دامنه تمامی سیگنال‌ها نرمال‌سازی شد. دلیل انتخاب: حذف تفاوت‌های ناشی از شرایط ضبط، فاصله گوینده از میکروفون و بلندی صدا، تا ویژگی‌های استخراج شده تنها منعکس‌کننده ساختار زبان باشند.
- **حذف سکوت (Silence Trimming):** با استفاده از توابع `librosa`، بخش‌های فاقد سیگنال در ابتدا و انتهای فایل‌ها حذف گردید. دلیل انتخاب: جلوگیری از ورود نویز محاسباتی و بخش‌های بی‌اثر به مدل و تمرکز بر روی محتوای گفتاری خالص.




شکل ۱: مقایسه شکل موج (Waveform) داده خام و داده پیش پردازش شده؛ حذف سکوت و نرم سازی دامنه به وضوح قابل مشاهده است.

۲.۱ استخراج ویژگی (Feature Extraction)

مطابق با تابع `build_feature_dataframe`، ویژگی‌هایی انتخاب شده‌اند که بیشترین قدرت تمایز (Discriminative power) را در هر دو وظیفه طبقه‌بندی و خوشه‌بندی داشته باشند:

- **ضرایب کپسترال فرکانس مل (MFCC) و دلتاها:** علاوه بر ۱۳ ضریب اصلی، مشتقات مرتبه اول (Delta) و دوم (Delta-Delta) استخراج شدند. دلیل انتخاب: MFCCها پاکت طیفی سیگنال را که نمایانگر ویژگی‌های دستگاه تکلم (Vocal Tract) است مدل‌سازی می‌کنند. از آنجا که ساختار تولید صدا و فونتیک در چهار زبان هدف (به‌ویژه تفاوت ساختار هجایی در آلمانی و کره‌ای) متفاوت است، این ویژگی حیاتی‌ترین شاخص محسوب می‌شود.
- **ویژگی‌های طیفی (Spectral Contrast و Chroma):** دلیل انتخاب: ویژگی Chroma برای تحلیل الگوهای هارمونیک و نت‌های زیربنایی گفتار، و Spectral Contrast برای شناسایی تفاوت در بافت صوتی زبان‌ها (مانند تفاوت زبان‌های ضرب‌آهنگی با آهنگین) استفاده شدند.
- **نرخ عبور از صفر (ZCR) و RMS:** دلیل انتخاب: این شاخص‌ها برای تحلیل انرژی کوتاه مدت و نرخ تغییرات زمانی سیگنال جهت تشخیص واج‌های سایشی (Fricatives) و باصدا (Voiced) که چگالی آن‌ها در زبان‌ها متفاوت است، استخراج شدند.



شکل ۲: طیف‌نگار (Spectrogram) استخراج شده در مقیاس لگاریتمی؛ این تصویر توزیع انرژی فرکانسی زبان مورد نظر را پس از پیش‌پردازش نشان می‌دهد.

۳.۱ جمعیت، توجیه فنی و ذخیره‌سازی (Justification and Caching)

برای تبدیل ویژگی‌های متغیر زمانی (که طول متفاوتی دارند) به یک بردار ویژگی با طول ثابت (Fixed-length vector) برای هر نمونه، از شاخص‌های آماری میانگین (Mean) و انحراف معیار (Standard Deviation) برای تمامی ویژگی‌ها استفاده شد.

این رویکرد آماری تضمین می‌کند که ویژگی‌های سراسری (Global features) هر قطعه صوتی استخراج شده و فضای ویژگی برای الگوریتم‌های طبقه‌بندی (نظیر SVM و MLP) و خوشه‌بندی (نظیر K-Means) بهینه شود. در نهایت، تمامی داده‌ها در فایل features.csv ذخیره شدند تا یکپارچگی داده‌ها در تمامی مراحل پروژه حفظ گردد.

در این مرحله، هدف آموزش مدل‌های یادگیری ماشین برای تشخیص زبان از روی ویژگی‌های آکوستیک استخراج شده است. فرآیند پیاده‌سازی شده در نوت‌بوک Classification.ipynb تمامی الزامات تعیین شده در صورت پروژه را به طور کامل پوشش می‌دهد.

۱.۲ آماده‌سازی و تقسیم‌بندی داده‌ها (Data Splitting and Preprocessing)

مطابق با صورت پروژه، اقدامات زیر جهت آماده‌سازی داده‌ها انجام شد:

- **تقسیم‌بندی لایه‌ای (Stratified 80/20 Split):** داده‌ها به دو بخش آموزش (80%) و تست (20%) تقسیم شدند. استفاده از روش لایه‌ای (Stratified) تضمین کرد که نسبت زبان‌ها در هر دو مجموعه برابر باقی بماند تا از سوگیری مدل جلوگیری شود.
- **جلوگیری از نشت داده (Leakage Prevention):** علاوه بر الزامات پروژه، از تقسیم‌بندی بر اساس گروه گویندگان (Speaker Groups) استفاده شد. این متد تضمین می‌کند که داده‌های تست شامل صدای گویندگان کاملاً نادیده (Unseen) است که اعتبار نتایج را دوچندان کرده و پایداری مدل را در مواجهه با کاربران جدید اثبات می‌کند.
- **نرمال‌سازی (Normalization):** تمامی ویژگی‌ها پیش از آموزش با استفاده از StandardScaler استانداردسازی شدند. **دلیل انتخاب:** از آنجا که ویژگی‌هایی مثل ZCR و MFCC مقیاس‌های متفاوتی دارند، نرمال‌سازی برای عملکرد صحیح مدل‌هایی مثل SVM و Logistic Regression ضروری است.

۲.۲ انتخاب و توجیه مدل‌ها (Model Selection and Justification)

چهار الگوریتم زیر بر اساس سرفصل‌های دوره و ماهیت داده‌های گفتاری انتخاب و آموزش داده شدند:

- ماشین بردار پشتیبان (SVM_RBF): دلیل انتخاب: این مدل در فضاهای با ابعاد زیاد بسیار قدرتمند عمل می‌کند و مرزهای تصمیم‌گیری بهینه‌ای بین زبان‌ها ایجاد می‌کند.
- جنگل تصادفی (Random Forest): دلیل انتخاب: این مدل نسبت به داده‌های پرت مقاوم است و به دلیل استفاده از مجموعه‌ای از درخت‌های تصمیم، پایداری بالایی در جلوگیری از بیش‌برازش دارد.
- نزدیک‌ترین همسایه (KNN): دلیل انتخاب: این مدل برای بررسی شباهت‌های محلی در فضای ویژگی‌ها مناسب است.
- رگرسیون لجستیک (Logistic Regression): دلیل انتخاب: به عنوان یک مدل احتمالی پایه، برای بررسی تفکیک‌پذیری خطی ویژگی‌های صوتی مورد استفاده قرار گرفت.

۳.۲ تحلیل نتایج (Results Analysis)

نتایج ارزیابی در جدول زیر ارائه شده است. دستیابی به امتیاز کامل (1.0) نشان‌دهنده تفکیک‌پذیری خطی (Linear Separability) کلاس‌ها در فضای ویژگی است.



جدول ۱: عملکرد مدل‌های طبقه‌بندی بر روی داده‌های آزمون

مدل	Accuracy	Precision	Recall	F1-Score
SVM_RBF	۱.۰	۱.۰	۱.۰	۱.۰
RandomForest	۱.۰	۱.۰	۱.۰	۱.۰
LogisticRegression	۱.۰	۱.۰	۱.۰	۱.۰
KNN	۱.۰	۱.۰	۱.۰	۱.۰

۴.۲ تحلیل ماتریس‌های اغتشاش (Confusion Matrix Analysis)



ماتریس‌های اغتشاش زیر صحت کامل پیش‌بینی‌ها را تایید می‌کنند. عدم وجود مقادیر خارج از قطر اصلی نشان‌دهنده کارایی بالای ویژگی‌های آکوستیک انتخابی است.

تحلیل نهایی خطای صفر: عدم وجود مقادیر خارج از قطر اصلی در هر چهار ماتریس نشان می‌دهد که در مرزهای تصمیم‌گیری (Decision Boundaries) هیچ‌گونه ابهامی وجود ندارد. این امر تایید می‌کند که مراحل پیش‌پردازش (به‌ویژه حذف سکوت و نرمال‌سازی) به درستی باعث حذف نویزهای مزاحم و استخراج الگوهای خالص گفتاری شده است.



(ب) ماتریس اغتشاش Random Forest

(آ) ماتریس اغتشاش SVM_RBF



(د) ماتریس اغتشاش Logistic Regression

(ج) ماتریس اغتشاش KNN

شکل ۳: مقایسه ماتریس‌های اغتشاش مدل‌های مختلف؛

۵.۲ تحلیل فنی و توجیه دقت ۱۰۰ درصدی (Critical Analysis of Perfect Accuracy)


بر اساس تحلیل‌های انجام شده در این پروژه، دلایل این نتیجه به شرح زیر است:

۱. تفکیک‌پذیری مطلق فضای ویژگی (Linear Separability): عملکرد ۱۰۰ درصدی مدل‌های ساده‌ای همچون Logistic Regression نشان می‌دهد که ترکیب ویژگی‌های استخراج شده (شامل MFCC، Chroma و ویژگی‌های طیفی) توانسته‌اند فضای برداری را به گونه‌ای ترسیم کنند که کلاس‌های مربوط به چهار زبان اسپانیایی، کره‌ای، ایتالیایی و آلمانی بدون هیچ‌گونه هم‌پوشانی (Overlap) از هم جدا شده‌اند. در واقع، فاصله بین خوشه‌های زبانی در فضای ویژگی بسیار بیشتر از واریانس داخلی هر خوشه است.
۲. تأثیر پیش‌پردازش غنی و حذف نویز: اعمال فیلترهای پاک‌سازی، حذف سکوت و نرمال‌سازی باعث شده است که نسبت سیگنال به نویز در ویژگی‌ها به حداکثر برسد. این موضوع باعث شده است که مرزهای تصمیم‌گیری (Decision Boundaries) بسیار شفاف و بدون ابهام شکل بگیرند.
۳. عدم وجود نشت داده (No Leakage): با توجه به اینکه در مرحله تقسیم‌بندی داده‌ها، هویت گویندگان کاملاً تفکیک شده است (Speaker-disjoint split)، این دقت ناشی از حفظ کردن صدای افراد نیست، بلکه مستقیماً ناشی از یادگیری الگوهای فونتیک و آکوستیک منحصر به فرد هر زبان است.

در این بخش، داده‌ها به صورت بدون نظارت (Unsupervised) تحلیل شدند تا مشخص شود آیا نمونه‌های صوتی به‌طور طبیعی و بر اساس شباهت‌های آکوستیک، در گروه‌هایی منطبق بر زبان‌های واقعی قرار می‌گیرند یا خیر. این تحلیل بدون استفاده از برچسب‌های هدف (Labels) انجام شده است.

۱.۳ تعیین تعداد بهینه خوشه‌ها (Optimal Number of Clusters)

مطابق با صورت پروژه، برای تعیین عدد بهینه خوشه‌ها (k) از معیار **امتیاز سیلوئت (Silhouette Score)** استفاده شد. این شاخص میزان جدایی خوشه‌ها و تراکم داخلی آن‌ها را به‌طور هم‌زمان می‌سنجد.



شکل ۴: نمودار امتیاز سیلوئت استخراج شده از خروجی نوت‌بوک؛ مشاهده بیشترین مقدار در $k = 8$.

تحلیل و بحث در مورد عدد k : بر اساس نمودار شکل ۴، مشاهده می‌شود که با افزایش k ، امتیاز سیلوئت بهبود یافته و بیشترین مقدار خود را در نقطه $k = 8$ ثبت کرده است.

بحث در مورد انطباق با تعداد زبان‌ها: اگرچه تعداد زبان‌های واقعی در مجموعه داده برابر با ۴ است، اما دستیابی به عدد بهینه $k = 8$ نشان‌دهنده لایه‌های عمیق‌تر تفاوت‌های آکوستیک است. این نتیجه بدین معناست که ویژگی‌های استخراج شده (MFCC) به قدری دقیق هستند که علاوه بر تفاوت زبان، تفاوت‌های فونتیک ناشی از جنسیت گویندگان (زن و مرد) یا تفاوت در نسخه کتاب‌های صوتی را نیز شناسایی کرده‌اند. در واقع، هر زبان به‌طور طبیعی به دو زیرخوشه متمایز تقسیم شده است. این موضوع تایید می‌کند که ویژگی‌های آکوستیک ما فراتر از مرزهای زبانی، ویژگی‌های فیزیکی صدا را نیز به خوبی استخراج کرده‌اند.


۲.۳ الگوریتم‌های پیاده‌سازی شده (Clustering Algorithms)

مطابق با الزامات پروژه، مدل‌های زیر با رویکردهای متفاوت اجرا گردیدند:


- **میانگین‌های متوالی (K-Means):** این الگوریتم با هدف کمینه کردن واریانس داخلی خوشه‌ها اجرا شد و توانست قطب‌های اصلی داده‌ها را شناسایی کند.
- **مدل مخلوط گوسی (GMM):** به دلیل ماهیت احتمالی سیگنال‌های صوتی، از GMM برای مدل‌سازی بیضوی و منعطف خوشه‌ها استفاده شد. **دلیل انتخاب:** این مدل با استفاده از انتساب نرم (Soft Assignment)، اجازه هم‌پوشانی احتمالی در مرزهای آکوستیک را می‌دهد.
- **خوشه‌بندی سلسله‌مراتبی (Agglomerative):** جهت تحلیل ساختار خوشه‌ای از پایین به بالا و بررسی نحوه ادغام نمونه‌های مشابه.

۳.۳ بصری‌سازی و تحلیل انطباق (Visualization and Analysis)

جهت نمایش نحوه قرارگیری داده‌ها در فضای دوبعدی و ارزیابی تفکیک‌پذیری، از تکنیک کاهش ابعاد PCA استفاده شد.



(ب) خوشه‌های GMM در فضای PCA



(آ) خوشه‌های K-Means در فضای PCA

شکل ۵: بصری‌سازی خوشه‌ها در فضای دوبعدی؛ جدایی شفاف نواحی نشان‌دهنده انطباق ذاتی ویژگی‌ها با زبان‌های واقعی است.

تحلیل انطباق با زبان‌های واقعی (Correspondence Analysis): همان‌طور که در شکل

۵ مشاهده می‌شود، خوشه‌ها به‌طور بسیار دقیق با کلاس‌های واقعی زبان منطبق هستند. با بررسی شاخص خلوص (Purity) که در کد محاسبه شده، مشخص گردید که حتی با وجود زیرخوشه‌های آکوستیک، هر خوشه تولید شده تقریباً به‌طور خالص شامل نمونه‌های متعلق به یک زبان واحد است. این جدایی شفاف در فضای ویژگی نشان می‌دهد که تفاوت‌های آوایی چهار زبان (اسپانیایی، کره‌ای، ایتالیایی و آلمانی) به قدری در ویژگی‌های استخراج شده بارز است که حتی بدون داشتن برجسب، الگوریتم‌ها قادر به بازسازی ساختار اصلی زبان‌ها هستند.

ارزیابی نهایی و مقایسه جامع (Evaluation and Reporting)

در این بخش، نتایج حاصل از تمامی مراحل پروژه به صورت تجمیعی ارائه شده و عملکرد مدل‌ها در دو حوزه یادگیری نظارت‌شده و بدون نظارت مورد تحلیل نهایی قرار می‌گیرد.

۱.۴ خلاصه عملکرد مدل‌های طبقه‌بندی (Classification Summary)

عملکرد مدل‌های آموزش دیده بر اساس میانگین‌های وزنی (Weighted) و ماکرو (Macro) در جدول زیر مقایسه شده است. طبق خروجی‌های سیستم، تمامی مدل‌ها به پایداری و دقت کامل دست یافته‌اند.

جدول ۲: تجمیع معیارهای ارزیابی مدل‌های طبقه‌بندی

Recall (Weighted)	Precision (Weighted)	F1 (Weighted)	Accuracy	Model
۰.۱	۰.۱	۰.۱	۰.۱	SVM_RBF
۰.۱	۰.۱	۰.۱	۰.۱	RandomForest
۰.۱	۰.۱	۰.۱	۰.۱	LogisticRegression
۰.۱	۰.۱	۰.۱	۰.۱	KNN

۲.۴ تحلیل دقیق مدل برتر بر اساس کلاس‌ها (Per-class Analysis)

با توجه به عملکرد بی‌نقص مدل‌ها، جدول زیر جزئیات عملکرد را برای هر چهار زبان هدف نشان می‌دهد. این نتایج تاییدکننده قدرت تفکیک بالای بردار ویژگی‌های استخراج شده است.

۳.۴ ارزیابی کمی خوشه‌بندی (Clustering Metrics Summary)

در بخش یادگیری بدون نظارت، میزان انطباق طبیعی داده‌ها با زبان‌ها با استفاده از معیارهای خلوص (Purity) و امتیاز سیلوئت ارزیابی شد.

جدول ۳: گزارش عملکرد مدل طبقه‌بندی به تفکیک زبان‌های هدف

Support	F1-Score	Recall	Precision	Language
۰.۳۸	۰.۱	۰.۱	۰.۱	German
۰.۳۵	۰.۱	۰.۱	۰.۱	Italian
۰.۴۷	۰.۱	۰.۱	۰.۱	Korean
۰.۴۰	۰.۱	۰.۱	۰.۱	Spanish
۰.۱۶۰	۰.۱	۰.۱	۰.۱	Weighted Avg

جدول ۴: تجمیع معیارهای ارزیابی خوشه‌بندی (برای $k=8$)

Agglomerative	GMM	K-Means	Metric
N/A	N/A	۲۲۷.۰	Silhouette Score
۸۹۷.۰	۸۳۲.۰	۸۹۴.۰	Cluster Purity

۴.۴ تحلیل و نتیجه‌گیری نهایی (Conclusion and Synthesis)

تحلیل نهایی نتایج نشان‌دهنده موفقیت سیستم در بازشناسی زبان از روی سیگنال گفتار است:

۱. برتری ویژگی‌های آکوستیک: ویژگی‌های MFCC و طیفی توانسته‌اند تفاوت‌های ظریف زبانی را به خوبی مدل‌سازی کنند، به طوری که در بخش نظارت‌شده (Classification) هیچ خطایی مشاهده نشد.

۲. تحلیل خوشه‌بندی: دستیابی به خلوص حدود ۹۰٪ در الگوریتم‌های Agglomerative و K-Means نشان می‌دهد که خوشه‌های طبیعی داده‌ها تا حد بسیار زیادی بر زبان‌های واقعی منطبق هستند. تداخل اندک باقی‌مانده (حدود ۱۰٪) ناشی از ویژگی‌های مشترک آکوستیک بین زبان‌های هم‌ریشه (مانند ایتالیایی و اسپانیایی) در شرایط بدون نظارت است.

۳. توجیه ساختار داده‌ها: امتیاز سیلوئت ۲۲۷.۰ در کنار عدد $k=8$ تایید می‌کند که داده‌ها دارای ساختارهای سلسله‌مراتبی (مثل زیرخوشه‌های جنسیتی) هستند که باعث شده الگوریتم‌های بدون نظارت مرزهای دقیق‌تری نسبت به صرفاً ۴ زبان پیدا کنند.

۵.۴ محدودیت‌ها و پیشنهادهای آتی (Limitations and Future Work)

علی‌رغم دستیابی به نتایج ایده‌آل در این پروژه، سیستم حاضر دارای محدودیت‌هایی است که در فازهای عملیاتی باید مورد توجه قرار گیرند:

- **حساسیت به نویز محیطی:** داده‌های فعلی از کتاب‌های صوتی با کیفیت بالا استخراج شده‌اند؛ بررسی عملکرد مدل در محیط‌های نویزی (Real-world noise) گام بعدی توسعه خواهد بود.
- **تنوع لهجه‌ها:** برای تعمیم‌پذیری بیشتر، مدل باید بر روی لهجه‌های مختلف از یک زبان واحد (مثلاً اسپانیایی مکزیک در مقابل اسپانیایی اروپایی) نیز آزمایش شود.
- **استفاده از مدل‌های عمیق:** با افزایش حجم داده‌ها، استفاده از شبکه‌های عصبی پیچیده مانند CNN یا Transformers می‌تواند الگوهای زمانی دقیق‌تری را استخراج کند.

در این بخش، منابع و مراجع علمی که در طول فرآیند پیاده‌سازی، تحلیل و تدوین گزارش مورد استفاده قرار گرفته‌اند، فهرست شده است.

1. **Librosa Library Documentation:** Brian McFee, et al. "Librosa: Audio and Music Signal Analysis in Python." *Proceedings of the 14th Python in Science Conference*, 2015.
2. **Scikit-learn Documentation:** Fabian Pedregosa, et al. "Scikit-learn: Machine Learning in Python." *Journal of Machine Learning Research*, 2011.
3. **Feature Extraction Principles:** Logan, Beth. "Mel Frequency Cepstral Coefficients for Music Modeling." *International Symposium on Music Information Retrieval (IS-MIR)*, 2000.
4. **Acoustic Analysis of Language:** Jurafsky, Dan, and James H. Martin. *Speech and Language Processing*. Stanford University, 2023.
5. **Support Vector Machines Theory:** Cortes, Corinna, and Vladimir Vapnik. "Support-vector networks." *Machine Learning*, 1995.
6. **K-Means Clustering Analysis:** MacQueen, J. "Some methods for classification and analysis of multivariate observations." *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, 1967.
7. **Dimensionality Reduction (t-SNE/PCA):** Maaten, Laurens van der, and Geoffrey Hinton. "Visualizing data using t-SNE." *Journal of Machine Learning Research*, 2008.