



دانشگاه تهران
پردیس دانشکده‌های فنی
دانشکده مهندسی برق و کامپیوتر



یادگیری ماشین

تمرین شماره ۲

نام و نام خانوادگی
پریا خلیلی

شماره دانشجویی
۸۱۰۸۰۱۰۶۵

۳ آذر ۱۴۰۴

فهرست مطالب

۲	۱ پرسش ۱ - مسئله بهینه‌سازی جستجوی خطی
۲	۱.۱ الف) فرم کلی و نقش‌های جهت جستجو و طول گام
۳	۲.۱ ب) تعریف و شرط جهت کاهشی
۴	۳.۱ ج) روش‌های تعیین طول گام
۵	۴.۱ د) تابع درجه دو
۷	۲ پرسش ۲ - ماشین بردار پشتیبان SVM
۷	۱.۲ الف) فرم اولیه (Primal) برای حاشیه سخت (Hard Margin)
۸	۲.۲ ب) لاگرانژین و شرایط ایستایی (Stationarity)
۱۰	۳.۲ ج) مسئله دوگان (Dual Problem)
۱۱	۴.۲ د) بردارهای پشتیبان و بازیابی پارامترها
۱۲	۵.۲ ه) حاشیه نرم (Soft Margin) و تغییر در دوگان
۱۴	۶.۲ و) کرنل‌سازی (Kernelization)
۱۶	۳ پرسش ۳ - بهینه‌سازی دوسطحی Bilevel Optimization
۱۶	۱.۳ الف) فرمول‌بندی مسئله
۱۶	۲.۳ ب) حل مسئله پیرو $(y^*(x))$
۱۷	۳.۳ ج) جایگذاری و فرمولاسیون نهایی رهبر
۱۸	۴.۳ د) یافتن (x^*, y^*)
۲۰	۵.۳ ه) بحث عمیق در مورد نظم و قواعد (Regularity)
۲۲	۴ پرسش ۴ - بهینه‌سازی چند هدفه
۲۲	۱.۴ تعریف بهینگی پارتو (Pareto Optimality)
۲۲	۲.۴ ۲. روش اسکالارسازی مجموع وزن‌دار (Weighted-Sum Scalarization) . .

۳.۴	بیان پارامتری جبهه پارتو (Pareto Front)	۲۴
۴.۴	قید ϵ و رابطه با w (Epsilon-Constraint and KKT)	۲۷
۵.۴	محاسبات برای مقادیر w	۲۸
۵	پرسش ۷ - روش های گرادیان کاهشی	۳۰
۱.۵	(الف) بار محاسباتی به ازای هر تکرار (Computational Load per Iteration)	۳۰
۲.۵	(ب) نویز (واریانس) در تخمین گرادیان	۳۱
۳.۵	(ج) پایداری و ماهیت همگرایی به مینیمم	۳۱
۶	پرسش ۸: جهت تندترین کاهش از طریق تیلور مرتبه اول	۳۳
۷	پرسش ۹ - اثبات کمینه سازی حداقل مربعات توسط راه حل شبه معکوس	۳۵
۸	پرسش ۱۰ - روش های نیوتن و شبه نیوتن Newton and Quasi-Newton Methods	۳۷
۱.۸	(الف) گام نیوتن چگونه محاسبه می شود؟	۳۷
۲.۸	(ب) چه زمانی روش نیوتن در همگرا شدن به مینیمم شکست می خورد؟	۳۸
۳.۸	(ج) چه زمانی جهت نیوتن یک جهت کاهش (Descent Direction) نیست؟	۴۰
۴.۸	(د) ایده اصلی روش های شبه نیوتن (Quasi-Newton) چیست؟	۴۰
۵.۸	(ه) چگونه تقریب هسین را بدون مشتقات صریح انجام می دهند؟	۴۰
۹	پرسش ۱۱ - همگرایی درجه دوم روش نیوتن	۴۱
۱.۹	(الف) تعریف همگرایی درجه دوم و تفاوت آن با همگرایی خطی	۴۱
۲.۹	(ب) اثبات تقریب گام نیوتن با جابجایی دقیق $(x^* - x_k)$	۴۲
۱۰	پرسش ۱۳ - بهینه سازی مقید به تساوی از طریق لاگرانژ و نیوتن - رافسون	۴۴
۱.۱۰	(الف) نوشتن لاگرانژین $\mathcal{L}(x, y, \lambda)$	۴۴
۲.۱۰	(ب) یافتن نقطه بهینه (x^*, y^*, λ^*) با حل $\nabla_{x,y,\lambda} \mathcal{L} = 0$	۴۴
۳.۱۰	(ج) سیستم غیرخطی $F(w) = 0$	۴۵
۴.۱۰	(د) اعمال نیوتن - رافسون و محاسبه ژاکوبین $J_F(w)$	۴۶
۵.۱۰	(ه) پیاده سازی و نمایش همگرایی	۴۷
۶.۱۰	عنوان بخش	۴۹

فهرست تصاویر

۴۹		عنوان تصویر نمونه	۱
----	-------	-------------------	---

فهرست جداول

۴۹		عنوان جدول نمونه	۱
----	-------	------------------	---

در این تمرین، مفاهیم کلیدی بهینه‌سازی در یادگیری ماشین و روش‌های عددی به صورت عمیق مورد بررسی قرار گرفته‌اند. هدف اصلی، تسلط بر مبانی تئوری و محاسباتی الگوریتم‌های بهینه‌سازی، از جمله روش‌های گرادیان (مانند جستجوی خطی و نیوتن) است. مراحل انجام کار شامل استخراج فرم‌های ریاضی، اثبات شروط همگرایی و کاهشی، و تحلیل عملکرد الگوریتم‌های مختلف (مانند SVM، گرادیان کاهشی، و نیوتن) بر روی توابع هدف گوناگون (مانند تابع درجه دوم و تابع روزنبروک) می‌باشد. انتظار می‌رود نتایج به دست آمده، درکی جامع از چگونگی انتخاب و پیاده‌سازی موثرترین روش بهینه‌سازی متناسب با ساختار مسئله فراهم کند.

پرسش ۱ - مسئله بهینه‌سازی جستجوی خطی

۱.۱ الف) فرم کلی و نقش‌های جهت جستجو و طول گام

فرم کلی مسئله بهینه‌سازی که الگوریتم‌های جستجوی خطی (Line Search) در هر تکرار k حل می‌کنند، به صورت زیر است:

$$\min_{\alpha > 0} \phi(\alpha) = f(x_k + \alpha p_k)$$

مسئله جستجوی خطی (Line Search Problem) یک زیرمسئله حیاتی در الگوریتم‌های بهینه‌سازی است که هدف آن تعیین α طول گام مناسب پس از انتخاب یک جهت کاهشی (p_k) است. این مسئله بهینه‌سازی چندبُعدی اصلی $(\min f(x))$ را به یک مسئله یک‌بُعدی تبدیل می‌کند.

- تابع هدف اصلی (f) : این تابعی است که در مسئله اصلی بهینه‌سازی قصد مینیمم کردن آن را داریم $(f : \mathbb{R}^n \rightarrow \mathbb{R})$.

- نقطه جاری (x_k) : بردار پارامترها در تکرار فعلی است. این نقطه، مبدأ جستجوی خطی محسوب می‌شود.

- جهت جستجو (p_k) : این بردار، مسیری را تعیین می‌کند که در آن جستجوی طول گام انجام می‌شود. p_k باید یک جهت کاهشی $**$ باشد (مانند $-\nabla f(x_k)$).

- طول گام (α) : این تنها متغیر بهینه‌سازی $**$ در این فرمول است و مقدار آن نشان می‌دهد که چقدر باید در راستای p_k حرکت کنیم. شرط $\alpha > 0$ حرکت به جلو را تضمین می‌کند.

- تابع هدف یک‌بُعدی $(\phi(\alpha))$: این تابع، مقدار تابع هدف اصلی f را در امتداد خط تعریف شده توسط x_k و p_k محاسبه می‌کند. x_{k+1} برابر است با $x_k + \alpha p_k$.

نحوه عملکرد:

۱. تعیین خط: الگوریتم، یک جهت کاهشی p_k را انتخاب کرده و یک خط مستقیم را در فضای پارامترها تعریف می‌کند.

۲. حل مسئله ساده شده: با تبدیل $f(x)$ به $\phi(\alpha)$ ، مسئله از فضای n -بعدی به یک مسئله یک‌بعدی (مینیم کردن $\phi(\alpha)$ نسبت به α) ساده می‌شود.

۳. یافتن گام بهینه: هدف نهایی یافتن α^* است که $\phi(\alpha)$ را مینیمم کند، تا بیشترین کاهش مقدار تابع هدف f در تکرار جاری حاصل شود.

۴. تکرار بعدی: نقطه بهینه بعدی x_{k+1} با استفاده از $x_{k+1} = x_k + \alpha^* p_k$ محاسبه می‌شود و این فرایند تکرار می‌گردد.

● جهت جستجو (p_k): این بردار، جهت حرکت از نقطه فعلی x_k را در فضای پارامتر تعیین می‌کند. هدف آن اطمینان از حرکت به سمت ناحیه‌ای با مقدار تابع هدف پایین‌تر است (مثلاً $p_k = -\nabla f(x_k)$).

● طول گام (α): یک مقدار اسکالر مثبت که تعیین می‌کند چه مقدار در راستای p_k پیشروی کنیم. انتخاب بهینه α برای جلوگیری از واگرایی یا کندی همگرایی حیاتی است.

۲.۱ (ب) تعریف و شرط جهت کاهشی

یک بردار p را **جهت کاهشی** (Descent Direction) در نقطه x_k برای تابع مشتق‌پذیر f می‌نامند، اگر حرکت در این جهت باعث **کاهش آنی** مقدار تابع شود. شرط لازم و کافی برای اینکه p یک جهت کاهشی باشد، این است که **مشتق جهتی** تابع در جهت p منفی باشد. این شرط از نظر ریاضی به صورت زیر بیان می‌شود:

$$\nabla f(x_k)^T p < 0$$

این حاصل ضرب، مشتق جهتی (Directional Derivative) تابع f در جهت p است. این مقدار نرخ تغییر تابع در امتداد جهت p را نشان می‌دهد. این نابرابری تضمین می‌کند که زاویه بین بردار گرادیان (جهت تندترین صعود) و جهت جستجوی p (برداري که جهت حرکت مورد نظر ما را از نقطه x_k مشخص می‌کند)، یک زاویه باز (بزرگتر از 90° درجه) باشد.

۳.۱ ج) روش‌های تعیین طول گام

هدف این روش‌ها یافتن یک طول گام (α) مناسب در جهت p_k است تا نقطه جدید x_{k+1} مقدار کمتری از تابع هدف داشته باشد.

۱. جستجوی خطی دقیق (Exact Line Search):

- ایده اصلی: این روش دقیق‌ترین حالت است و به دنبال یافتن α^* است که تابع یک‌بُعدی $\phi(\alpha) = f(x_k + \alpha p_k)$ را به صورت سراسری مینیمم کند.
- نحوه تعیین: برای توابع درجه دو (مانند سوال ۱ (د)) با حل تحلیلی معادله $\frac{d\phi}{d\alpha} = 0$ به دست می‌آید.
- کاربرد: در عمل، این روش برای توابع پیچیده و غیر درجه دو از لحاظ محاسباتی بسیار پرهزینه است و اغلب غیرقابل استفاده است.

۲. جستجوی خطی غیردقیق (آرمیجو / عقب‌گرد):

- ایده اصلی: به جای یافتن مینیمم مطلق، به دنبال یافتن اولین α است که یک کاهش کافی (Sufficient Decrease) در مقدار تابع هدف را تضمین کند.
- شرط آرمیجو: این شرط تضمین می‌کند که کاهش واقعی حداقل به اندازه یک کسری از کاهش پیش‌بینی شده توسط گرادیان باشد:

$$f(x_k + \alpha p_k) \leq f(x_k) + c_1 \alpha \nabla f(x_k)^\top p_k$$

- نحوه کار (عقب‌گرد): الگوریتم با یک گام بزرگ (معمولاً $\alpha = 1$) شروع کرده و اگر شرط برقرار نشد، آن را به صورت تکراری با ضریب کاهش $\tau < 1$ (مثلاً $\tau = 0.5$) کوچک می‌کند ($\alpha \leftarrow \tau \alpha$) تا شرط برای اولین بار ارضا شود.

۳. شرایط ولف (Wolfe Conditions):

- ایده اصلی: روش آرمیجو (شرط ۲) ممکن است گام‌های بسیار کوتاه انتخاب کند که همگرایی را کند می‌کند. شرایط ولف مجموعه‌ای از دو شرط است که علاوه بر کاهش کافی، ****بزرگی گام**** را نیز تضمین می‌کند.
- شرط ۱ (آرمیجو): همان شرط کاهش کافی است (برای جلوگیری از گام‌های بزرگ).
- شرط ۲ (انحنا): این شرط از انتخاب گام‌های بسیار کوتاه جلوگیری می‌کند و اطمینان می‌دهد که شیب تابع در نقطه جدید به اندازه کافی کم شده است:

$$\nabla f(x_k + \alpha p_k)^\top p_k \geq c_2 \nabla f(x_k)^\top p_k$$

سمت چپ: شیب تابع در نقطه جدید (x_{k+1}) در جهت حرکت (p_k) را نشان می‌دهد. سمت راست: شیب تابع در نقطه شروع (x_k) در جهت حرکت (p_k) را نشان می‌دهد (یک عدد منفی است). این شرط می‌گوید شیب در نقطه جدید باید به اندازه کافی کم شده باشد. به عبارت دیگر، شما آنقدر دور شده‌اید که شیب منحنی تقریباً صاف شده است. اگر α خیلی کوچک باشد، شیب در نقطه جدید (سمت چپ) تقریباً برابر با شیب در نقطه شروع (سمت راست) می‌ماند، و شرط برقرار نمی‌شود.

- نقش: این روش گامی را تضمین می‌کند که نه تنها کافی، بلکه کارآمد (دور از شروع) است، و پایه و اساس بسیاری از الگوریتم‌های شبه‌نیوتن پیشرفته می‌باشد.

۴.۱ (د) تابع درجه دو

تابع $f(x_1, x_2) = 2x_1^2 + x_1x_2 + 4x_2^2$ با نقطه $x^{(t)} = (0, 1)^\top$ و جهت $p^{(t)} = (1, -2)^\top$.
۱. اثبات جهت کاهشی بودن $p^{(t)}$ گرادیان تابع f به صورت زیر است:

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \end{pmatrix} = \begin{pmatrix} 4x_1 + x_2 \\ x_1 + 8x_2 \end{pmatrix}$$

گرادیان در نقطه $x^{(t)}$:

$$\nabla f(x^{(t)}) = \begin{pmatrix} 4(0) + 1 \\ 0 + 8(1) \end{pmatrix} = \begin{pmatrix} 1 \\ 8 \end{pmatrix}$$

محاسبه حاصل ضرب داخلی:

$$\nabla f(x^{(t)})^\top p^{(t)} = \begin{pmatrix} 1 & 8 \end{pmatrix} \begin{pmatrix} 1 \\ -2 \end{pmatrix} = (1)(1) + (8)(-2) = 1 - 16 = -15$$

چون $\nabla f^\top p = -15 < 0$ است، $p^{(t)}$ یک جهت کاهشی است.
۲. تشکیل و ساده‌سازی تابع $\phi(\alpha)$ ابتدا $x^{(t)} + \alpha p^{(t)}$ را محاسبه می‌کنیم:

$$x(\alpha) = \begin{pmatrix} 0 \\ 1 \end{pmatrix} + \alpha \begin{pmatrix} 1 \\ -2 \end{pmatrix} = \begin{pmatrix} \alpha \\ 1 - 2\alpha \end{pmatrix}$$

با جایگذاری در $f(x)$:

$$\begin{aligned} \phi(\alpha) &= 2(\alpha)^2 + (\alpha)(1 - 2\alpha) + 4(1 - 2\alpha)^2 \\ &= 2\alpha^2 + (\alpha - 2\alpha^2) + 4(1 - 4\alpha + 4\alpha^2) \\ &= 2\alpha^2 + \alpha - 2\alpha^2 + 4 - 16\alpha + 16\alpha^2 \\ &= 16\alpha^2 - 15\alpha + 4 \end{aligned}$$

تابع $\phi(\alpha)$ به فرم درجه دوم $A\alpha^2 + B\alpha + C$ ساده شد.

۳. محاسبه α^* نشان‌دهنده طول گام بهینه (Optimal Step Length) است که در فرآیند جستجوی خطی دقیق (Exact Line Search) پیدا می‌شود. نقطه مینیمم یک تابع درجه دوم در $\alpha^* = -B/(2A)$ یا با صفر قرار دادن مشتق یافت می‌شود:

$$\frac{d\phi}{d\alpha} = 32\alpha - 15 = 0$$

$$\alpha^* = \frac{15}{32}$$

پرسش ۲ - ماشین بردار پشتیبان SVM

۱.۲ الف) فرم اولیه (Primal) برای حاشیه سخت (Hard Margin)

مفهوم حاشیه سخت: مسئله SVM حاشیه سخت تنها در شرایطی قابل تعریف و حل است که مجموعه داده‌های آموزشی به صورت ****خطی جداپذیر (Linearly Separable)**** باشند. در این حالت، الگوریتم به دنبال یافتن ابرصفحه جداکننده $\mathbf{w}^\top \mathbf{x} + \mathbf{b} = 0$ است به طوری که هیچ نقطه داده‌ای نباید حاشیه (Margin) را نقض کند. هدف نهایی، حداکثرسازی فاصله بین نزدیک‌ترین نقاط هر دو کلاس است.

۱. تابع هدف (حداکثرسازی حاشیه): حاشیه هندسی ابرصفحه با $\frac{1}{\|\mathbf{w}\|}$ متناسب است. بنابراین، حداکثر کردن حاشیه معادل مینیم کردن ****نرم اقلیدسی $\|\mathbf{w}\|$ **** است. برای سادگی محاسبات در مراحل بعدی (به ویژه مشتق‌گیری نسبت به w) از تابع محدب درجه دوم $\frac{1}{2}\|\mathbf{w}\|^2$ استفاده می‌شود که هدف بهینه‌سازی معادل را حفظ می‌کند:

$$\min_{w,b} \frac{1}{2} \|\mathbf{w}\|^2$$

۲. قید تفکیک‌پذیری (حاشیه سخت): این قید، شرط اصلی "حاشیه سخت" است. ما نیاز داریم که فاصله عملکردی (Functional Margin) برای همه نقاط، حداقل ۱ باشد:

$$y_i(w^\top x_i + b) \geq 1 \quad \forall i = 1, \dots, N$$

این قیدها دو ****اب‌صفحه موازی**** را تعریف می‌کنند که حاشیه را در بر می‌گیرند:

$$\bullet \quad \mathbf{w}^\top \mathbf{x} + \mathbf{b} = 1 : +1 \text{ کلاس}$$

$$\bullet \quad \mathbf{w}^\top \mathbf{x} + \mathbf{b} = -1 : -1 \text{ کلاس}$$

(این شرط تضمین می‌کند که بردارهای پشتیبان (Support Vectors) روی این مرزها قرار

گیرند و فاصله هندسی بین این دو ابرصفحه $\frac{2}{\|w\|}$ است که باید حداکثر شود.

فرم نهایی مسئله اولیه (آماده برای لاگرانژین):

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad \text{s.t.} \quad 1 - y_i(w^\top x_i + b) \leq 0$$

۲.۲ ب) لاگرانژین و شرایط ایستایی (Stationarity)

هدف اصلی استفاده از لاگرانژین، تبدیل یک مسئله بهینه‌سازی دارای قید به یک مسئله نامقید است.

نقش α_i : ضرب‌کننده لاگرانژ α_i به عنوان یک "وزن" یا "جریمه" برای قید مربوطه عمل می‌کند. با ضرب قید در α_i و اضافه کردن آن به تابع هدف، ما عملاً قید را به درون تابع هدف جذب می‌کنیم.

مزیت: با این تبدیل، می‌توانیم با گرفتن مشتق جزئی نسبت به همه متغیرها (w ، b و α) و صفر قرار دادن آن‌ها ($\nabla \mathcal{L} = 0$)، نقاط بحرانی را پیدا کنیم، کاری که در مسائل مقید به سادگی ممکن نبود.

برای تبدیل مسئله مقید به یک مسئله نامقید، لاگرانژین را با استفاده از ضرب‌کننده‌های لاگرانژ ($\alpha_i \geq 0$) تشکیل می‌دهیم:

۱. تشکیل لاگرانژین:

$$\mathcal{L}(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^N \alpha_i [y_i(w^\top x_i + b) - 1]$$

۲. شرایط ایستایی (KKT): در نقطه بهینه، مشتقات لاگرانژین نسبت به پارامترهای اولیه (w و b) باید صفر باشند: * مشتق نسبت به w :

$$\frac{\partial \mathcal{L}}{\partial w} = w - \sum_{i=1}^N \alpha_i y_i x_i = 0 \implies \mathbf{w} = \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i$$

* مشتق نسبت به b :

$$\frac{\partial \mathcal{L}}{\partial b} = - \sum_{i=1}^N \alpha_i y_i = 0 \implies \sum_{i=1}^N \alpha_i y_i = 0$$

ایستایی (Stationarity) در بهینه‌سازی، یک شرط ریاضی ضروری برای یافتن نقاط بحرانی (Critical Points) است. این شرط هسته اصلی تمام الگوریتم‌های مبتنی بر گرادیان است. ۱. معنی کلی ایستایی در حالت بهینه‌سازی نامقید (مانند یافتن مینیمم یک تابع معمولی): تعریف: یک نقطه x^* را نقطه ایستایی می‌نامند اگر گرادیان تابع در آن نقطه برابر با صفر باشد.

$$\nabla f(x^*) = 0$$

تفسیر: صفر بودن گرادیان به این معنی است که در آن نقطه، هیچ جهت محلی وجود ندارد که بتواند مقدار تابع را فوراً کاهش یا افزایش دهد. به عبارت دیگر، شما در بالای یک قله (ماکزیمم)، در انتهای یک دره (مینیمم)، یا در یک نقطه زین اسبی (Saddle Point) قرار دارید. ۲. ایستایی در روش لاگرانژین و در SVM روش حل مسئله با استفاده از لاگرانژین (بهینه‌سازی مقید)، شرط ایستایی یکی از سه بخش اصلی شرایط کاروش-کون-تاکر (KKT Conditions) است.

$$\nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}^*, \lambda^*) = 0$$

وقتی لاگرانژین ($\mathcal{L}$) را نسبت به پارامترهای اصلی (w و b) مشتق می‌گیریم و برابر صفر قرار می‌دهیم:

$$\frac{\partial \mathcal{L}}{\partial w} = 0 \quad \text{و} \quad \frac{\partial \mathcal{L}}{\partial b} = 0$$

نقش: این شرایط تضمین می‌کنند که در نقطه بهینه، جهت گرادیان تابع هدف (∇f) با جهت گرادیان قیدها (∇g_i) هم‌راستا باشد (با ضریب لاگرانژ α_i). به بیان دیگر، این شرط نقطه بهینه‌ای را پیدا می‌کند که در آن دیگر امکان بهبود تابع هدف بدون نقض قیدها وجود ندارد. ۳. نتیجه ایستایی برای پارامترهای در SVM مسئله SVM (بخش ب)، اعمال شرط ایستایی نسبت به w و b دو رابطه حیاتی را به دست آورد که در واقع تعریف بردار وزن نهایی را مشخص می‌کنند: ایستایی نسبت به w :

$$\mathbf{w} = \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i$$

این شرط ایستایی حکم می‌کند که بردار وزن نهایی باید ترکیبی خطی از نقاط داده باشد. ایستایی نسبت به b :

$$\sum_{i=1}^N \alpha_i y_i = 0$$

این شرط به صورت ضمنی بیان می‌کند که مجموع وزن‌های (جریمه‌های) بردارهای پشتیبان (Support Vectors) برای کلاس $+1$ باید با مجموع وزن‌ها برای کلاس -1 برابر باشد. نتیجه نهایی: ایستایی نه تنها یک شرط برای توقف جستجوی الگوریتم است، بلکه یک معادله است که در مسئله SVM، به ما اجازه می‌دهد w و b را بر حسب متغیرهای دوگان (α_i) بیان کنیم و مسئله را به فرمول‌بندی ساده‌تر دوگان تبدیل کنیم.

۳.۲ ج) مسئله دوگان (Dual Problem)

با جایگذاری روابط ایستایی در لاگرانژین، به مسئله دوگان (که تنها بر حسب α است) می‌رسیم. هدف تبدیل مینیمم‌سازی لاگرانژین نسبت به w, b به ماکزیمم‌سازی آن نسبت به α است. فرمول نهایی مسئله دوگان:

$$\max_{\alpha} \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i^T x_j)$$

s. t.

$$\alpha_i \geq 0 \quad \text{and} \quad \sum_{i=1}^N \alpha_i y_i = 0$$

تبدیل مسئله اولیه SVM (Primal) به مسئله دوگان (Dual Problem) با استفاده از روش دوگانگی لاگرانژ (Lagrange Duality) انجام می‌گیرد. هدف از این تبدیل، تغییر جهت بهینه‌سازی از مینیمم‌سازی لاگرانژین نسبت به پارامترهای اولیه (w, b) به یک ماکزیمم‌سازی نسبت به متغیرهای دوگان (α) است. فرآیند به این صورت است که ابتدا با اعمال شرایط ایستایی ($\nabla_w \mathcal{L} = 0$ و $\nabla_b \mathcal{L} = 0$)، پارامترهای w و b از طریق یک فرآیند جایگذاری حذف می‌شوند، و تابع هدف دوگان $g(\alpha)$ (فرمول طولانی مسئله دوگان) از $\min_{w,b} \mathcal{L}$ استخراج می‌شود. سپس با ماکزیمم کردن $g(\alpha)$ نسبت به α ، راه‌حل بهینه پیدا می‌شود؛ که به دلیل ماهیت محدب SVM، به واسطه دوگانگی قوی (Strong Duality)، با پاسخ بهینه مسئله اولیه یکسان است. قیدهای مسئله دوگان نیز مستقیماً از شرایط KKT ناشی می‌شوند: قید $\alpha_i \geq 0$ از شرط نامنفی بودن

ضرب‌کننده‌ها برای قیده‌های نامساوی اولیه و قید $\sum \alpha_i y_i = 0$ از شرط ایستایی نسبت به متغیر بایاس (b) که نامقید بود، به دست می‌آیند.

۴.۲ (د) بردارهای پشتیبان و بازیابی پارامترها

تعریف پارامترها:

- w^* : بردار وزن بهینه** که بر ابرصفحه تصمیم عمود است.
- b^* : بایاس بهینه** که موقعیت ابرصفحه را تعیین می‌کند.
- α_i^* : ضرب‌کننده لاگرانژ بهینه** (وزن ریاضی نقطه x_i).
- x_i و y_i : نقطه داده i ام و برچسب کلاس آن (± 1).
- بردارهای پشتیبان (Support Vectors): اینها نقاط داده‌ای هستند که **شرط مکمل بودن سستی (Complementary Slackness)** را نقض نمی‌کنند و در تعیین مرز تصمیم مشارکت فعال دارند.
- شرط مکمل بودن سستی: این شرط به صورت $\alpha_i [y_i(w^T x_i + b) - 1] = 0$ بیان می‌شود و حکم می‌کند:
 - اگر $y_i(w^T x_i + b) > 1$ (نقطه از حاشیه فاصله دارد)، آنگاه باید $\alpha_i = 0$ باشد (نقطه نقشی در w^* ندارد).
 - اگر $\alpha_i > 0$ (نقطه وزن دارد)، آنگاه باید $y_i(w^T x_i + b) = 1$ باشد (نقطه **دقیقاً روی مرز حاشیه** است).
- **بردارهای پشتیبان** دقیقاً همان نقاطی هستند که برای آن‌ها $\alpha_i^* > 0$ به دست می‌آید.
- بازیابی w^* و b^* :

۱. بردار وزن (w^*): این بردار به طور مستقیم از **رابطه ایستایی** (بخش ب) که پس از حل مسئله دوگان، بهینه شده است، به دست می‌آید. این رابطه نشان می‌دهد که w^* فقط توسط بردارهای پشتیبان تعیین می‌شود:

$$w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$$

۲. بایاس (b^*): برای بازیابی b^* ، باید از شرط ****مکمل بودن سستی**** برای هر بردار پشتیبان x_s (که $\alpha_s^* > 0$) استفاده کنیم، زیرا می‌دانیم برای این نقاط، قید باید به صورت تساوی باشد:

$$y_s(w^{*\top} x_s + b^*) = 1$$

با ضرب طرفین در y_s (توجه داشته باشید که $y_s^2 = 1$)، b^* به صورت زیر بازیابی می‌شود:

$$b^* = y_s - w^{*\top} x_s$$

۵.۲ ه) حاشیه نرم (Soft Margin) و تغییر در دوگان

مفهوم حاشیه نرم: مدل ****حاشیه سخت**** تنها برای داده‌های کاملاً خطی جداپذیر کار می‌کند. برای مقابله با ****داده‌های غیر قابل تفکیک خطی****، نویز، و جلوگیری از **** (Overfitting) ****، مدل حاشیه نرم معرفی می‌شود. حاشیه نرم اجازه می‌دهد که برخی از نقاط، حاشیه را نقض کنند (حتی به اشتباه طبقه‌بندی شوند) در ازای آنکه ابرصفحه جداساز، عمومی‌تر و قوی‌تر باشد.

۱. فرم اولیه با حاشیه نرم: برای اجازه نقض، از ****متغیرهای سستی (Slack Variables) $\xi_i \geq 0$ **** استفاده می‌شود.

• **** ξ_i چیست؟**** ξ_i میزان نقض قید حاشیه توسط نقطه داده i ام را اندازه‌گیری می‌کند. اگر $\xi_i = 0$ باشد، قید رعایت شده است. اگر $\xi_i > 0$ باشد، قید نقض شده است.

• ****پارامتر جریمه C :**** ترم $\sum \xi_i$ به تابع هدف اضافه می‌شود. C پارامتر تنظیم‌کننده است که تعادل بین ****حداکثرسازی حاشیه**** (مینیم کردن $\|w\|^2$) و ****به حداقل رساندن خطا**** (مینیم کردن $\sum \xi_i$) را برقرار می‌کند.

فرم نهایی مسئله اولیه حاشیه نرم:

$$\min_{w, b, \xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i$$

s. t.

$$y_i(w^\top x_i + b) \geq 1 - \xi_i \quad \text{and} \quad \xi_i \geq 0$$

۲. تغییر در مسئله دوگان و قید C : برای رسیدن به فرمول دوگان، لاگرانژین جدیدی تشکیل

می‌شود که شامل ضرب‌کننده‌های α_i (برای قید حاشیه) و μ_i (برای قید $\xi_i \geq 0$) است. با اعمال شرایط ایستایی نسبت به w, b, ξ ، در نهایت ξ_i و μ_i حذف می‌شوند. شرط ایستایی نسبت به ξ_i ، منجر به قید زیر در مسئله دوگان می‌شود:

$$\alpha_i + \mu_i = C$$

از آنجایی که $\mu_i \geq 0$ (زیرا یک ضرب‌کننده لاگرانژ است)، این رابطه منجر به ایجاد یک α_i $\leq C$ می‌شود:

$$0 \leq \alpha_i \leq C$$

(فرم نهایی تابع هدف دوگان دقیقاً شبیه حالت حاشیه سخت است، تنها قید تغییر می‌کند.)

$$\max_{\alpha} \quad W(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (\mathbf{x}_i^T \mathbf{x}_j)$$

s. t.

$$\sum_{i=1}^N \alpha_i y_i = 0$$

$$0 \leq \alpha_i \leq C \quad \forall i = 1, \dots, N$$

معنی قید $0 \leq \alpha_i \leq C$: این قید، وزن مجاز α_i را برای هر بردار پشتیبان محدود می‌کند و نقش نقطه داده را مشخص می‌سازد:

- $\alpha_i = 0$: نقطه در داخل حاشیه قرار ندارد و در تعیین مرز α_i نقشی ندارد.
- $0 < \alpha_i < C$: نقطه یک بردار پشتیبان است و α_i دقیقاً روی مرز حاشیه قرار دارد (مانند حاشیه سخت).
- $\alpha_i = C$: نقطه یک بردار پشتیبان است که یا α_i حاشیه را نقض کرده یا α_i به اشتباه طبقه‌بندی شده است. این نقطه بیشترین جریمه ممکن (C) را برای کمک به تعریف مرز دریافت کرده است.

۶.۲ و کرنل سازی (Kernelization)

کرنل سازی یا ترفند کرنل (Kernel Trick) یک مفهوم بنیادی است که به SVM اجازه می دهد تا مرزهای تصمیم گیری غیرخطی را مدل کند بدون اینکه نیاز به کار صریح در فضای ویژگی با ابعاد بالاتر باشد.

منشأ و ضرورت:

- مسئله غیرخطی: اگر داده ها در فضای ویژگی اصلی خطی جداپذیر نباشند، SVM حاشیه سختی پیدا نمی کند.

- راه حل ضمنی: برای حل این مسئله، داده ها باید به یک فضای جدید با ابعاد بالاتر نگاشت شوند، جایی که انتظار می رود تفکیک خطی ممکن باشد ($\Phi(x)$).

۱. نقش ترفند کرنل (Kernel Trick): در فرمول دوگان، همانطور که قبلاً دیدیم، نقاط داده همیشه به شکل حاصل ضرب داخلی ($x_i^T x_j$) ظاهر می شوند. این وابستگی انحصاری به حاصل ضرب داخلی، فرصت استفاده از ترفند کرنل را فراهم می کند.

۲. جایگزینی: به جای محاسبه صریح نگاشت $\Phi(x)$ در فضای بالا (که ممکن است هزینه بر یا ناممکن باشد)، ما حاصل ضرب داخلی در فضای اصلی را با یک تابع کرنل $K(x_i, x_j)$ جایگزین می کنیم:

$$x_i^T x_j \xrightarrow{\text{Trick Kernel}} K(x_i, x_j)$$

که $K(x_i, x_j)$ به عنوان حاصل ضرب داخلی در فضای ویژگی نگاشت شده تعریف می شود:

$$K(x_i, x_j) = \Phi(x_i)^T \Phi(x_j)$$

۳. مزیت: این تکنیک باعث می شود که SVM به صورت ضمنی، داده ها را به یک فضای ویژگی با ابعاد بسیار بالا نگاشت کند که در آن تفکیک خطی ممکن می شود، بدون اینکه بار محاسباتی مربوط به آن فضای بالا متحمل شود. این کار انعطاف پذیری مدل را برای یادگیری مرزهای غیرخطی پیچیده، به شدت افزایش می دهد.

تابع تصمیم نهایی SVM (Decision Function)، برای یک نقطه جدید x_{test} ، خروجی خام $f(x_{\text{test}})$ را تولید می کند که سپس علامت آن طبقه بندی را مشخص می سازد. تابع تصمیم استاندارد

در فضای ویژگی نگاشت شده (Φ) به صورت زیر است:

$$f(\mathbf{x}_{\text{test}}) = \mathbf{w}^{*\top} \Phi(\mathbf{x}_{\text{test}}) + b^*$$

از شرط ایستایی می‌دانیم که بردار وزن بهینه $\mathbf{w}^*$ ترکیبی خطی از بردارهای پشتیبان نگاشت شده است:

$$\mathbf{w}^* = \sum_{i=1}^N \alpha_i^* y_i \Phi(\mathbf{x}_i)$$

با جایگذاری $\mathbf{w}^*$ در تابع تصمیم:

$$f(\mathbf{x}_{\text{test}}) = \left(\sum_{i=1}^N \alpha_i^* y_i \Phi(\mathbf{x}_i) \right)^\top \Phi(\mathbf{x}_{\text{test}}) + b^*$$

با استفاده از خاصیت توزیع پذیری حاصل ضرب داخلی و جابه‌جایی علامت جمع و ضرب:

$$f(\mathbf{x}_{\text{test}}) = \sum_{i=1}^N \alpha_i^* y_i (\Phi(\mathbf{x}_i)^\top \Phi(\mathbf{x}_{\text{test}})) + b^*$$

در نهایت، با اعمال ترفند کرنل بر روی حاصل ضرب داخلی $(\Phi(\mathbf{x}_i)^\top \Phi(\mathbf{x}_{\text{test}}) = \mathbf{K}(\mathbf{x}_i, \mathbf{x}_{\text{test}}))$ ۲. تابع تصمیم کرنل سازی شده

$$f(\mathbf{x}_{\text{test}}) = \sum_{i \in \text{SV}} \alpha_i^* y_i \mathbf{K}(\mathbf{x}_i, \mathbf{x}_{\text{test}}) + b^*$$

طبقه‌بندی نهایی

$$\text{Classification}(\mathbf{x}_{\text{test}}) = \text{sign}(f(\mathbf{x}_{\text{test}}))$$

این فرمول نشان می‌دهد که SVM کرنل سازی شده، برای طبقه‌بندی یک نقطه جدید، تنها نیاز دارد که آن نقطه را با بردارهای پشتیبان مقایسه کند (از طریق تابع $\mathbf{K}$).

پرسش ۳ - بهینه‌سازی دوسطحی Bilevel Optimization

۱.۳ الف) فرمول‌بندی مسئله

فرمول‌بندی مسئله دوسطحی (Bilevel) ساختار سلسله‌مراتبی آن را مشخص می‌کند: مسئله سطح بالا (رهبر): رهبر متغیر x را برای کمینه کردن تابع هدف F انتخاب می‌کند، با قید $x \geq 0$.

$$\min_x F(x, y) = (x - 2)^2 + (y - 3)^2 \quad \text{s.t. } x \geq 0$$

مسئله سطح پایین (پیرو): متغیر y باید پاسخ بهینه پیرو به x باشد.

$$\text{to subject } y \in \arg \min_{y' \geq 0} \{f(x, y') = (y' - x^2)^2 + y'\}$$

۲.۳ ب) حل مسئله پیرو $(y^*(x))$

برای هر x ثابت، تابع هدف پیرو $f(y) = (y - x^2)^2 + y$ تحت قید $y \geq 0$ حل می‌شود. الف) تحلیل محدب بودن: ابتدا مشتق دوم f نسبت به y را محاسبه می‌کنیم تا از محدب بودن مطمئن شویم: $\frac{\partial^2 f}{\partial y^2} = 2$. این تابع کاملاً محدب است، بنابراین مینیمم سراسری یگانه است. ب) یافتن نقطه بحرانی (بدون قید): مشتق اول را نسبت به y صفر قرار می‌دهیم:

$$\frac{\partial f}{\partial y} = 2(y - x^2) + 1 = 0$$

$$y_{\text{crit}} = x^2 - 0.5$$

ج) اعمال قید $y \geq 0$: چون تابع محدب است، اگر y_{crit} منفی شود، مینیمم در مرز، یعنی $y = 0$ رخ می‌دهد.

$$y^*(x) = \begin{cases} x^2 - 0.5 & \text{if } x^2 \geq 0.5 \\ 0 & \text{if } x^2 < 0.5 \end{cases}$$

۳.۳ ج) جایگذاری و فرمولاسیون نهایی رهبر

هدف از این مرحله، تبدیل مسئله بهینه‌سازی دوسطحی (Bilevel) به یک مسئله بهینه‌سازی تک‌سطحی (Single-Level) و تک‌متغیره است. ۱. توجه ریاضی جایگذاری در مسئله دوسطحی، قید سطح بالا این است که y باید پاسخ بهینه پیرو به انتخاب x باشد: $y = y^*(x)$. نقش $y^*(x)$: این تابع، قید پیچیده "عضویت در مجموعه" را به یک قید تابعی ساده تبدیل می‌کند. مزیت: با جایگذاری $y^*(x)$ در $F(x, y)$ ، متغیر y از مسئله حذف می‌شود و رهبر می‌تواند مستقیماً تابع جدید $G(x)$ را کمینه کند. ۲. فرض و انتخاب تابع $y^*(x)$ پاسخ بهینه پیرو $y^*(x)$ یک تابع دوتکه‌ای بود. برای سادگی حل، فرض می‌کنیم که x^* بهینه در ناحیه‌ای قرار می‌گیرد که $y^*(x)$ از صفر بزرگتر است ($x^2 \geq 0.5$):

$$F(x, y) = (x - 2)^2 + (y - 3)^2 \text{ تابع هدف رهبر:}$$

$$y^*(x) = x^2 - 0.5$$

۳. مراحل جایگذاری و ساده‌سازی (کاهش به $G(x)$) با جایگذاری $y^*(x)$ در تابع $F(x, y)$ ، تابع تک‌متغیره $G(x)$ به دست می‌آید:

$$G(x) = F(x, y^*(x))$$

گام ۱: جایگذاری

$$G(x) = (x - 2)^2 + (y^*(x) - 3)^2$$

$$G(x) = (x - 2)^2 + ((x^2 - 0.5) - 3)^2$$

گام ۲: ساده‌سازی پیرانتز داخل عبارت $(x^2 - 0.5) - 3$ ساده می‌شود:

$$G(x) = (x - 2)^2 + (x^2 - 3.5)^2$$

گام ۳: فرم نهایی تابع تک‌متغیره

$$G(x) = (x - 2)^2 + (x^2 - 3.5)^2$$

رهبر اکنون تنها باید این تابع $G(x)$ را تحت قید $x \geq 0$ کمینه کند تا x^* بهینه را بیابد.

۴.۳ (د) یافتن (x^*, y^*)

یافتن نقطه بهینه (x^*, y^*) نیازمند کمینه‌سازی تابع هدف رهبر پس از جایگذاری پاسخ بهینه پیرو $y^*(x)$ است. این فرآیند به‌طور مستقیم به حل مسئله تک‌متغیره $G(x)$ منجر می‌شود. در قسمت‌های قبل، تابع هدف رهبر (با فرض اینکه حل در ناحیه $x^2 \geq 0.5$ رخ می‌دهد و $y^*(x) = x^2 - 0.5$ است) به صورت تک‌متغیره $G(x)$ تبدیل شد:

$$G(x) = (x - 2)^2 + (x^2 - 3.5)^2$$

هدف ما این است که $G(x)$ را تحت قید $x \geq 0$ کمینه کنیم. برای یافتن نقاط بهینه، مشتق اول $G(x)$ را نسبت به x محاسبه کرده و برابر صفر قرار می‌دهیم (شرط لازم مرتبه اول).

$$G'(x) = \frac{d}{dx} [(x - 2)^2] + \frac{d}{dx} [(x^2 - 3.5)^2]$$

$$G'(x) = 2x - 4 + 4x(x^2 - 3.5)$$

$$G'(x) = 2x - 4 + 4x^3 - 14x$$

$$G'(x) = 4x^3 - 12x - 4$$

حل برای x^* ؛ با صفر قرار دادن $G'(x)$ ، به معادله درجه سوم زیر می‌رسیم:

$$4x^3 - 12x - 4 = 0$$

$$x^3 - 3x - 1 = 0$$

این معادله سه ریشه حقیقی دارد. از آنجایی که رهبر قید $x \geq 0$ را دارد، تنها ریشه‌های مثبت را در نظر می‌گیریم. ریشه‌ای که $G(x)$ را کمینه می‌کند (و طبق تحلیل‌های بالاتر، تنها ریشه مثبت مینیمم‌کننده است) عبارت است از:

$$x^* \approx 1.879$$

ما باید مطمئن شویم که x^* به دست آمده، در ناحیه‌ای که $y^*(x) = x^2 - 0.5$ استفاده شده، قرار دارد ($x^2 \geq 0.5$).

$$x^{*2} \approx (1.879)^2 \approx 3.530$$

چون $3.530 \geq 0.5$ است، فرض ما معتبر است. با استفاده از x^* و تابع $y^*(x)$:

$$y^* = x^{*2} - 0.5$$

$$y^* \approx 3.530 - 0.5 = 3.030$$

نقطه بهینه (x^*, y^*) که تابع هدف رهبر را کمینه می‌کند، عبارت است از:

$$(x^*, y^*) \approx (1.88, 3.03)$$

۵.۳ (Regularity) بحث عمیق در مورد نظم و قواعد

محدب بودن کامل تابع هدف پیرو (Strict Convexity of Follower)

این شرط وجود یک پاسخ بهینه قابل اعتماد را تضمین می‌کند.

$$\text{تابع پیرو: } f(x, y) = (y - x^2)^2 + y$$

اثبات محدب بودن: برای تعیین اینکه تابع $f(x, y)$ نسبت به متغیر بهینه‌سازی پیرو (y) محدب است (با فرض ثابت بودن x)، از آزمون مشتق دوم استفاده می‌کنیم:

• مشتق اول:

$$\frac{\partial f}{\partial y} = 2(y - x^2) + 1$$

• مشتق دوم:

$$\frac{\partial^2 f}{\partial y^2} = 2$$

از آنجایی که مشتق دوم (عدد ۲) مثبت و بزرگتر از صفر است ($\frac{\partial^2 f}{\partial y^2} > 0$)، تابع $f(x, y)$ نسبت به y کاملاً محدب (Strictly Convex) است. این خاصیت تضمین می‌کند که هر نقطه بحرانی، یک مینیمم سراسری (Global Minimum) یگانه است.

یگانگی پاسخ بهینه پیرو (Uniqueness of Follower's Solution)

پاسخ بهینه پیرو $y^*(x)$ باید برای هر x انتخاب شده توسط رهبر، منحصر به فرد باشد.
دلیل یگانگی:

• محدب بودن کامل: چون تابع $f(x, y)$ کاملاً محدب است، نمی‌تواند بیش از یک مینیمم سراسری داشته باشد.

• تأثیر قید: قید $y \geq 0$ نیز یگانگی را حفظ می‌کند. اگر مینیمم بدون قید منفی باشد، پاسخ به مرز $y = 0$ پرتاب می‌شود که همچنان یک نقطه یگانه است.

نقش در مسئله دوسطحی: یگانگی $y^*(x)$ باعث می‌شود که قید رهبر به یک تابع صریح تبدیل شود، و نه یک مجموعه از پاسخ‌ها (مسئله $y \in Y^*(x)$). این موضوع ابهام را از بین می‌برد.

اعتبار جایگذاری و توجیه تبدیل سطح (Validity of Substitution)

این بخش، اعتبار نهایی تبدیل مسئله دوسطحی به مسئله تکسطحی $G(x)$ را توجیه می‌کند.

تحلیل جایگذاری:

● **قید اولیه:** مسئله رهبر توسط یک قید پیچیده "عضویت در مجموعه" تعریف می‌شود:

$$y \in \arg \min \{ \dots \}$$

● **حذف قید:** از آنجایی که ثابت کردیم پاسخ $y^*(x)$ کاملاً یگانه است، می‌توانیم مجموعه

$\arg \min$ را با تابع صریح $y^*(x)$ جایگزین کنیم:

$$\arg \min_{y' \geq 0} \{ f(x, y') \} \xrightarrow{\text{یگانگی}} \{ y^*(x) \}$$

این یگانگی به ما اجازه می‌دهد تا مسئله دوسطحی را به یک مسئله بهینه‌سازی تکسطحی

ساده‌تر $G(x) = F(x, y^*(x))$ تبدیل کنیم. اعتبار جایگذاری تضمین می‌کند که مینیمم کردن

$G(x)$ دقیقاً معادل حل مسئله اصلی دوسطحی است و راه حل ما را از نظر ریاضی کاملاً معتبر

می‌سازد.

پرسش ۴ - بهینه‌سازی چند هدفه

این مسئله به تحلیل بهینه‌سازی چندهدفه (MOP) می‌پردازد که در آن هیچ نقطه‌ای نمی‌تواند به طور همزمان هر دو هدف f_1 و f_2 را کمینه کند. راه حل شامل یافتن مجموعه مصالحه‌ای از راه‌حل‌ها به نام مجموعه پارتو (Pareto Set) و نگاشت آن‌ها بر جبهه پارتو (Pareto Front) است.

۱.۴ تعریف بهینگی پارتو (Pareto Optimality)

نقطه $z^* = (x^*, y^*) \in \mathbb{R}^2$ یک نقطه بهینه پارتو است اگر هیچ نقطه دیگری $z = (x, y) \in \mathbb{R}^2$ وجود نداشته باشد که:

۱. بر همه اهداف غالب باشد: $f_i(z) \leq f_i(z^*)$ برای تمام $i \in \{1, 2\}$

۲. حداقل بر روی یک هدف برتری مطلق داشته باشد: $f_j(z) < f_j(z^*)$ برای حداقل یک $j \in \{1, 2\}$.

به عبارت دیگر، در یک نقطه پارتو، نمی‌توانیم هیچ یک از اهداف را بدون بدتر شدن حداقل یک هدف دیگر، بهبود بخشیم.

۲.۴ روش اسکالارسازی مجموع وزن‌دار (Weighted-Sum Scalarization)

در این روش، اهداف با استفاده از پارامتر وزن $w \in [0, 1]$ به یک هدف واحد F_w تبدیل می‌شوند.

$$F_w(x, y) = wf_1(x, y) + (1 - w)f_2(x, y)$$

با جایگذاری توابع هدف:

$$F_w(x, y) = w[(x - 2)^2 + y^2] + (1 - w)[x^2 + (y - 3)^2]$$

برای یافتن نقطه $(x(w), y(w))$ مینیمم کننده، باید مشتقات جزئی $\nabla F_w(x, y)$ را نسبت به x و y محاسبه کرده و برابر صفر قرار دهیم (شرط لازم مرتبه اول).
مشتق جزئی نسبت به x :

$$\frac{\partial F_w}{\partial x} = w[2(x - 2)] + (1 - w)[2x]$$

با صفر قرار دادن و ساده سازی:

$$2wx - 4w + 2x - 2wx = 0$$

$$2x - 4w = 0 \implies x(w) = 2w$$

مشتق جزئی نسبت به y :

$$\frac{\partial F_w}{\partial y} = w[2y] + (1 - w)[2(y - 3)]$$

با صفر قرار دادن و ساده سازی:

$$2wy + 2y - 6(1 - w) - 2wy = 0$$

$$2y - 6(1 - w) = 0 \implies y(w) = 3(1 - w)$$

$$(x(w), y(w)) = (2w, 3(1 - w))$$

نشان دادن اینکه این نقاط مجموعه پارتو را می سازند

در بهینه سازی چندهدفه، اگر اهداف f_i محدب باشند، هر حل بهینه از روش مجموع وزن دار (با $w > 0$ و $1 - w > 0$) یک نقطه پارتو است.

● **محدب بودن کامل:** توابع هدف f_1 و f_2 هر دو توابع درجه دوم هستند و ماتریس هسیان هر یک از آن ها $H = \text{diag}(2, 2)$ است که مثبت معین (Positive Definite) است. بنابراین، f_1 و f_2 و در نتیجه F_w ، کاملاً محدب هستند.

● **پوشش کامل:** برای مسائل محدب (مانند این مسئله)، روش مجموع وزن دار تضمین

می‌کند که با تغییر دادن w در بازه $[0, 1]$ ، تمام نقاط روی مرز محدب مجموعه پارتو به دست می‌آید.

بنابراین، مسیر تولید شده توسط $(x(w), y(w))$ به ازای $w \in [0, 1]$ ، دقیقاً مجموعه پارتو را در فضای تصمیم (Decision Space) ترسیم می‌کند.

۳.۴ بیان پارامتری جبهه پارتو (Pareto Front)

جبهه پارتو P ، تصویر نقاط بهینه پارتو (مجموعه پارتو)، $(x(w), y(w))$ در فضای اهداف است. هر نقطه روی جبهه پارتو نشان دهنده بهترین مصالحه ممکن بین f_1 و f_2 است.

بیان پارامتری با جایگذاری $x(w) = 2w$ و $y(w) = 3(1 - w)$ در f_1 و f_2 :
 ۱. برای $u = f_1$: برای یافتن مقدار هدف اول (که آن را u می‌نامیم)، $x(w)$ و $y(w)$ را در f_1 جایگذاری می‌کنیم.

$$u = f_1(w) = (x(w) - 2)^2 + y(w)^2$$

جایگذاری:

$$u = (2w - 2)^2 + (3(1 - w))^2$$

ساده‌سازی جمله اول:

$$(2w - 2)^2 = [2(w - 1)]^2 = 4(w - 1)^2$$

ساده‌سازی جمله دوم:

$$(3(1 - w))^2 = 9(1 - w)^2$$

جمع بندی:

$$u = 4(w - 1)^2 + 9(1 - w)^2$$

از آنجا که $(w - 1)^2 = (1 - w)^2$ است، می‌توانیم فاکتور بگیریم:

$$u = 13(1 - w)^2$$

این معادله نشان می‌دهد که هرچه w به ۱ نزدیک شود (اهمیت f_1 افزایش یابد)، u به ۰ نزدیک

می شود (مینیم f_1).

۲. برای $v = f_2$: به طور مشابه، برای یافتن مقدار هدف دوم (v) ، $x(w)$ و $y(w)$ را در f_2 جایگذاری می کنیم.

$$v = f_2(w) = x(w)^2 + (y(w) - 3)^2$$

جایگذاری:

$$v = (2w)^2 + (3(1 - w) - 3)^2$$

ساده سازی پرانتز داخلی:

$$3(1 - w) - 3 = 3 - 3w - 3 = -3w$$

ساده سازی نهایی:

$$v = (2w)^2 + (-3w)^2$$

$$v = 4w^2 + 9w^2$$

$$v = 13w^2$$

این معادله نشان می دهد که هرچه w به $\bullet$ نزدیک شود (اهمیت f_2 افزایش یابد)، v به $\bullet$ نزدیک می شود (مینیم f_2).

نتیجه گیری نهایی (بیان پارامتری) مجموعه P از تمام زوج های (u, v) که توسط پارامتر $w \in [0, 1]$ تولید می شوند، تشکیل شده است:

$$P = \{(13(1 - w)^2, 13w^2) : w \in [0, 1]\}$$

رابطه بسته (Closed Relation) بین $u = f_1$ و $v = f_2$ هدف از این بخش، حذف پارامتر w از معادلات پارامتری است تا یک رابطه مستقیم و بسته (Closed Relation) بین مقادیر هدف f_1 و f_2 (یعنی u و v) به دست آید. این رابطه، شکل هندسی جبهه پارتو را در فضای هدف مشخص می کند.

برای حذف پارامتر w ، ابتدا از هر دو رابطه ریشه دوم می گیریم. این کار عبارات $(1 - w)$ و

w را ایزوله می‌کند. از معادله u :

$$\sqrt{u} = \sqrt{13(1-w)^2} = \sqrt{13}\sqrt{(1-w)^2}$$

$$\sqrt{u} = \sqrt{13}|1-w|$$

از آنجایی که $w \in [0, 1]$ است، $(1-w)$ همیشه نامنفی است، پس:

$$\sqrt{u} = \sqrt{13}(1-w)$$

از معادله v :

$$\sqrt{v} = \sqrt{13w^2} = \sqrt{13}\sqrt{w^2}$$

$$\sqrt{v} = \sqrt{13}|w|$$

از آنجایی که $w \geq 0$ است،

$$\sqrt{v} = \sqrt{13}w$$

کلید حذف w در این است که اگر دو رابطه نهایی را با هم جمع کنیم، پارامتر w به طور خودکار حذف می‌شود:

$$\sqrt{u} + \sqrt{v} = \sqrt{13}(1-w) + \sqrt{13}w$$

با فاکتورگیری از $\sqrt{13}$:

$$\sqrt{u} + \sqrt{v} = \sqrt{13}[\underbrace{(1-w+w)}_{\text{حذف می‌شود}}]$$

$$\sqrt{u} + \sqrt{v} = \sqrt{13}$$

این معادله، یک رابطه مستقیم بین مقادیر هدف f_1 و f_2 است که بدون نیاز به پارامتر w ،
هندس جبهه پارتو را مشخص می‌کند:

$$\sqrt{f_1} + \sqrt{f_2} = \sqrt{13}$$

این رابطه نشان می‌دهد که جبهه پارتو در فضای هدف، یک منحنی محدب است که از نقاط بحرانی $(\sqrt{13}, 0)$ و $(0, \sqrt{13})$ عبور می‌کند.

۴.۴ قید ϵ و رابطه با w (Epsilon-Constraint and KKT)

روش قید ϵ (اولویت‌بندی با محدودیت) هدف: در این روش، ما یک هدف (مثلاً f_1) را به عنوان هدف اصلی انتخاب کرده و آن را کمینه می‌کنیم، در حالی که مطمئن می‌شویم هدف دیگر (f_2) از یک آستانه قابل قبول t تجاوز نمی‌کند: $f_2 \leq t$ s.t. $\min f_1$. لاگرانژین: برای تبدیل این مسئله قیددار به یک مسئله بدون قید (که با مشتق قابل حل باشد)، از تابع لاگرانژ استفاده می‌کنیم. ضریب λ (ضرب‌کننده لاگرانژ) به قید افزوده می‌شود:

$$L(x, y, \lambda) = f_1(x, y) + \lambda(f_2(x, y) - t)$$

نقش λ (قیمت مبادله): در شرایط KKT، λ نشان‌دهنده "قیمت سایه" قید است. به عبارت دیگر، مقدار بهبود (f_1 به ازای یک واحد شل شدن (افزایش) قید t را نشان می‌دهد. در مسائل چندهدفه، λ نرخ مبادله (Trade-off Rate) بین f_1 و f_2 در نقطه بهینه است. شرط ایستایی KKT (شرط لازم بهینگی) شرط ایستایی بیان می‌کند که در نقطه بهینه، گرادیان (شیب) هدف اصلی باید دقیقاً توسط گرادیان قید خنثی شود. این شرط مستلزم آن است که گرادیان لاگرانژین صفر باشد:

$$\nabla f_1 + \lambda \nabla f_2 = 0 \quad (*)$$

این معادله بیان می‌کند که بردار گرادیان ∇f_1 باید در جهت مخالف ∇f_2 باشد و نسبت اندازه آن‌ها برابر با λ باشد. یعنی: $\nabla f_1 = -\lambda \nabla f_2$. اثبات هم‌ارزی با روش مجموع وزن‌دار روش مجموع وزن‌دار $F_w = w f_1 + (1 - w) f_2$ را مینیمم می‌کند. شرط ایستایی آن نیز باید صفر باشد:

$$\nabla F_w = w \nabla f_1 + (1 - w) \nabla f_2 = 0$$

با تقسیم کل معادله بر w (با فرض $w \neq 0$) به رابطه زیر می‌رسیم:

$$\nabla f_1 + \frac{1-w}{w} \nabla f_2 = 0 \quad (**)$$

مقایسه نهایی: با مقایسه معادله KKT (*) و معادله مجموع وزن‌دار (**)، که هر دو در نقطه بهینه برقرار هستند، نتیجه می‌شود که:

$$\lambda = \frac{1-w}{w}$$

این رابطه نشان می‌دهد که هر نقطه پارتو که توسط روش قید ϵ با نرخ مبادله λ به دست آمده است، دقیقاً همان نقطه‌ای است که توسط روش مجموع وزن‌دار با وزن $w = \frac{1}{1+\lambda}$ (یا $w = \frac{1}{\lambda+1}$) کمینه می‌شود.

۵.۴ محاسبات برای مقادیر w

هدف ما این است که با انتخاب پنج مقدار نماینده برای وزن (w) ، ببینیم که این تغییر وزن چگونه بر تصمیم بهینه (x, y) و در نهایت بر مقادیر هدف (f_1, f_2) تأثیر می‌گذارد. این نقاط، مرز مصالحه بین دو هدف را مشخص می‌کنند.

محاسبات بر اساس روابط زیر که در بخش‌های قبلی مشتق شدند، انجام می‌شوند و نشان می‌دهند که چگونه w همزمان بر x, y (فضای تصمیم) و f_1, f_2 (فضای هدف) تأثیر می‌گذارد: متغیرهای تصمیم (Decision Variables): $x(w) = 2w$ و $y(w) = 3(1-w)$ اهداف (Objective Values):

$$f_2(w) = 13w^2 \text{ و } f_1(w) = 13(1-w)^2$$

جدول محاسبات (گرد شده تا ۴ رقم اعشار):

$f_2 = v$	$f_1 = u$	$y(w)$	$x(w)$	w
۰۰۰۰.۰	۰۰۰۰.۱۳	۰۰۰۰.۳	۰۰۰۰.۰	۰
۸۱۲۵.۰	۳۱۲۵.۷	۲۵۰۰.۲	۵۰۰۰.۰	۲۵.۰
۲۵۰۰.۳	۲۵۰۰.۳	۵۰۰۰.۱	۰۰۰۰.۱	۵.۰
۳۱۲۵.۷	۸۱۲۵.۰	۷۵۰۰.۰	۵۰۰۰.۱	۷۵.۰
۰۰۰۰.۱۳	۰۰۰۰.۰	۰۰۰۰.۰	۰۰۰۰.۲	۱

این محاسبات نشان می‌دهند که هر نقطه‌ای روی جبهه پارتو، یک مبادله (Trade-off) بین

دو هدف است: مسیر مصالحه: حرکت از $w = 0$ به $w = 1$ (افزایش اهمیت f_1) نشان‌دهنده مسیری است که در آن بهبود در f_1 (کاهش از ۱۳ به ۰) همواره به قیمت بدتر شدن f_2 (افزایش از ۰ به ۱۳) تمام می‌شود و بالعکس. تأیید رابطه بسته: این مقادیر از رابطه بسته $\sqrt{f_1} + \sqrt{f_2} = \sqrt{13}$ (که تقریباً برابر با ۳.۶۰۵۶) پیروی می‌کنند. به عنوان مثال، برای $w = 0.25$: $\sqrt{7.3125} + \sqrt{0.8125} \approx 2.7041 + 0.9014 = 3.6055$.

پرسش ۷ - روش‌های گرادیان کاهشی

مقایسه‌ای بین دو روش بنیادی در بهینه‌سازی مدل‌های یادگیری ماشین، یعنی گرادیان کاهشی دسته‌ای BGD - Batch Gradient Descent و گرادیان کاهشی تصادفی Stochastic Gradient Descent داریم. تفاوت اصلی در نحوه محاسبه گرادیان تابع هزینه $(\nabla J(\theta))$ است. فرمول اصلی به‌روزرسانی پارامترها (θ) در هر دو روش یکسان است:

$$\theta_{\text{new}} = \theta_{\text{old}} - \alpha \nabla J(\theta)$$

۱.۵ (الف) بار محاسباتی به ازای هر تکرار (Computational Load per Iteration)

Descent Gradient Batch: در هر تکرار، BGD باید مجموع میانگین گرادیان‌ها را روی کل N نمونه آموزشی محاسبه کند:

$$\nabla J_B(\theta) = \frac{1}{N} \sum_{i=1}^N \nabla J_i(\theta)$$

محاسبات شامل پردازش تمام داده‌ها در هر مرحله است. بنابراین، بار محاسباتی در هر تکرار بسیار بالا است و به طور خطی با اندازه مجموعه داده $(O(N))$ افزایش می‌یابد.

Descent Gradient Stochastic: مرحله: در هر تکرار، SGD فقط گرادیان را برای یک نمونه آموزشی تصادفی i محاسبه می‌کند:

$$\nabla J_S(\theta) = \nabla J_i(\theta)$$

محاسبات شامل پردازش فقط یک نقطه داده است. بنابراین، بار محاسباتی در هر تکرار بسیار پایین و ثابت است $(O(1))$ و به اندازه کل مجموعه داده بستگی ندارد.

۲.۵ (ب) نویز (واریانس) در تخمین گرادیان

نویز گرادیان به میزان انحراف گرادیان تخمینی از گرادیان واقعی (گرادیان محاسبه شده بر روی کل جمعیت داده) اشاره دارد.

Descent Gradient Batch: از آنجایی که گرادیان بر اساس میانگین‌گیری روی کل N نمونه محاسبه می‌شود، گرادیان تخمینی $\nabla J_B(\theta)$ یک تخمین بسیار دقیق از گرادیان واقعی است.

نتیجه: نویز (واریانس) در تخمین گرادیان بسیار پایین است. جهت به‌روزرسانی پارامترها در هر تکرار، یک مسیر بسیار مطمئن به سمت مینیمم را نشان می‌دهد.

Descent Gradient Stochastic: گرادیان فقط بر اساس یک نمونه تکی $\nabla J_i(\theta)$ محاسبه می‌شود که می‌تواند نماینده خوبی از کل داده‌ها نباشد (به خصوص اگر آن نمونه یک داده پرت باشد).

نتیجه: نویز (واریانس) در تخمین گرادیان بسیار بالا است. این نویز باعث می‌شود که به‌روزرسانی پارامترها در هر تکرار نامنظم و پرنوسان باشد.

۳.۵ (ج) پایداری و ماهیت همگرایی به مینیمم

ماهیت همگرایی به چگونگی حرکت الگوریتم در فضای پارامترها برای رسیدن به مینیمم تابع هزینه اشاره دارد.

(BGD): Descent Gradient Batch

پایداری: بسیار پایدار و قابل پیش‌بینی. مسیر حرکت در فضای پارامتر بسیار هموار است زیرا هر قدم در جهت دقیق کاهش هزینه است.
ماهیت همگرایی:

همگرایی: BGD مستقیماً به سمت مینیمم محلی (یا مینیمم سراسری) همگرا می‌شود و در نهایت به طور دقیق در مینیمم متوقف می‌شود (به شرط نرخ یادگیری مناسب).

مشکل: در توابع هزینه غیرمحدب (که در یادگیری عمیق رایج هستند)، این همواری یک عیب است، زیرا BGD مستعد گیر کردن در مینیمم‌های محلی کم‌عمق است و به سختی از آن‌ها خارج می‌شود.

(SGD): Descent Gradient Stochastic

پایداری: کمتر پایدار؛ مسیر حرکت در فضای پارامتر نویزی و پرنوسان است.
ماهیت همگرایی:

همگرایی: به دلیل نویز زیاد، SGD تمایل دارد در اطراف مینیمم محلی نوسان کند و هرگز به طور دقیق در آن متوقف نشود. برای اطمینان از همگرایی واقعی، معمولاً باید از یک نرخ یادگیری کاهشی استفاده شود.

مزیت: در توابع هزینه غیرمحدب، نویز گرادیان (واریانس بالا) یک مزیت بزرگ است: این نوسانات و حرکت تصادفی به الگوریتم کمک می‌کند تا از مینیمم‌های محلی کم‌عمق و نقاط زینی فرار کند و به سمت مینیمم‌های عمیق‌تر و بهتر حرکت کند.

خلاصه: BGD برای دقت بالا و مسیر هموار طراحی شده است اما در داده‌های بزرگ کند است. SGD برای سرعت و مقیاس‌پذیری طراحی شده و نویز آن به یافتن مینیمم‌های بهتر در توابع غیرمحدب کمک می‌کند، اما همگرایی آن آشفته است. به همین دلیل، Mini-Batch Descent Gradient (استفاده از دسته‌های کوچک ۳۲ تا ۵۱۲ تایی) به عنوان یک تعادل بهینه، رایج‌ترین روش در عمل است.

پرسش ۸: جهت تندترین کاهش از طریق تیلور مرتبه اول

این پرسش یک اثبات بنیادین در زمینه بهینه‌سازی است که نشان می‌دهد چرا در الگوریتم‌های گرادیان کاهشی (Gradient Descent)، جهت حرکت، همواره مخالف جهت گرادیان است. این جهت، تندترین مسیر کاهش (Steepest Descent Direction) نامیده می‌شود. هدف ما این است که با انتخاب یک جهت $\mathbf{p}$ واحد ($\|\mathbf{p}\| = 1$)، بیشترین کاهش ممکن در مقدار تابع $f(\mathbf{x})$ را در همسایگی محلی $\mathbf{x}_k$ به دست آوریم. تقریب تیلور مرتبه اول با فرض یک گام کوچک $\alpha > 0$ در جهت $\mathbf{p}$ ، مقدار تابع در نقطه جدید $\mathbf{x}_k + \alpha\mathbf{p}$ با استفاده از تقریب تیلور مرتبه اول تخمین زده می‌شود:

$$f(\mathbf{x}_k + \alpha\mathbf{p}) \approx f(\mathbf{x}_k) + \nabla f(\mathbf{x}_k)^T (\alpha\mathbf{p})$$

فرمول تغییر تابع برای یافتن جهت تندترین کاهش، باید جهت $\mathbf{p}$ را طوری انتخاب کنیم که تغییر در تابع (Δf) کمینه شود:

$$\Delta f = f(\mathbf{x}_k + \alpha\mathbf{p}) - f(\mathbf{x}_k) \approx \alpha \nabla f(\mathbf{x}_k)^T \mathbf{p}$$

از آنجایی که $f(\mathbf{x}_k)$ ثابت است و $\alpha > 0$ است، کمینه کردن $f(\mathbf{x}_k + \alpha\mathbf{p})$ معادل کمینه کردن عبارت $\nabla f(\mathbf{x}_k)^T \mathbf{p}$ است.

اعمال نامساوی کوشی-شوارتز عبارت ضرب داخلی را بر حسب زاویه (θ) بین بردار گرادیان $\nabla f(\mathbf{x}_k)$ و جهت $\mathbf{p}$ بازنویسی می‌کنیم:

$$\nabla f(\mathbf{x}_k)^T \mathbf{p} = \|\nabla f(\mathbf{x}_k)\| \cdot \|\mathbf{p}\| \cdot \cos(\theta)$$

یافتن مینیمم با توجه به شرایط:

• $\|\nabla f(\mathbf{x}_k)\|$ ثابت است.

• $\|p\| = 1$ (بردار واحد است).

برای کمینه کردن عبارت، باید $\cos(\theta)$ را کمینه کنیم. کمترین مقدار $\cos(\theta)$ برابر با -1 است. نتیجه‌گیری حالت $\cos(\theta) = -1$ زمانی رخ می‌دهد که زاویه بین دو بردار $\theta = 180^\circ$ باشد. این بدان معنی است که جهت p باید دقیقاً در جهت مخالف گرادیان باشد:

$$p_k \propto -\nabla f(x_k)$$

بنابراین، $p_k = -\nabla f(x_k)$ تندترین مسیر کاهش در همسایگی محلی x_k است.

پرسش ۹ - اثبات کمینه‌سازی حداقل مربعات توسط راه حل شبه معکوس

راه حل شبه معکوس (Pseudoinverse Solution)، که با نماد $A^\dagger$ نمایش داده می‌شود، تعمیمی از مفهوم ماتریس معکوس (A^{-1}) است که برای ماتریس‌های غیر مربعی (مانند $A \in \mathbb{R}^{m \times n}$ که $m \neq n$) یا ماتریس‌های مربعی که معکوس پذیر نیستند (Singular)، تعریف می‌شود. فرمول شبه معکوس ($A^\dagger$) در حالتی که ماتریس A دارای رتبه ستونی کامل (Full Column Rank) است، شبه معکوس سمت چپ (Left Pseudoinverse) آن به شکل زیر تعریف می‌شود:

$$A^\dagger = (A^T A)^{-1} A^T$$

نتیجه نهایی اثبات این خواهد بود که $x^* = A^\dagger b$. استخراج کمینه‌ساز از طریق گرادیان (شرط بهینگی مرتبه اول) هدف این است که x را طوری پیدا کنیم که تابع هزینه $L(x) = \|Ax - b\|_2^2$ کمینه شود. *الف) بسط تابع هدف را با استفاده از ضرب داخلی بازنویسی می‌کنیم:

$$L(x) = (Ax - b)^T (Ax - b)$$

با بسط دادن، تابع به شکل زیر در می‌آید:

$$L(x) = x^T A^T A x - 2b^T A x + b^T b$$

ب) محاسبه گرادیان و معادلات نرمال برای یافتن نقطه ایستای x^* ، گرادیان $\nabla_x L(x)$ را نسبت به x محاسبه کرده و آن را برابر با صفر قرار می‌دهیم:

$$\nabla_x L(x) = 2A^T A x - 2A^T b$$

با قرار دادن $\nabla_x L(\mathbf{x}) = 0$:

$$2\mathbf{A}^T \mathbf{A} \mathbf{x}^* - 2\mathbf{A}^T \mathbf{b} = 0$$

$$\mathbf{A}^T \mathbf{A} \mathbf{x}^* = \mathbf{A}^T \mathbf{b} \quad (\text{معادلات نرمال})$$

ج) استخراج راه حل $\mathbf{x}^*$ با معکوس کردن $\mathbf{A}^T \mathbf{A}$ (که به دلیل رتبه ستونی کامل $\mathbf{A}$ معکوس پذیر است):

$$\mathbf{x}^* = (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{b}$$

این فرمول، همان راه حل شبه معکوس $\mathbf{x}^* = \mathbf{A}^\dagger \mathbf{b}$ است.

اثبات یکتایی و کمینگی سراسری (Uniqueness and Global Minimum)

برای اثبات اینکه $\mathbf{x}^*$ کمینه ساز سراسری منحصر به فرد است، باید محدب بودن اکید (Strict Convexity) تابع $L(\mathbf{x})$ را نشان دهیم.

الف) محاسبه ماتریس هسین ماتریس هسین، مشتق دوم $\nabla_x^2 L(\mathbf{x})$ است:

$$\text{Hessian} = \nabla_x^2 L(\mathbf{x}) = 2\mathbf{A}^T \mathbf{A}$$

ب) اثبات مثبت معین بودن (Positive Definite) چون $\mathbf{A}$ دارای رتبه ستونی کامل است، ماتریس $\mathbf{A}^T \mathbf{A}$ یک ماتریس مثبت معین است، زیرا برای هر بردار غیر صفر $\mathbf{z}$:

$$\mathbf{z}^T (\mathbf{A}^T \mathbf{A}) \mathbf{z} = \|\mathbf{A} \mathbf{z}\|_2^2 > 0$$

(زیرا $\mathbf{A} \mathbf{z} \neq 0$).

ج) نتیجه نهایی کمینگی سراسری چون هسین تابع $L(\mathbf{x})$ مثبت معین است، تابع $L(\mathbf{x})$ یک تابع محدب اکید است. در توابع محدب اکید، هر نقطه ایستایی (که گرادیان آن صفر است) یک **کمینه ساز سراسری منحصر به فرد** است. بنابراین، $\mathbf{x}^* = (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{b}$ تنها کمینه ساز سراسری این مسئله است.

این سؤال به مقایسه روش قدرتمند نیوتن با روش‌های شبه‌نیوتن که برای رفع محدودیت‌های محاسباتی آن ایجاد شده‌اند، می‌پردازد.

۱.۸ الف) گام نیوتن چگونه محاسبه می‌شود؟

هدف ما یافتن نقطه‌ای است که مدل درجه دوم (تقریب تیلور مرتبه دوم) در آن حداقل می‌شود. ما تابع اصلی $f(\mathbf{x})$ را در اطراف نقطه فعلی $\mathbf{x}_k$ با تقریب درجه دوم $\hat{f}(\mathbf{x})$ تقریب می‌زنیم.

$$\hat{f}(\mathbf{x}) = f(\mathbf{x}_k) + \nabla f(\mathbf{x}_k)^T (\mathbf{x} - \mathbf{x}_k) + \frac{1}{2} (\mathbf{x} - \mathbf{x}_k)^T \mathbf{H}_k (\mathbf{x} - \mathbf{x}_k)$$

ما به دنبال گام بهینه $(\mathbf{p})$ از $\mathbf{x}_k$ به $\mathbf{x}$ هستیم.

$$\mathbf{p} = \mathbf{x} - \mathbf{x}_k$$

بنابراین، $\mathbf{x} = \mathbf{x}_k + \mathbf{p}$. با جایگزین کردن این در معادله $\hat{f}(\mathbf{x})$ ، تابع جدیدی بر حسب $\mathbf{p}$ به دست می‌آوریم که باید آن را مینیمم کنیم.

$$\hat{f}(\mathbf{x}_k + \mathbf{p}) = f(\mathbf{x}_k) + \nabla f(\mathbf{x}_k)^T \mathbf{p} + \frac{1}{2} \mathbf{p}^T \mathbf{H}_k \mathbf{p}$$

برای یافتن مینیمم یک تابع، باید گرادیان آن را نسبت به متغیر مورد نظر (در اینجا $\mathbf{p}$) محاسبه کرده و آن را مساوی صفر قرار دهیم.

$$\nabla_{\mathbf{p}} \hat{f}(\mathbf{x}_k + \mathbf{p}) = \nabla_{\mathbf{p}} \left(f(\mathbf{x}_k) + \nabla f(\mathbf{x}_k)^T \mathbf{p} + \frac{1}{2} \mathbf{p}^T \mathbf{H}_k \mathbf{p} \right)$$

با مشتق‌گیری جزء به جزء:

- مشتق $f(\mathbf{x}_k)$ نسبت به $\mathbf{p}$ (که یک عدد ثابت است) برابر با 0 است.
- مشتق $\nabla f(\mathbf{x}_k)^T \mathbf{p}$ نسبت به $\mathbf{p}$ برابر با $\nabla f(\mathbf{x}_k)$ (که به اختصار $\mathbf{g}_k$ نامیده می‌شود) است.
- مشتق $\frac{1}{2} \mathbf{p}^T \mathbf{H}_k \mathbf{p}$ (که یک فرم درجه دوم است) نسبت به $\mathbf{p}$ برابر با $\mathbf{H}_k \mathbf{p}$ است (با فرض متقارن بودن $\mathbf{H}_k$).

بنابراین گرادیان تقریب درجه دوم نسبت به $\mathbf{p}$ به صورت زیر است:

$$\nabla_{\mathbf{p}} \hat{f}(\mathbf{x}_k + \mathbf{p}) = \nabla f(\mathbf{x}_k) + \mathbf{H}_k \mathbf{p}$$

برای یافتن گام بهینه $\mathbf{p}_k$ که مینیم تقریب را به دست می‌دهد، گرادیان بالا را برابر با بردار صفر قرار می‌دهیم:

$$\nabla f(\mathbf{x}_k) + \mathbf{H}_k \mathbf{p}_k = \mathbf{0}$$

با جابجایی ترم‌ها، به معادله‌ای برای $\mathbf{p}_k$ می‌رسیم:

$$\mathbf{H}_k \mathbf{p}_k = -\nabla f(\mathbf{x}_k)$$

در نهایت، با ضرب معکوس ماتریس هسین ($\mathbf{H}_k^{-1}$) از سمت چپ، $\mathbf{p}_k$ (گام نیوتن) به دست می‌آید:

$$\mathbf{p}_k = -\mathbf{H}_k^{-1} \nabla f(\mathbf{x}_k)$$

این فرمول، گام نیوتن را مشخص می‌کند. این گام، تابعی از گرادیان (نیروی رانش نزول) و معکوس هسین (شکل و انحنای تابع) است.

روش نیوتن دارای نرخ همگرایی درجه دوم (Quadratic Convergence) است که فوق‌العاده سریع است.

۲.۸ ب) چه زمانی روش نیوتن در همگرا شدن به مینیم شکست می‌خورد؟

شکست در همگرایی به یک مینیم (و همگرا شدن به یک ماکسیمم یا نقطه زینی) زمانی رخ می‌دهد که ماتریس هسین ($\mathbf{H}$) مثبت معین (Positive Definite) نباشد.

- اگر الگوریتم در نقطه‌ای شروع شود که $\mathbf{H}$ مثبت معین نباشد (مثلاً در یک نقطه زینی)، تضمینی برای حرکت به سمت یک مینیمم وجود ندارد.

روش نیوتن در هر تکرار، از یک مدل درجه دوم (تقریب تیلور مرتبه دوم) برای تخمین زدن تابع در نزدیکی نقطه فعلی استفاده می‌کند. این مدل به صورت زیر است:

$$\hat{f}(\mathbf{x}) \approx f(\mathbf{x}_k) + \nabla f(\mathbf{x}_k)^T \mathbf{p} + \frac{1}{2} \mathbf{p}^T \mathbf{H}_k \mathbf{p}$$

نیوتن به سادگی نقطه‌ای را پیدا می‌کند که گرادیان این مدل تقریب‌زده شده در آن صفر باشد ($\nabla_{\mathbf{p}} \hat{f} = 0$).

۱. عدم تحدب: وقتی $\mathbf{H}$ مثبت معین (Positive Definite) نیست شرط لازم و کافی برای اینکه یک نقطه ایستایی ($\nabla f = 0$) یک مینیمم محلی باشد، این است که ماتریس هسین ($\mathbf{H}$) مثبت معین باشد ($\mathbf{H} \succ 0$). اگر $\mathbf{H}$ مثبت معین نباشد، مدل درجه دوم تقریب‌زده شده، ویژگی‌های یک کاسه رو به بالا (محدب) را از دست می‌دهد و الگوریتم دچار مشکل می‌شود:

الف) همگرایی به ماکزیمم محلی وضعیت هسین: منفی معین (Negative Definite). این بدان معناست که تابع در تمام جهات دارای انحنای منفی است (شکل یک تپه دارد). مدل درجه دوم در آن ناحیه دارای ماکزیمم است. اگر نیوتن به نقطه‌ای که در آن $\mathbf{H}$ منفی معین است، هدایت شود، به ماکزیمم محلی همگرا خواهد شد.

ب) همگرایی به نقطه زینی (Saddle Point) وضعیت هسین: نامعین (Indefinite). $\mathbf{H}$ دارای مقادیر ویژه مثبت و منفی است. این بدان معنی است که تابع در برخی جهات صعودی (مثل یک کاسه) و در برخی جهات نزولی (مثل یک تپه) است. گرادیان در این نقاط صفر است، اما آن‌ها نه مینیمم هستند و نه ماکزیمم (مثل زین اسب). روش نیوتن، که تنها به دنبال $\nabla f = 0$ است، بدون تمایز به این نقاط زینی همگرا می‌شود.

روش نیوتن فقط در صورتی همگرایی درجه دوم را تضمین می‌کند که: نزدیک به مینیمم شروع شود. $\mathbf{H}$ نزدیک مینیمم به اندازه کافی خوش رفتار (مثبت معین) باشد. اگر نقطه شروع ($\mathbf{x}_0$) خیلی دور باشد، تقریب درجه دوم ضعیف است. گام نیوتن ($\mathbf{p}_k$) ممکن است آنقدر بزرگ باشد که الگوریتم از ناحیه مینیمم دور شده و واگرا (Diverge) شود، یا به یک مینیمم محلی دیگر همگرا شود که دورتر از هدف اصلی بوده است.

۳.۸ ج) چه زمانی جهت نیوتن یک جهت کاهش (Descent Direction) نیست؟

جهت نیوتن ($\mathbf{p}_k = -\mathbf{H}(\mathbf{x}_k)^{-1} \nabla f(\mathbf{x}_k)$) در صورتی یک جهت کاهش نخواهد بود که $\mathbf{H}(\mathbf{x}_k)$ مثبت معین نباشد. اگر هسین نامعین یا منفی معین باشد، ممکن است ضرب داخلی $\mathbf{p}_k^T \nabla f(\mathbf{x}_k)$ مثبت شود و در نتیجه الگوریتم به جای پایین رفتن، به سمت بالا حرکت کند.

۴.۸ د) ایده اصلی روش‌های شبه‌نیوتن (Quasi-Newton) چیست؟

ایده اصلی شبه‌نیوتن‌ها مانند BFGS و DFP این است که از هزینه محاسباتی بالای روش نیوتن (محاسبه $O(n^2)$ مشتقات دوم و معکوس کردن $O(n^3)$ هسین) اجتناب کنند.

● هدف: جایگزینی $\mathbf{H}$ (یا معکوس آن $\mathbf{B} = \mathbf{H}^{-1}$) با یک تقریب که فقط از اطلاعات گرادیان‌های (مشتقات مرتبه اول) تکرارهای گذشته استفاده می‌کند.

۵.۸ ه) چگونه تقریب هسین را بدون مشتقات صریح انجام می‌دهند؟

روش‌های شبه‌نیوتن تقریب $\mathbf{B}_{k+1}$ را با استفاده از معادله سکانت (Secant Equation) به‌روزرسانی می‌کنند. این معادله یک محدودیت ریاضی بر تقریب اعمال می‌کند که باید رابطه بین تغییر موقعیت و تغییر گرادیان در آخرین گام را حفظ کند:

$$\mathbf{B}_{k+1} \mathbf{y}_k = \mathbf{s}_k$$

● $\mathbf{s}_k = \mathbf{x}_{k+1} - \mathbf{x}_k$ (تغییر موقعیت).

● $\mathbf{y}_k = \nabla f(\mathbf{x}_{k+1}) - \nabla f(\mathbf{x}_k)$ (تغییر گرادیان).

توضیح: $\mathbf{B}_{k+1}$ به صورت تکراری و با استفاده از به‌روزرسانی‌های رتبه یک یا دو تصحیح می‌شود و به یک همگرایی فوق‌خطی (Superlinear Convergence) با هزینه محاسباتی بسیار پایین‌تر $O(n^2)$ در هر تکرار دست می‌یابد.

پرسش ۱۱ - همگرایی درجه دوم روش نیوتن

۱.۹ الف) تعریف همگرایی درجه دوم و تفاوت آن با همگرایی خطی

همگرایی (Convergence) سرعتی است که دنباله تکراری x_k به راه‌حل نهایی x^* نزدیک می‌شود. خطا در مرحله k با $e_k = x_k - x^*$ تعریف می‌شود.

۱. همگرایی درجه دوم (Quadratic Convergence)

همگرایی درجه دوم به این معناست که خطا در هر تکرار، به صورت ****درجه دوم**** کاهش می‌یابد. این نرخ با ضریب $C \geq 0$ به صورت زیر تعریف می‌شود:

$$\lim_{k \rightarrow \infty} \frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|^2} = \lim_{k \rightarrow \infty} \frac{\|e_{k+1}\|}{\|e_k\|^2} = C$$

تفسیر: اگر خطا (نرم بردار خطا) در مرحله فعلی 0.1 باشد، خطا در تکرار بعدی تقریباً 0.01 خواهد بود. این سرعت فوق‌العاده بالاست زیرا تعداد ارقام معنی‌دار صحیح در هر مرحله تقریباً دو برابر می‌شود.

۲. همگرایی خطی (Linear Convergence)

همگرایی خطی به این معناست که خطا در هر مرحله با یک ****نسبت ثابت**** r (که باید $0 \leq r < 1$ باشد) کاهش می‌یابد:

$$\lim_{k \rightarrow \infty} \frac{\|e_{k+1}\|}{\|e_k\|} = r$$

تفسیر: خطا در هر تکرار، یک کسری ثابت از خطای قبلی است. این نرخ استاندارد همگرایی برای روش‌های مرتبه اول مانند گرادیان کاهش است.

تضاد اصلی بین همگرایی خطی (Linear Convergence) و همگرایی درجه دوم (Quadratic Convergence) در نرخ کاهش خطا در هر تکرار نهفته است: در همگرایی خطی، خطا ($\|e_{k+1}\|$)

با یک نسبت ثابت ($r < 1$) از خطای قبلی ($\|e_k\|$) کاهش می‌یابد ($\|e_{k+1}\| \propto \|e_k\|$)؛ به عبارت دیگر، دقت حل در هر مرحله به طور ثابت افزایش می‌یابد. در مقابل، همگرایی درجه دوم، که ویژگی بارز روش نیوتن است، به این معنی است که خطا متناسب با توان دوم خطای قبلی کاهش می‌یابد ($\|e_{k+1}\| \propto \|e_k\|^2$)؛ این یعنی اگر خطا 0.1 باشد، در مرحله بعد به 0.01 کاهش می‌یابد و اگر 0.01 شود، در مرحله بعد به 0.0001 می‌رسد، در نتیجه، تعداد ارقام معنی‌دار صحیح در هر تکرار تقریباً دو برابر می‌شود. بنابراین، همگرایی خطی به دلیل نرخ ثابت، کندتر اما معمولاً پایدارتر است (مانند گرادیان کاهشی)، در حالی که همگرایی درجه دوم، فوق‌العاده سریع است اما تنها زمانی تضمین می‌شود که الگوریتم به اندازه کافی به مینیم محلی نزدیک شده باشد.

۲.۹ ب) اثبات تقریب گام نیوتن با جابجایی دقیق ($x^* - x_k$)

هدف این است که نشان دهیم اگر x_k به اندازه کافی نزدیک به مینیم محلی x^* باشد، گام نیوتن (p_k) تخمینی تقریباً کامل از جابجایی دقیق مورد نیاز ($x^* - x_k$) است. شرط مینیم و بسط تیلور راه‌حل x^* یک نقطه ایستایی است، بنابراین شرط مرتبه اول را ارضا می‌کند:

$$\nabla f(x^*) = 0$$

گرادیان $\nabla f(x^*)$ را در اطراف نقطه فعلی x_k با استفاده از بسط تیلور مرتبه اول بسط می‌دهیم:

$$\nabla f(x^*) \approx \nabla f(x_k) + H(x_k)(x^* - x_k)$$

حل برای جابجایی دقیق با جایگزینی $\nabla f(x^*) = 0$:

$$0 \approx \nabla f(x_k) + H_k(x^* - x_k)$$

با حل این معادله برای $x^* - x_k$ (جابجایی دقیق):

$$H_k(x^* - x_k) \approx -\nabla f(x_k)$$

با ضرب معکوس هسین ($\mathbf{H}_k^{-1}$) از سمت چپ (با فرض معکوس پذیر بودن $\mathbf{H}_k$):

$$\mathbf{x}^* - \mathbf{x}_k \approx -\mathbf{H}_k^{-1} \nabla f(\mathbf{x}_k) \quad (1)$$

نتیجه گیری نهایی گام نیوتن ($\mathbf{p}_k$) به صورت زیر تعریف شده است:

$$\mathbf{p}_k = -\mathbf{H}_k^{-1} \nabla f(\mathbf{x}_k) \quad (2)$$

از مقایسه روابط (1) و (2) نتیجه می گیریم:

$$\mathbf{p}_k \approx \mathbf{x}^* - \mathbf{x}_k$$

تفسیر: گام نیوتن در نزدیکی مینیمم، تخمینی دقیق از فاصله و جهت مورد نیاز برای رسیدن به $\mathbf{x}^*$ ارائه می دهد. این دقت بالا، دلیل اصلی همگرایی درجه دوم آن است.

پرسش ۱۳ - بهینه‌سازی مقید به تساوی از طریق لاگرانژ و نیوتن - رافسون

مسئله:

$$\min_{x,y} f(x,y) = e^{x^2+y^2} \quad \text{s.t.} \quad g(x,y) = x + y - 1 = 0$$

۱.۱۰ الف) نوشتن لاگرانژین $\mathcal{L}(x, y, \lambda)$

تابع لاگرانژین (Lagrangian) برای این مسئله به صورت زیر است:

$$\mathcal{L}(x, y, \lambda) = f(x, y) + \lambda g(x, y)$$

$$\mathcal{L}(x, y, \lambda) = e^{x^2+y^2} + \lambda(x + y - 1)$$

۲.۱۰ ب) یافتن نقطه بهینه (x^*, y^*, λ^*) با حل $\nabla_{x,y,\lambda} \mathcal{L} = 0$

شرایط لازم برای بهینگی (KKT Conditions) با صفر قرار دادن مشتقات جزئی لاگرانژین به دست می‌آید:

$$\frac{\partial \mathcal{L}}{\partial x} = 2xe^{x^2+y^2} + \lambda = 0 \quad (\text{Eq.1})$$

$$\frac{\partial \mathcal{L}}{\partial y} = 2ye^{x^2+y^2} + \lambda = 0 \quad (\text{Eq.2})$$

$$\frac{\partial \mathcal{L}}{\partial \lambda} = x + y - 1 = 0 \quad (\text{Eq.3})$$

حل تحلیلی:

- از (۱) و (۲): دو عبارت برابر با $-\lambda$ هستند، پس $2xe^{x^2+y^2} = 2ye^{x^2+y^2}$. از آنجایی که $e^{x^2+y^2} > 0$ است، نتیجه می‌شود:

$$2x = 2y \Rightarrow x = y$$

- جایگذاری در (۳): با جایگذاری $x = y$ در قید:

$$x + x - 1 = 0 \Rightarrow 2x = 1 \Rightarrow x^* = 1/2, \quad y^* = 1/2$$

- یافتن λ^* : با جایگذاری x^* و y^* در (۱):

$$\lambda^* = -2x^*e^{(x^*)^2+(y^*)^2} = -2\left(\frac{1}{2}\right)e^{1/4+1/4} = -e^{1/2}$$

نقطه بهینه تحلیلی:

$$(x^*, y^*, \lambda^*) = \left(\frac{1}{2}, \frac{1}{2}, -e^{1/2}\right)$$

۳.۱۰ ج) سیستم غیرخطی $F(\mathbf{w}) = 0$

سیستم غیرخطی $F(\mathbf{w}) = 0$ همان سه معادله شرایط KKT است که در آن بردار متغیرها $\mathbf{w} = [x, y, \lambda]^T$ تعریف می‌شود:

$$\mathbf{F}(\mathbf{w}) = \begin{bmatrix} F_1(\mathbf{w}) \\ F_2(\mathbf{w}) \\ F_3(\mathbf{w}) \end{bmatrix} = \begin{bmatrix} 2xe^{x^2+y^2} + \lambda \\ 2ye^{x^2+y^2} + \lambda \\ x + y - 1 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

۴.۱۰ (د) اعمال نیوتن-رافسون و محاسبه ژاکوبین $\mathbf{J}_F(\mathbf{w})$

فرمول تکراری نیوتن-رافسون (Newton-Raphson) برای حل $\mathbf{F}(\mathbf{w}) = 0$ به صورت زیر است:

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \mathbf{J}_F(\mathbf{w}_k)^{-1} \mathbf{F}(\mathbf{w}_k)$$

ماتریس ژاکوبین $\mathbf{J}_F(\mathbf{w})$ ، ماتریس مشتقات جزئی $\mathbf{F}(\mathbf{w})$ نسبت به $\mathbf{w}$ است:

$$\mathbf{J}_F(x, y, \lambda) = \begin{bmatrix} \frac{\partial F_1}{\partial x} & \frac{\partial F_1}{\partial y} & \frac{\partial F_1}{\partial \lambda} \\ \frac{\partial F_2}{\partial x} & \frac{\partial F_2}{\partial y} & \frac{\partial F_2}{\partial \lambda} \\ \frac{\partial F_3}{\partial x} & \frac{\partial F_3}{\partial y} & \frac{\partial F_3}{\partial \lambda} \end{bmatrix}$$

محاسبات مشتقات:

$$\frac{\partial F_1}{\partial x} = 2e^{x^2+y^2} + 2x(2xe^{x^2+y^2}) = 2e^{x^2+y^2}(1 + 2x^2) \bullet$$

$$\frac{\partial F_1}{\partial y} = 2x(2ye^{x^2+y^2}) = 4xye^{x^2+y^2} \bullet$$

$$\frac{\partial F_1}{\partial \lambda} = 1 \bullet$$

$$\frac{\partial F_2}{\partial x} = 2y(2xe^{x^2+y^2}) = 4xye^{x^2+y^2} \bullet$$

$$\frac{\partial F_2}{\partial y} = 2e^{x^2+y^2} + 2y(2ye^{x^2+y^2}) = 2e^{x^2+y^2}(1 + 2y^2) \bullet$$

$$\frac{\partial F_2}{\partial \lambda} = 1 \bullet$$

$$\frac{\partial F_3}{\partial \lambda} = 0, \frac{\partial F_3}{\partial y} = 1, \frac{\partial F_3}{\partial x} = 1 \bullet$$

ماتریس ژاکوبین $\mathbf{J}_F(\mathbf{w})$:

$$\mathbf{J}_F(x, y, \lambda) = \begin{bmatrix} 2e^{x^2+y^2}(1 + 2x^2) & 4xye^{x^2+y^2} & 1 \\ 4xye^{x^2+y^2} & 2e^{x^2+y^2}(1 + 2y^2) & 1 \\ 1 & 1 & 0 \end{bmatrix}$$

۵.۱۰ (ه) پیاده‌سازی و نمایش همگرایی

نقطه شروع: $\mathbf{w}_0 = [0, 0, 0]^T$.

۱. محاسبه $\mathbf{F}(\mathbf{w}_0)$:

$$\mathbf{F}(\mathbf{w}_0) = \begin{bmatrix} 2(0)e^0 + 0 \\ 2(0)e^0 + 0 \\ 0 + 0 - 1 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ -1 \end{bmatrix}$$

۲. محاسبه $\mathbf{J}_F(\mathbf{w}_0)$:

$$\mathbf{J}_F(\mathbf{w}_0) = \begin{bmatrix} 2e^0(1+0) & 0 & 1 \\ 0 & 2e^0(1+0) & 1 \\ 1 & 1 & 0 \end{bmatrix} = \begin{bmatrix} 2 & 0 & 1 \\ 0 & 2 & 1 \\ 1 & 1 & 0 \end{bmatrix}$$

۳. محاسبه گام اول $\mathbf{w}_1$:

$$\mathbf{w}_1 = \mathbf{w}_0 - \mathbf{J}_F(\mathbf{w}_0)^{-1} \mathbf{F}(\mathbf{w}_0)$$

پس از حل سیستم خطی $\mathbf{J}_F(\mathbf{w}_0)\mathbf{p}_0 = -\mathbf{F}(\mathbf{w}_0)$ که $\mathbf{p}_0 = \mathbf{w}_1 - \mathbf{w}_0$ است، به دست می‌آید:

$$\mathbf{p}_0 = \begin{bmatrix} 1/2 \\ 1/2 \\ 1 \end{bmatrix}$$

$$\mathbf{w}_1 = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} - \begin{bmatrix} 1/2 \\ 1/2 \\ 1 \end{bmatrix} = \begin{bmatrix} -1/2 \\ -1/2 \\ -1 \end{bmatrix}$$

نتیجه گام اول: $\mathbf{w}_1 = [-0.5, -0.5, -1]^T$. این گام، به دلیل ماهیت نمایی $f(x, y)$ و

نزدیکی نقطه شروع به $[0, 0]$ ، مستقیماً به سمت راه حل $\mathbf{w}^* = [0.5, 0.5, -1.6487]$ حرکت نمی‌کند، اما به دلیل ماهیت همگرایی درجه دوم نیوتن، در تکرارهای بعدی به سرعت به آن همگرا خواهد شد.

۶.۱۰ عنوان بخش

متن نمونه

ML Model	Role In Our Life
Naïve Bayes	Makes us overconfident
Decision Tree	Makes us comfortable
SVM	Makes us question our life choices (e.g. taking this course)

جدول ۱: عنوان جدول نمونه

Model Performance on Training Data



Model Performance on Test Data



شکل ۱: عنوان تصویر نمونه

در این بخش، منابعی که در تمرینات و پیاده‌سازی استفاده کرده‌اید (مانند مقالات، سایت‌ها و ...) را در یک فرمت استاندارد فهرست کنید. برای رفرنس‌دهی می‌توانید از بخش Reference در نرم‌افزار Word، سایت‌های مخصوص یا افزونه‌های مرتبط استفاده کنید. همچنین، لازم است که هر منبع استفاده‌شده را در بخش مربوطه ارجاع دهید. توجه داشته باشید که شباهت کد یا پاسخ شما به منابع دیگر باید در حد معقول باشد؛ کپی‌برداری مستقیم از منابع، مدنظر ما نیست. در صورت مشاهده کپی کامل از یک منبع، نمره آن تمرین یا بخش مربوطه به شما تعلق نخواهد گرفت.