

دانشگاه تهران
پردیس دانشکده‌های فنی
دانشکده مهندسی برق و کامپیوتر



یادگیری ماشین

تمرین شماره ۴

نام و نام خانوادگی
پریا خلیلی

شماره دانشجویی
۸۱۰۸۰۱۰۶۵

۲۵ بهمن ۱۴۰۴

فهرست مطالب

۲	۱ پرسش ۱ - یک تکرار کامل از الگوریتم K-Means
۲	۱.۱ شرح مسئله و داده‌ها
۲	۲.۱ گام اول: تخصیص نقاط به خوشه‌ها
۴	۳.۱ گام دوم: به‌روزرسانی مراکز خوشه‌ها
۴	۴.۱ خلاصه نتایج نهایی
۵	۲ پرسش ۲ استراتژی‌های پیوند در خوشه‌بندی سلسله‌مراتبی
۵	۱.۲ مبانی خوشه‌بندی سلسله‌مراتبی تجمعی (<i>Agglomerative</i>)
۵	۲.۲ استراتژی‌های پیوند (<i>Linkage</i>)
۶	۳.۲ مقایسه پیچیدگی محاسباتی و مقاومت در برابر نقاط پرت
۶	۴.۲ خوشه‌بندی با روش Linkage Complete
۸	۳ پرسش ۳ کاهش ابعاد و هندسه داده‌ها
۸	۱.۳ ۱. داده‌های گاوسی با همبستگی خطی
۸	۲.۳ ۲. دو دایره متحدالمرکز
۹	۳.۳ ۳. داده‌های ابعاد بالا با همپوشانی شدید کلاس‌ها
۹	۴.۳ ۴. داده‌های حاوی ویژگی‌های نامرتب یا نویزی
۱۰	۴ پرسش ۴: مبانی نظری LDA و Kernel PCA
۱۰	۱.۴ ۱. محدودیت تعداد جهت‌های ممیز در LDA
۱۱	۲.۴ ۲. تحلیل Kernel PCA و استخراج معادله مقدار ویژه
۱۳	۵ پرسش ۵: محاسبات دستی LDA
۱۶	۶ پرسش ۶: انتخاب ویژگی و تحلیل الگوریتم‌های حریصانه

۱۹	۷ پرسش ۷ - تحلیل PCA و Kernel PCA روی داده‌های ساختاریافته
۲۲	۸ پرسش ۸ - انتخاب ویژگی و مصورسازی بر روی مجموعه داده واقعی
۲۷	۹ پرسش ۹ - بخش‌بندی تصاویر با استفاده از خوشه‌بندی (امتیازی)
۳۱	۱۰ مراجع

فهرست تصاویر

۱	دندروگرام کامل حاصل از خوشه‌بندی سلسله‌مراتبی با روش پیوند کامل (Com-Linkage)	۷
۲	نمودار پراکندگی داده‌های Iris در فضای دو مولفه اصلی اول	۲۰
۳	مقایسه عملکرد PCA خطی (چپ) و Kernel PCA با هسته RBF (راست)	۲۱
۴	ماتریس همبستگی ویژگی‌های دیتاست heart.csv	۲۲
۵	رتبه‌بندی ویژگی‌ها در روش RFE	۲۴
۶	دقت مدل در مقابل تعداد ویژگی‌ها (RFECV)	۲۴
۷	نمودار واریانس انباشته در تحلیل PCA	۲۵
۸	نتایج بخش‌بندی تصویر اول (image1.jpg) با دو روش K-Means و GMM	۲۸
۹	نتایج بخش‌بندی تصویر دوم (image2.jpg) با دو روش K-Means و GMM	۲۹

فهرست جداول

۱	مختصات یک بعدی نقاط پس از تصویر کردن توسط LDA	۱۵
۲	مقایسه روش های انتخاب ویژگی	۱۸

هدف از این مجموعه تمرین‌ها، بررسی عمیق مفاهیم یادگیری بدون نظارت و روش‌های استخراج و انتخاب ویژگی است. در این گزارش، ابتدا الگوریتم خوشه‌بندی K-Means به صورت محاسباتی و گام‌به‌گام تحلیل شده و سپس تفاوت‌های ساختاری روش‌های پیوند در خوشه‌بندی سلسله‌مراتبی از منظر پیچیدگی محاسباتی و حساسیت به نویز مورد بررسی قرار می‌گیرد. همچنین، مبانی نظری و ریاضیاتی تحلیل ممیز خطی (LDA) و تحلیل مؤلفه‌های اصلی (PCA) به عنوان دو ابزار کلیدی در کاهش ابعاد و جداسازی کلاس‌ها تبیین می‌گردد. در بخش‌های عملی، پیاده‌سازی خوشه‌بندی روی داده‌های تصویری با استفاده از دو رویکرد K-Means و مدل‌های مخلوط گوسی (GMM) انجام می‌شود تا تأثیر مفروضات آماری هر مدل بر کیفیت بخش‌بندی تصاویر مقایسه گردد. انتظار می‌رود نتایج حاصل، برتری روش‌های مبتنی بر بیشینه‌سازی احتمال مانند EM را در مواجهه با توزیع‌های پیچیده آماری نشان داده و اهمیت انتخاب صحیح فضای ویژگی و کاهش ابعاد در بهبود عملکرد مدل‌های یادگیری ماشین را اثبات نماید.

پرسش ۱ - یک تکرار کامل از الگوریتم K-Means

۱.۱ شرح مسئله و داده‌ها

مجموعه داده D شامل ۵ نقطه با مختصات زیر داده شده است:

$$d_1 = (5.5, 3.1) \bullet$$

$$d_2 = (5.1, 4.8) \bullet$$

$$d_3 = (6.6, 3.0) \bullet$$

$$d_4 = (5.5, 4.6) \bullet$$

$$d_5 = (6.8, 3.8) \bullet$$

مراکز خوشه‌های اولیه (*Centroids*) عبارتند از:

$$\mu_0 = (5.3, 3.5) \bullet$$

$$\mu_1 = (5.1, 4.2) \bullet$$

هدف انجام یک تکرار کامل شامل تخصیص نقاط به نزدیک‌ترین مرکز (با استفاده از فاصله اقلیدسی) و به‌روزرسانی مراکز است.

۲.۱ گام اول: تخصیص نقاط به خوشه‌ها

برای هر نقطه، مجذور فاصله اقلیدسی تا هر دو مرکز را محاسبه می‌کنیم تا از محاسبات غیرضروری رادیکال اجتناب شود. معیار تصمیم‌گیری کمینه بودن مقدار $dist^2$ است.

۱. نقطه $d_1 = (5.5, 3.1)$:

$$\begin{aligned} dist(d_1, \mu_0)^2 &= (5.5 - 5.3)^2 + (3.1 - 3.5)^2 = (0.2)^2 + (-0.4)^2 = \bullet \\ 0.04 + 0.16 &= \mathbf{0.20} \end{aligned}$$

$$\begin{aligned} dist(d_1, \mu_1)^2 &= (5.5 - 5.1)^2 + (3.1 - 4.2)^2 = (0.4)^2 + (-1.1)^2 = \bullet \\ 0.16 + 1.21 &= 1.37 \end{aligned}$$

• نتیجه: چون $0.20 < 1.37$ است، نقطه d_1 به خوشه ۰ تخصیص می‌یابد.

۲. نقطه $d_2 = (5.1, 4.8)$:

$$\begin{aligned} dist(d_2, \mu_0)^2 &= (5.1 - 5.3)^2 + (4.8 - 3.5)^2 = (-0.2)^2 + (1.3)^2 = \bullet \\ 0.04 + 1.69 &= 1.73 \end{aligned}$$

$$\begin{aligned} dist(d_2, \mu_1)^2 &= (5.1 - 5.1)^2 + (4.8 - 4.2)^2 = (0)^2 + (0.6)^2 = \bullet \\ 0 + 0.36 &= \mathbf{0.36} \end{aligned}$$

• نتیجه: چون $0.36 < 1.73$ است، نقطه d_2 به خوشه ۱ تخصیص می‌یابد.

۳. نقطه $d_3 = (6.6, 3.0)$:

$$\begin{aligned} dist(d_3, \mu_0)^2 &= (6.6 - 5.3)^2 + (3.0 - 3.5)^2 = (1.3)^2 + (-0.5)^2 = \bullet \\ 1.69 + 0.25 &= \mathbf{1.94} \end{aligned}$$

$$\begin{aligned} dist(d_3, \mu_1)^2 &= (6.6 - 5.1)^2 + (3.0 - 4.2)^2 = (1.5)^2 + (-1.2)^2 = \bullet \\ 2.25 + 1.44 &= 3.69 \end{aligned}$$

• نتیجه: چون $1.94 < 3.69$ است، نقطه d_3 به خوشه ۰ تخصیص می‌یابد.

۴. نقطه $d_4 = (5.5, 4.6)$:

$$\begin{aligned} dist(d_4, \mu_0)^2 &= (5.5 - 5.3)^2 + (4.6 - 3.5)^2 = (0.2)^2 + (1.1)^2 = \bullet \\ 0.04 + 1.21 &= 1.25 \end{aligned}$$

$$\begin{aligned} dist(d_4, \mu_1)^2 &= (5.5 - 5.1)^2 + (4.6 - 4.2)^2 = (0.4)^2 + (0.4)^2 = \bullet \\ 0.16 + 0.16 &= \mathbf{0.32} \end{aligned}$$

• نتیجه: چون $0.32 < 1.25$ است، نقطه d_4 به خوشه ۱ تخصیص می‌یابد.

۵. نقطه $d_5 = (6.8, 3.8)$:

$$\begin{aligned} dist(d_5, \mu_0)^2 &= (6.8 - 5.3)^2 + (3.8 - 3.5)^2 = (1.5)^2 + (0.3)^2 = \bullet \\ 2.25 + 0.09 &= \mathbf{2.34} \end{aligned}$$

$$\begin{aligned} dist(d_5, \mu_1)^2 &= (6.8 - 5.1)^2 + (3.8 - 4.2)^2 = (1.7)^2 + (-0.4)^2 = \bullet \\ 2.89 + 0.16 &= 3.05 \end{aligned}$$

• نتیجه: چون $2.34 < 3.05$ است، نقطه d_5 به خوشه ۰ تخصیص می‌یابد.

۳.۱ گام دوم: به‌روزرسانی مراکز خوشه‌ها

مراکز جدید از طریق میانگین‌گیری مختصات نقاط موجود در هر خوشه محاسبه می‌شوند.

مركز جديد خوشه ۰ $(\mu_0^{(new)})$: نقاط موجود: $\{d_1, d_3, d_5\}$

$$\mu_0^{(new)} = \left(\frac{5.5 + 6.6 + 6.8}{3}, \frac{3.1 + 3.0 + 3.8}{3} \right) = \left(\frac{18.9}{3}, \frac{9.9}{3} \right) = (6.3, 3.3)$$

مركز جديد خوشه ۱ $(\mu_1^{(new)})$: نقاط موجود: $\{d_2, d_4\}$

$$\mu_1^{(new)} = \left(\frac{5.1 + 5.5}{2}, \frac{4.8 + 4.6}{2} \right) = \left(\frac{10.6}{2}, \frac{9.4}{2} \right) = (5.3, 4.7)$$

۴.۱ خلاصه نتایج نهایی

• مرکز جدید خوشه ۰: $(6.3, 3.3)$

• مرکز جدید خوشه ۱: $(5.3, 4.7)$

• تعداد نقاط خوشه ۰ $(Cardinality)$: 3 نقطه

• تعداد نقاط خوشه ۱ $(Cardinality)$: 2 نقطه

پرسش ۲ استراتژی‌های پیوند در خوشه‌بندی سلسله‌مراتبی

۱.۲ مبانی خوشه‌بندی سلسله‌مراتبی تجمعی (*Agglomerative*)

خوشه‌بندی سلسله‌مراتبی پایین به بالا یا تجمعی، با در نظر گرفتن هر نقطه داده به عنوان یک خوشه مجزا آغاز می‌شود. در هر مرحله از الگوریتم، دو خوشه‌ای که کمترین فاصله (بیشترین شباهت) را با یکدیگر دارند، ادغام می‌شوند. این فرآیند تا زمانی ادامه می‌یابد که تمامی نقاط در قالب یک خوشه واحد قرار گیرند. خروجی این الگوریتم معمولاً به صورت یک ساختار درختی به نام دندروگرام (*Dendrogram*) نمایش داده می‌شود.

۲.۲ استراتژی‌های پیوند (*Linkage*)

در خوشه‌بندی تجمعی، برای تعیین فاصله بین دو خوشه (که هر کدام شامل چندین نقطه هستند)، از استراتژی‌های پیوند استفاده می‌شود. دو استراتژی اصلی عبارتند از:

● پیوند تک‌گانه :

در این روش، فاصله بین دو خوشه برابر با کمترین فاصله بین جفت نقاط آن‌ها تعریف می‌شود. این معیار تمایل دارد خوشه‌های طولانی و زنجیره‌ای ایجاد کند و نسبت به «پدیده زنجیره‌ای شدن» حساس است.

● پیوند کامل :

در این روش، فاصله بین دو خوشه برابر با بیشترین فاصله بین جفت نقاط آن‌ها تعریف می‌شود. این معیار باعث ایجاد خوشه‌های فشرده و کروی می‌شود و نسبت به نویز مقاوم‌تر است.

۳.۲ مقایسه پیچیدگی محاسباتی و مقاومت در برابر نقاط پرت


- پیچیدگی محاسباتی: هر دو روش در حالت کلی دارای پیچیدگی از مرتبه $O(n^2 \log n)$ هستند. با این حال، روش **Single Linkage** به دلیل شباهت با الگوریتم‌های درخت پوشای کمینه (MST)، می‌تواند در زمان $O(n^2)$ اجرا شود. روش **Complete Linkage** نیز در پیاده‌سازی‌های بهینه دارای مرتبه $O(n^2)$ است.

- مقاومت در برابر نقاط پرت: روش **Complete Linkage** نسبت به نقاط پرت مقاوم‌تر (*Robust*) است. در روش **Single Linkage**، پدیده «زنجیره‌ای شدن» (*Chaining*) باعث می‌شود یک نقطه پرت بتواند مانند یک پل عمل کرده و دو خوشه کاملاً مجزا را به اشتباه و زود هنگام به هم متصل کند. اما در **Complete Linkage**، چون بیشینه فاصله (قطر خوشه) ملاک ادغام است، خوشه‌ها تمایل دارند فشرده و کروی باقی بمانند و تأثیر نقاط پرت در ادغام‌های اولیه کمتر است.

۴.۲ خوشه‌بندی با روش **Linkage Complete**

گام‌های ادغام (بر اساس معیار بیشینه فاصله):

۱. ادغام $\{p_4, p_7\}$ و $\{p_5, p_8\}$ با کمترین فاصله 1.41.
۲. ادغام p_3 به خوشه $\{p_5, p_8\}$ با فاصله کامل 2.24.
۳. ادغام p_1 و p_2 با فاصله 2.24.
۴. ادغام p_9 به خوشه $\{p_1, p_2\}$ با فاصله کامل 3.00.
۵. ادغام p_6 به خوشه $\{p_3, p_5, p_8\}$ با فاصله کامل 6.00.
۶. ادغام دو بلوک سمت چپ یعنی $\{p_1, p_2, p_9\}$ و $\{p_4, p_7\}$ با فاصله 7.61.
۷. ادغام نهایی تمامی نقاط در یک خوشه واحد با فاصله تقریبی 10.63.



شکل ۱: دندروگرام کامل حاصل از خوشه‌بندی سلسله‌مراتبی با روش پیوند کامل (Complete Linkage)

پرسش ۳ کاهش ابعاد و هندسه داده‌ها

انتخاب روش بهینه برای کاهش ابعاد مستلزم تطبیق فرضیات آماری مدل با ساختار هندسی داده‌ها است.

۱.۳ .۱ داده‌های گاوسی با همبستگی خطی

روش بهینه: PCA

- تابع هدف: بیشینه‌سازی واریانس داده‌های تصویر شده:

$$\max_{\mathbf{w}} \mathbf{w}^T \Sigma \mathbf{w} \quad \text{s.t.} \quad \mathbf{w}^T \mathbf{w} = 1$$

در اینجا Σ ماتریس کوواریانس است که با استفاده از عملگر جمع (Σ) به صورت زیر تعریف می‌شود:

$$\Sigma = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^T$$

- استدلال: PCA بهترین تقریب خطی (Linear Approximation) را برای توزیع‌های گاوسی فراهم می‌کند. چون همبستگی خطی است، مؤلفه‌های اصلی بر بردارهای ویژه ماتریس کوواریانس منطبق شده و بیشترین اطلاعات را استخراج می‌کنند.

۲.۳ .۲ دو دایره متحدالمرکز

روش بهینه: PCA Kernel

- تابع هدف: حل مسئله مقدار ویژه در فضای ویژگی نگاشت شده (Φ) :

$$\mathbf{K}\mathbf{a} = \lambda\mathbf{a}$$

که در آن K ماتریس هسته (Kernel Matrix) با درایه‌های $K_{ij} = \kappa(\mathbf{x}_i, \mathbf{x}_j)$ است.

- استدلال: داده‌های دایره‌ای "خطی تفکیک‌پذیر" نیستند. kPCA با استفاده از تابع هسته (مانند Gaussian RBF)، داده‌ها را به فضایی با ابعاد بالاتر می‌برد که در آنجا ساختار غیرخطی به صورت خطی ظاهر می‌شود.

۳.۳. داده‌های ابعاد بالا با همپوشانی شدید کلاس‌ها

روش بهینه: LDA

- تابع هدف: بیشینه‌سازی نسبت Rayleigh (معیار فیشر):

$$J(\mathbf{w}) = \frac{\mathbf{w}^T \mathbf{S}_B \mathbf{w}}{\mathbf{w}^T \mathbf{S}_W \mathbf{w}}$$

که در آن $\mathbf{S}_B$ ماتریس پراکندگی بین‌کلاسی و $\mathbf{S}_W$ ماتریس پراکندگی درون‌کلاسی است.

- استدلال: برای طبقه‌بندی (Classification)، PCA ممکن است جهت‌هایی را انتخاب کند که کلاس‌ها را در هم ادغام کند. LDA با استفاده از برچسب‌ها، زیرفضایی را پیدا می‌کند که علی‌رغم همپوشانی، مرز بین کلاس‌ها حداکثر شود.

۴.۳. داده‌های حاوی ویژگی‌های نامرتب یا نویزی

روش بهینه: PCA

- استدلال: فرض اصلی در روش‌های کاهش ابعاد خطی این است که نویز دارای واریانس کم و ایزوتروپیک (در همه جهات یکسان) است.
- عملکرد: با نگه داشتن مؤلفه‌هایی که مقادیر ویژه (λ) بزرگی دارند و حذف مؤلفه‌های با λ کوچک، نویز از سیگنال اصلی جدا می‌شود. این فرآیند در ریاضیات به عنوان بازسازی داده با رتبه پایین (Low-rank Approximation) شناخته می‌شود.

۱.۴. ۱. محدودیت تعداد جهت‌های ممیز در LDA

در یک مسئله طبقه‌بندی با C کلاس، هدف LDA پیدا کردن جهت‌هایی است که رتبه تابع هدف فیشر را بیشینه کند. ماتریس پراکندگی بین‌کلاسی (S_B) به صورت زیر تعریف می‌شود:

$$S_B = \sum_{i=1}^C n_i (\mu_i - \mu)(\mu_i - \mu)^T$$

که در آن μ_i میانگین هر کلاس و μ میانگین کل داده‌ها است.
اثبات رتبه:

۱. ماتریس S_B مجموع C ماتریس رتبه ۱ است که از ضرب خارجی بردار تفاوت $(\mu_i - \mu)$ در خودش به دست می‌آیند.

۲. میانگین کل بر اساس میانگین کلاس‌ها چنین تعریف می‌شود: $\mu = \sum_{i=1}^C \frac{n_i}{N} \mu_i$.

۳. این رابطه منجر به یک قید خطی می‌شود: $\sum_{i=1}^C n_i (\mu_i - \mu) = 0$. این یعنی بردار C -ام همواره ترکیبی خطی از $C - 1$ بردار دیگر است.

۴. بنابراین، فضای زیرمجموعه تولید شده توسط بردارهای $(\mu_i - \mu)$ حداکثر دارای بعد $C - 1$ است.

۵. در نتیجه، $\text{rank}(S_B) \leq C - 1$. چون جهت‌های ممیز از حل مسئله مقدار ویژه معموم $S_B \mathbf{v} = \lambda S_W \mathbf{v}$ به دست می‌آیند، حداکثر $C - 1$ مقدار ویژه غیرصفر و در نتیجه $C - 1$ جهت ممیز وجود خواهد داشت.

۲.۴. تحلیل Kernel PCA و استخراج معادله مقدار ویژه

فرض بر این است که داده‌ها توسط نگاشت Φ به فضای ویژگی $\mathcal{F}$ منتقل شده و مرکزیت یافته‌اند $(\sum \Phi(x_i) = 0)$.

۱. عدم امکان تجزیه مستقیم:

ماتریس کوواریانس در فضای ویژگی $C = \frac{1}{N} \sum_{i=1}^N \Phi(x_i) \Phi(x_i)^T$ ابعادی برابر با ابعاد فضای ویژگی دارد. اگر Φ داده را به فضای با ابعاد نامتناهی ببرد، ماتریس C ابعاد نامتناهی خواهد داشت و تجزیه مقدار ویژه مستقیم آن غیرممکن است.

۲. قضیه نمایش (Representer Theorem):

معادله مقدار ویژه $CV = \lambda V$ است. با جایگذاری C :

$$\frac{1}{N} \sum_{i=1}^N \Phi(x_i) (\Phi(x_i)^T V) = \lambda V \implies V = \sum_{i=1}^N \frac{\Phi(x_i)^T V}{N\lambda} \Phi(x_i)$$

این نشان می‌دهد که V لزوماً ترکیبی خطی از نمونه‌های آموزش دیده در فضای ویژگی است: $V = \sum_{i=1}^N \alpha_i \Phi(x_i)$.

۳. استخراج معادله مقدار ویژه هسته: با جایگذاری V در معادله $CV = \lambda V$ و ضرب داخلی هر دو طرف در $\Phi(x_k)^T$:

$$\frac{1}{N} \sum_{i=1}^N \Phi(x_k)^T \Phi(x_i) \Phi(x_i)^T \sum_{j=1}^N \alpha_j \Phi(x_j) = \lambda \sum_{j=1}^N \alpha_j \Phi(x_k)^T \Phi(x_j)$$

با استفاده از تعریف هسته $K_{ij} = \langle \Phi(x_i), \Phi(x_j) \rangle$:

$$\frac{1}{N} \sum_{i=1}^N K_{ki} \sum_{j=1}^N \alpha_j K_{ij} = \lambda \sum_{j=1}^N \alpha_j K_{kj} \implies \frac{1}{N} K^2 \alpha = \lambda K \alpha$$

با حذف K از طرفین (برای مقادیر ویژه غیرصفر)، به معادله نهایی می‌رسیم:

$$K \alpha = (N\lambda) \alpha$$

۴. تصویر کردن نقطه جدید: برای یک نقطه جدید x ، تصویر آن روی k -امین مؤلفه اصلی (V^k) برابر است با:

$$y_k(x) = \Phi(x)^T V^k = \sum_{i=1}^N \alpha_i^k \langle \Phi(x), \Phi(x_i) \rangle = \sum_{i=1}^N \alpha_i^k \kappa(x, x_i)$$

که این رابطه کاملاً بر حسب تابع هسته است و نیازی به دانستن صریح Φ ندارد.

پرسش ۵: محاسبات دستی LDA

هدف از تحلیل ممیز خطی (LDA)، یافتن بردار وزن $\mathbf{w}$ است که معیار فیشر $J(\mathbf{w})$ را بیشینه کند. در ادامه مراحل گام به گام محاسبات آورده شده است:

۱. محاسبه میانگین کلاسی و میانگین کل

ابتدا بردارهای میانگین برای هر کلاس ($n_1 = n_2 = 5$) محاسبه می‌شوند:

$$\bullet \text{ میانگین کلاس ۱: } \mu_1 = \frac{1}{5} \sum \mathbf{x}_{1,i} = \left(\frac{15}{5}, \frac{19}{5}\right)^T = (3.0, 3.8)^T$$

$$\bullet \text{ میانگین کلاس ۲: } \mu_2 = \frac{1}{5} \sum \mathbf{x}_{2,i} = \left(\frac{42}{5}, \frac{38}{5}\right)^T = (8.4, 7.6)^T$$

$$\bullet \text{ میانگین کل (Overall Mean): } \mu = \frac{5\mu_1 + 5\mu_2}{10} = (5.7, 5.7)^T$$

۲. محاسبه ماتریس پراکندگی درون کلاسی (S_W)

ماتریس پراکندگی برای هر کلاس از رابطه $\mathbf{S}_i = \sum_{\mathbf{x} \in C_i} (\mathbf{x} - \mu_i)(\mathbf{x} - \mu_i)^T$ به دست می‌آید:

$$\bullet \text{ محاسبه } \mathbf{S}_1: \begin{pmatrix} 1 & -1.8 \\ -1 & 0.2 \\ -1 & -0.8 \\ 0 & 2.2 \\ 1 & 0.2 \end{pmatrix}^T \begin{pmatrix} 1 & -1.8 \\ -1 & 0.2 \\ -1 & -0.8 \\ 0 & 2.2 \\ 1 & 0.2 \end{pmatrix} = \begin{pmatrix} 4.0 & -1.0 \\ -1.0 & 9.2 \end{pmatrix}$$

$$\bullet \text{ محاسبه } \mathbf{S}_2: \begin{pmatrix} 0.6 & 2.4 \\ -2.4 & 0.4 \\ 0.6 & -2.6 \\ -0.4 & -0.6 \\ 1.6 & 0.4 \end{pmatrix}^T \begin{pmatrix} 0.6 & 2.4 \\ -2.4 & 0.4 \\ 0.6 & -2.6 \\ -0.4 & -0.6 \\ 1.6 & 0.4 \end{pmatrix} = \begin{pmatrix} 8.8 & 4.2 \\ 4.2 & 13.2 \end{pmatrix}$$

• ماتریس مجموع (S_W) :
$$S_W = S_1 + S_2 = \begin{pmatrix} 12.8 & 3.2 \\ 3.2 & 22.4 \end{pmatrix}$$

۳. محاسبه ماتریس پراکندگی بین کلاسی (S_B)

از آنجا که دو کلاس داریم، ماتریس S_B دارای رتبه ۱ بوده و به صورت زیر محاسبه می شود:

$$S_B = \sum_{i=1}^2 n_i (\mu_i - \mu)(\mu_i - \mu)^T$$

با توجه به اینکه $(\mu_1 - \mu) = (-2.7, -1.9)^T$ و $(\mu_2 - \mu) = (2.7, 1.9)^T$:

$$S_B = 5 \begin{pmatrix} -2.7 \\ -1.9 \end{pmatrix} \begin{pmatrix} -2.7 & -1.9 \end{pmatrix} + 5 \begin{pmatrix} 2.7 \\ 1.9 \end{pmatrix} \begin{pmatrix} 2.7 & 1.9 \end{pmatrix} = \begin{pmatrix} 72.9 & 51.3 \\ 51.3 & 36.1 \end{pmatrix}$$

۴. حل مسئله مقدار ویژه و تعیین جهت بهینه

برای حالت دو کلاس، جهت بهینه $\mathbf{w}$ مستقیماً از حل معادله $S_W \mathbf{w} = (\mu_2 - \mu_1)$ به دست می آید:

$$\mathbf{w} \propto S_W^{-1}(\mu_2 - \mu_1)$$

ابتدا وارون ماتریس S_W را محاسبه می کنیم $(\det = 12.8 \times 22.4 - 3.2^2 = 276.48)$:

$$S_W^{-1} = \frac{1}{276.48} \begin{pmatrix} 22.4 & -3.2 \\ -3.2 & 12.8 \end{pmatrix}$$

$$\mathbf{w} = \frac{1}{276.48} \begin{pmatrix} 22.4 & -3.2 \\ -3.2 & 12.8 \end{pmatrix} \begin{pmatrix} 5.4 \\ 3.8 \end{pmatrix} = \begin{pmatrix} 0.393 \\ 0.113 \end{pmatrix}$$

برای سادگی، بردار را نرمالایز می کنیم: $\mathbf{w} \approx (0.96, 0.28)^T$.

۵. تصویر کردن تمامی نقاط و گزارش مختصات یک بعدی

مختصات یک بعدی نهایی (y) برای هر نقطه داده شده $\mathbf{x} = (x_1, x_2)^T$ از طریق ضرب داخلی با بردار ممیز بهینه $\mathbf{w} \approx (0.393, 0.113)^T$ محاسبه می شود:

$$y = \mathbf{w}^T \mathbf{x} = 0.393x_1 + 0.113x_2$$

در جدول زیر، مختصات تصویر شده برای تمامی نقاط هر دو کلاس آورده شده است:

Data Point	1D Projected Coordinate (y)
Class 1 - (4, 2)	$0.393(4) + 0.113(2) = 1.798$
Class 1 - (2, 4)	$0.393(2) + 0.113(4) = 1.238$
Class 1 - (2, 3)	$0.393(2) + 0.113(3) = 1.125$
Class 1 - (3, 6)	$0.393(3) + 0.113(6) = 1.857$
Class 1 - (4, 4)	$0.393(4) + 0.113(4) = 2.024$
Mean C1	Projected Mean: 1.608
Class 2 - (9, 10)	$0.393(9) + 0.113(10) = 4.667$
Class 2 - (6, 8)	$0.393(6) + 0.113(8) = 3.262$
Class 2 - (9, 5)	$0.393(9) + 0.113(5) = 4.102$
Class 2 - (8, 7)	$0.393(8) + 0.113(7) = 3.935$
Class 2 - (10, 8)	$0.393(10) + 0.113(8) = 4.834$
Mean C2	Projected Mean: 4.159

جدول ۱: مختصات یک بعدی نقاط پس از تصویر کردن توسط LDA

نتیجه گیری: بازه کلاس اول $[1.12, 2.02]$ و بازه کلاس دوم $[3.26, 4.83]$ است. عدم همپوشانی این بازه ها نشان دهنده استخراج صحیح جهت ممیز است.

پرسش ۶: انتخاب ویژگی و تحلیل الگوریتم‌های حریصانه

۱. مکانیزم عملکرد روش‌های انتخاب متوالی (Sequential Selection)

روش‌های Wrapper از یک مدل پیش‌بین به عنوان «جعبه سیاه» برای ارزیابی زیرمجموعه‌های ویژگی استفاده می‌کنند.

● (SFS): Sequential Forward Selection

- مقداردهی اولیه (Initialization): شروع با یک مجموعه تهی از ویژگی‌ها $Y_0 = \emptyset$.
- گام به‌روزرسانی (Update Step): در هر تکرار، ویژگی x^+ از میان ویژگی‌های انتخاب‌نشده به گونه‌ای انتخاب می‌شود که تابع ارزیابی $J(Y_k \cup \{x^+\})$ بیشینه شود.
- معیار توقف (Stopping Criterion): رسیدن به تعداد ویژگی مطلوب (p) یا زمانی که اضافه کردن هر ویژگی جدید باعث بهبود در عملکرد مدل نشود.

● (SBS): Sequential Backward Selection

- مقداردهی اولیه: شروع با مجموعه کامل تمام ویژگی‌ها $Y_0 = \mathcal{X}$.
- گام به‌روزرسانی: در هر مرحله ویژگی x^- حذف می‌شود که حذف آن کمترین کاهش (یا بیشترین بهبود) را در تابع معیار $J(Y_k \setminus \{x^-\})$ ایجاد کند.
- معیار توقف: رسیدن به تعداد ویژگی هدف یا زمانی که حذف هر ویژگی دیگر منجر به افت شدید عملکرد شود.

- انتخاب دوطرفه (Bidirectional Selection): این روش ترکیبی از SFS و SBS است. در هر مرحله، الگوریتم هم ویژگی‌های جدید را اضافه می‌کند و هم ویژگی‌های قبلاً انتخاب شده را برای حذف احتمالی بررسی می‌کند. این کار اجازه می‌دهد ویژگی‌هایی که در مراحل

اولیه SFS انتخاب شده‌اند اما بعداً با حضور ویژگی‌های جدید اهمیت خود را از دست داده‌اند، حذف شوند.

- **الگوریتم حریصانه (Greedy):** این روش‌ها «حریصانه» نامیده می‌شوند زیرا در هر گام، تصمیمی را می‌گیرند که در همان لحظه بهترین به نظر می‌رسد (Best Local Decision). در این فضا، «حریصانه» به معنای تمرکز بر سود آنی بدون در نظر گرفتن پیامدهای احتمالی این انتخاب در مراحل آینده است.

۲. تحلیل پیامدهای رفتار حریصانه

الگوریتم‌های SFS و SBS تضمینی برای یافتن بهینه سراسری (Globally Optimal Subset) ندارند. حتی در صورت محذب بودن مدل پیش‌بین، هیچ‌یک از روش‌ها تضمینی برای یافتن زیرمجموعه بهینه سراسری ندارند. علت این امر به ماهیت حریصانه آن‌ها برمی‌گردد:

- **در SFS و SBS (اثر آشیانه‌ای):** این دو روش دچار محدودیت «صلبیت در تصمیم‌گیری» هستند. در SFS، مجموعه‌ای که در گام k انتخاب می‌شود، لزوماً باید شامل تمام اعضای گام $k - 1$ باشد ($Y_{k-1} \subset Y_k$). این یعنی اگر ویژگی x_1 در گام اول انتخاب شود، تا انتها «قفل» شده و هرگز حذف نمی‌شود، حتی اگر ترکیب‌های بهتری بدون حضور x_1 وجود داشته باشد. به طور مشابه در SBS، ویژگی حذف شده هرگز شانس بازگشت ندارد ($Y_k \subset Y_{k-1}$).

- **Bidirectional Selection (عدم تضمین بهینه سراسری):** اگرچه این روش با ترکیب گام‌های اضافه و حذف، محدودیت «آشیانه‌ای» (Nesting) را تا حد زیادی بهبود می‌بخشد و اجازه بازنگری در تصمیمات قبلی را می‌دهد، اما همچنان یک الگوریتم حریصانه است. این روش تنها مسیرهایی را بررسی می‌کند که در هر گام منجر به بهبود آنی تابع ارزیابی J شوند. بسیاری از زیرمجموعه‌های بهینه ممکن است در میانه مسیر امتیاز پایینی داشته باشند و تنها در ابعاد نهایی قدرت خود را نشان دهند؛ الگوریتم‌های حریصانه (حتی دوطرفه) به دلیل عدم جستجوی جامع در فضای 2^d ، قادر به شناسایی این «تعاملات پنهان» نیستند و ممکن است در یک بهینه محلی (Local Optimum) متوقف شوند.

سناریوی شکست (مثال نقض): فرض کنید ترکیب سه ویژگی $\{x_1, x_2, x_3\}$ بهترین عملکرد را دارد، اما به تنهایی یا دو به دو، امتیاز بسیار پایینی تولید می‌کنند. در SFS، چون هیچ‌کدام در گام اول انفرادی موفق نیستند، انتخاب نمی‌شوند. در SBS، چون در ترکیب‌های بزرگ (مثلاً با ۱۰ ویژگی نویزی دیگر) اثر آن‌ها پنهان است، ممکن است یکی از آن‌ها به اشتباه حذف شود. حتی در روش دوطرفه، اگر حذف یا اضافه کردن یکی از این سه عضو در یک گام خاص منجر به بهبود لحظه‌ای J نشود، الگوریتم از مسیر رسیدن به این زیرمجموعه بهینه منحرف می‌شود.

۳. مقایسه با روش‌های جایگزین (RFE و Lasso)

Metric	Sequential (SFS/SBS)	RFE	L1 (Lasso)
Computational Complexity	High: Requires $O(d^2)$ model trainings.	Moderate: Requires $O(d)$ iterations.	Low: Solved via single convex optimization.
Feature Correlations	Sensitive: May pick redundant features.	More robust: Prunes based on weight importance.	High: Tends to pick only one from a group of correlated features.
Feature Interactions	Poorly captured due to greedy addition/removal.	Better captured as it starts with all features.	Limited: Depends on the model structure.
High-Dimensional Data	Unsuitable: Search space becomes too large.	Better scalability than SFS.	Highly suitable: Very efficient for $d \gg n$.

جدول ۲: مقایسه روش‌های انتخاب ویژگی

پرسش ۷ - تحلیل PCA و Kernel PCA روی داده‌های ساختاریافته

در این تمرین، ابتدا به تحلیل PCA بر روی یک مجموعه داده واقعی با ابعاد کم (Iris) پرداخته و سپس محدودیت‌های روش‌های خطی را بر روی داده‌های غیرخطی بررسی می‌کنیم.

الف) تحلیل مجموعه داده Iris

۱. نتایج محاسباتی و واریانس: پس از استانداردسازی داده‌ها و اعمال PCA برای کاهش ابعاد از ۴ به ۲ ویژگی، نتایج زیر حاصل شد:

- مقادیر ویژه ماتریس کوواریانس: مقادیر متناظر با دو مولفه اول به ترتیب برابر با ۹۳۸.۲ و ۹۲۰.۰ می‌باشند.

- نسبت واریانس بیان‌شده (Explained Variance Ratio):


— مولفه اصلی اول (PC1): ۷۲٪/۹۶٪

— مولفه اصلی دوم (PC2): ۲۲٪/۸۵٪

- در مجموع، این دو مولفه توانسته‌اند ۹۵٪/۸۱٪ از کل واریانس داده‌ها را حفظ کنند.

۲. بصری‌سازی و تحلیل نتایج: داده‌های تصویر شده در فضای دو بعدی PCA در شکل ۲ نمایش داده شده‌اند.

- تحلیل واریانس: مولفه اصلی اول (PC1) بیشترین میزان واریانس را جذب کرده است. دلیل شهودی این امر آن است که PCA جهت‌هایی را می‌یابد که داده‌ها در آن بیشترین گسترگی را دارند؛ در داده‌های Iris، ویژگی‌هایی مانند طول و عرض گلبرگ همبستگی بالایی دارند و تغییرات اصلی داده‌ها در راستای ترکیبی از این ویژگی‌ها رخ می‌دهد.



شکل ۲: نمودار پراکندگی داده‌های Iris در فضای دو مولفه اصلی اول.

- **تفکیک‌پذیری کلاس‌ها:** همان‌طور که در شکل مشاهده می‌شود، کلاس‌ها (به‌ویژه Setosa) به خوبی در فضای کاهش‌یافته جدا شده‌اند. این موضوع مورد انتظار است، زیرا تابع هدف PCA حفظ واریانس است و در این دیتاست، جهت‌های دارای واریانس بالا با جهت‌های تمایزدهنده کلاس‌ها هم‌راستا هستند.
- **مناسب بودن برای طبقه‌بندی:** اگرچه در اینجا جداسازی خوبی رخ داده است، اما PCA لزوماً برای طبقه‌بندی بهینه نیست. PCA یک روش بدون نظارت است که برچسب‌ها را نادیده می‌گیرد؛ اگر اطلاعات تمایزدهنده کلاس‌ها در جهت‌هایی با واریانس کم قرار داشت، PCA آن‌ها را حذف می‌کرد.


۳. مقایسه مفهومی با LDA: در صورت استفاده از تحلیل تفکیک خطی (LDA) به جای

:PCA

- **تابع هدف:** PCA به دنبال بیشینه‌سازی واریانس کل است، اما LDA به دنبال بیشینه‌سازی نسبت واریانس بین‌کلاسی به درون‌کلاسی است.
- **استفاده از برچسب‌ها:** LDA از برچسب کلاس‌ها استفاده می‌کند تا محورهایی بیابد که کلاس‌ها را به بهترین شکل از هم جدا کنند. در نتیجه، در تصویر LDA، فاصله بین خوشه‌ها بیشتر و تراکم درون آن‌ها نسبت به PCA افزایش می‌یابد.

ب) داده‌های غیرخطی (دایره‌های متحدالمرکز)

در این بخش، محدودیت روش‌های خطی بر روی داده‌هایی که به صورت دو دایره تو در تو هستند بررسی شد.



شکل ۳: مقایسه عملکرد PCA خطی (چپ) و Kernel PCA با هسته RBF (راست).

تحلیل مقایسه‌ای:


- شکست Standard PCA: همان‌طور که در نمودار سمت چپ شکل فوق مشخص است، PCA خطی نتوانسته است دو کلاس را از هم جدا کند. چون این روش تنها از ترکیبات خطی ویژگی‌ها استفاده می‌کند، نمی‌تواند ساختار دایره‌ای داده‌ها را که میانگین یکسانی دارند باز کند.
- موفقیت Kernel PCA: در نمودار سمت راست، مشاهده می‌شود که با استفاده از هسته RBF، داده‌ها کاملاً تفکیک پذیر شده‌اند.
- نقش نگاشت غیرخطی و ترفند هسته: Kernel PCA داده‌ها را به طور ضمنی به یک فضای ویژگی با ابعاد بالاتر نگاشت می‌کند که در آنجا دایره‌ها به صورت خطی تفکیک پذیر می‌شوند. «ترفند هسته» به ما اجازه می‌دهد بدون محاسبه صریح مختصات در آن فضای پیچیده، تنها با استفاده از توابع هسته، ساختار غیرخطی داده‌ها را استخراج کنیم.

پرسش ۸ - انتخاب ویژگی و مصورسازی بر روی مجموعه داده واقعی

در این بخش، مجموعه داده بیماری قلبی ارسالی (heart.csv) با استفاده از روش‌های متنوع انتخاب ویژگی مورد تحلیل قرار گرفت تا تأثیر حذف ویژگی‌های زائد بر عملکرد و مفسرپذیری مدل بررسی شود.

۱. تحلیل اکتشافی و فیلتر همبستگی

ماتریس همبستگی ویژگی‌ها در شکل ۴ نمایش داده شده است. با بررسی این ماتریس، مشاهده شد که همبستگی‌های خطی شدیدی (بالای ۸۰٪) بین متغیرها وجود ندارد.



شکل ۴: ماتریس همبستگی ویژگی‌های دیتاست heart.csv.


عدم حذف ویژگی‌ها در گام فیلتر نشان‌دهنده این است که متغیرهای ورودی اطلاعات مکملی را ارائه می‌دهند. روش‌های فیلتر معمولاً تعاملات پیچیده بین ویژگی‌ها را نادیده می‌گیرند، لذا استفاده از روش‌های مبتنی بر مدل الزامی است.

۲. تحلیل روش‌های Wrapper (نمودارهای RFE و RFECV)


در این بخش، دو نمودار برای بررسی حذف بازگشتی ویژگی‌ها استخراج شد:

- **رتبه‌بندی ویژگی‌ها (RFE):** در شکل ۵، اولویت ویژگی‌ها نمایش داده شده است. ویژگی‌هایی با رتبه ۱ (sex, cp, thalach, oldpeak, ca) به عنوان ۵ ویژگی برتر شناسایی شدند. این نمودار نشان می‌دهد که مدل برای رسیدن به دقت مناسب، ابتدا ویژگی‌هایی مانند fbs را حذف کرده است.

- **تعداد بهینه ویژگی‌ها (RFECV):** طبق شکل ۶، دقت مدل با افزایش تعداد ویژگی‌ها تا ۱۲ مورد روند صعودی دارد. این موضوع بیانگر آن است که برای پیش‌بینی دقیق بیماری قلبی در این دیتاست، تقریباً تمامی ویژگی‌های کلینیکی نقش مثبت ایفا می‌کنند.



شکل ۵: رتبه‌بندی ویژگی‌ها در روش RFE.




شکل ۶: دقت مدل در مقابل تعداد ویژگی‌ها (RFECV).

۳. مقایسه روش‌های آماری و نهفته (Lasso)

مقایسه لیست ویژگی‌های منتخب نشان داد که روش Lasso با جریمه L1، همان ۱۲ ویژگی شناسایی شده در RFECV را حفظ کرده است. تفاوت اندک در اولویت‌بندی روش تک‌متغیره (Mutual Information) با روش‌های مبتنی بر مدل (RFE) تأیید می‌کند که برخی ویژگی‌ها (مانند sex) در تعامل با سایر متغیرها قدرت پیش‌بینی پیدا می‌کنند و به تنهایی ممکن است کم‌اهمیت به نظر برسند.

۴. تحلیل کاهش ابعاد با PCA

تحلیل واریانس انباشته در شکل ۷ نشان می‌دهد که ۱۱ مولفه اصلی برای توضیح ۹۰٪ از تغییرات داده‌ها کافی است.



شکل ۷: نمودار واریانس انباشته در تحلیل PCA.

تفاوت تفسیرپذیری: برخلاف روش‌های انتخاب ویژگی که متغیرهای اصلی (مانند سن یا فشار خون) را نگه می‌دارند، PCA ویژگی‌های جدیدی می‌سازد که ترکیبی نامفهوم از داده‌های اولیه هستند. در حوزه پزشکی، انتخاب ویژگی بر PCA ارجحیت دارد، زیرا پزشک باید بداند دقیقاً کدام پارامتر فیزیولوژیک بر خطر بیماری تأثیرگذار است.

۵. نتیجه‌گیری و مقایسه نهایی روش‌ها

در این بخش، مقایسه نهایی بین رویکردهای مختلف انتخاب ویژگی (Embedded، Wrapper، Filter) و کاهش ابعاد (PCA) بر اساس چهار معیار کلیدی انجام شده است:

- **عملکرد پیش‌بینی (Predictive Performance):** روش‌های Wrapper (مانند RFECV)

و Embedded (مانند Lasso) بهترین عملکرد را در پیش‌بینی دقیق بیماری قلبی روی این مجموعه داده داشتند. بر اساس نمودار ۶، مدل با استفاده از ۱۲ ویژگی به بیشینه دقت خود دست یافت. روش‌های تک‌متغیره (Filter) به دلیل نادیده گرفتن تعاملات بین متغیرها، معمولاً دقت کمتری نسبت به روش‌های مبتنی بر مدل ارائه می‌دهند.

- **تفسیرپذیری (Interpretability):** روش‌های انتخاب ویژگی (Lasso، RFE، Filter) دارای

بالاترین میزان تفسیرپذیری هستند، زیرا مستقیماً ویژگی‌های کلینیکی اصلی (مانند نوع درد قفسه سینه یا فشار خون) را شناسایی و حفظ می‌کنند. در مقابل، PCA کمترین تفسیرپذیری را دارد، زیرا مولفه‌های جدید ترکیباتی انتزاعی از متغیرها هستند و معنای پزشکی مستقیمی ندارند.

- **حساسیت به همبستگی ویژگی‌ها:** روش Filter بیشترین حساسیت را به همبستگی دارد

و ممکن است نتواند ویژگی‌های همبسته و زائد را به خوبی تفکیک کند. روش‌های Embedded مانند Lasso به دلیل استفاده از جریمه L1، در مدیریت ویژگی‌های همبسته بسیار پایدار عمل کرده و تمایل دارند از بین متغیرهای همبسته، مرتبط‌ترین آن‌ها را حفظ کنند.

- **هزینه محاسباتی (Computational Cost):** روش‌های Filter کمترین هزینه محاسباتی را

دارند و بسیار سریع اجرا می‌شوند. در مقابل، روش‌های Wrapper به دلیل تکرار فرآیند آموزش و ارزیابی مدل در هر مرحله حذف ویژگی، بیشترین هزینه را دارا هستند. روش Lasso توازن مناسب بین دقت و سرعت محاسباتی برقرار می‌کند.

در نهایت، برای کاربرد تشخیص بیماری قلبی، روش‌های Embedded و Wrapper به دلیل حفظ دقت بالا در کنار مفسرپذیری پزشکی (که برای پزشک حیاتی است)، نسبت به PCA و روش‌های ساده آماری برتری دارند.

پرسش ۹ - بخش‌بندی تصاویر با استفاده از خوشه‌بندی (امتیازی)

در این مسئله، هدف بخش‌بندی دو تصویر رنگی با استفاده از الگوریتم‌های K-Means و مدل مخلوط گوسی (GMM) بر اساس ویژگی‌های ترکیبی رنگی و مکانی است.

۱. تشکیل بردار ویژگی و نرمال‌سازی

برای هر پیکسل در تصویر، یک بردار ویژگی ۵ بعدی استخراج گردید که شامل مختصات افقی و عمودی نرمال شده و مقادیر نرمال شده کانال‌های رنگی R، G و B است. مطابق با صورت سوال، تمامی ویژگی‌ها به بازه $[0, 1]$ نگاشت شدند تا مجموعه داده در یک ابرمکعب واحد قرار گیرد. این فرآیند تضمین می‌کند که مولفه‌های مکانی و رنگی با وزن یکسانی در محاسبات فاصله تأثیرگذار باشند.


۲. پیاده‌سازی الگوریتم‌ها

بخش‌بندی برای مقادیر $K \in \{2, 3, 4, 5\}$ با دو رویکرد متفاوت انجام شد:


- **الگوریتم K-Means:** اختصاص هر پیکسل به نزدیک‌ترین مرکز خوشه بر اساس کمترین فاصله اقلیدسی در فضای ویژگی ۵ بعدی.
- **الگوریتم GMM:** برازش مدل با استفاده از الگوریتم EM و اختصاص برچسب به پیکسل‌ها بر اساس بیشینه احتمال پسین (MAP).

۳. نمایش نتایج و تحلیل نهایی

جهت بهبود بصری و تفکیک بهتر خوشه‌ها، از نقشه‌های رنگی با کنتراست بالا استفاده شد. نتایج در شکل‌های ۸ و ۹ نمایش داده شده‌اند.



شکل ۸: نتایج بخش بندی تصویر اول (image1.jpg) با دو روش K-Means و GMM.



شکل ۹: نتایج بخش بندی تصویر دوم (image2.jpg) با دو روش K-Means و GMM.

تحلیل تفاوت‌ها: مشاهده می‌شود که الگوریتم K-Means به دلیل استفاده از فاصله اقلیدسی ساده، تمایل دارد بخش‌هایی با هندسه صلب و کروی ایجاد کند. در مقابل، الگوریتم GMM به دلیل استفاده از ماتریس کوواریانس، انعطاف‌پذیری بیشتری در مدل‌سازی خوشه‌ها به شکل بیضوی دارد. این ویژگی باعث می‌شود GMM در جداسازی نواحی که دارای تغییرات تدریجی در بافت یا رنگ هستند (مانند سایه‌روشن‌ها)، عملکرد دقیق‌تر و طبیعی‌تری نسبت به K-Means ارائه دهد.

١. Pedregosa, F. et al. (٢٠١١) "Scikit-learn: Machine Learning in Python". *Journal of Machine Learning Research*. (For PCA, K-Means, and GMM implementations).
٢. Dua, D. and Graff, C. (٢٠١٩) "UCI Machine Learning Repository". University of California, Irvine, School of Information and Computer Science. (Source of the Heart Disease Dataset).
٣. Hunter, J. D. (٢٠٠٧) "Matplotlib: A ٢D Graphics Environment". *Computing in Science & Engineering*. (Used for all data visualizations and clustering results).
٤. Scikit-learn Documentation: "User Guide – Dimensionality Reduction, Clustering, and Feature Selection".
٥. McKinney, W. (٢٠١٠) "Data Structures for Statistical Computing in Python". *Proceedings of the ٩th Python in Science Conference*. (For Pandas data manipulation).