

دانشگاه تهران
پردیس دانشکده‌های فنی
دانشکده مهندسی برق و کامپیوتر



یادگیری ماشین

تمرین شماره ۵

نام و نام خانوادگی
پریا خلیلی

شماره دانشجویی
۸۱۰۸۰۱۰۶۵

۲۴ بهمن ۱۴۰۴

فهرست مطالب

۲	۱ پرسش ۱ - تخمین درست‌نمایی بیشینه	۲
۴	۲ پرسش ۲ - رگرسیون لجستیک با یک ویژگی	۴
۷	۳ پرسش ۳ - رگرسیون خطی با تنظیم L2 و روش نیوتن	۷
۱۰	۴ پرسش ۴: رگرسیون چندجمله‌ای و تنظیم Ridge	۱۰
۱۴	۵ پرسش ۵ - پرسپترون	۱۴
۱۷	۶ پرسش ۶ - نمایش‌های شبکه عصبی	۱۷
۲۰	۷ پرسش ۷ - تابع هزینه	۲۰
۲۰	۱.۷ .۱ هم‌ارزی درست‌نمایی بیشینه و آنتروپی متقاطع	۲۰
۲۱	۲.۷ .۲ برچسب‌های نویزی (Noisy Labels)	۲۱
۲۱	۳.۷ .۳ تابع هزینه برای اهداف $t \in \{-1, 1\}$	۲۱
۲۳	۸ پرسش ۸ - پایداری تصادفی و Dead ReLU	۲۳
۲۳	۱.۸ .۱ اثبات توزیع (Distribution Proof)	۲۳
۲۴	۲.۸ .۲ احتمال فعال‌سازی (Activation Probability)	۲۴
۲۴	۳.۸ .۳ آستانه 3σ	۲۴
۲۵	۴.۸ .۴ اثبات گرادینان صفر (Dead ReLU)	۲۵
۲۶	۹ پرسش ۹ - حفظ واریانس و مقداردهی اولیه خاویر (Xavier Initialization)	۲۶
۲۶	۱.۹ .۱ قیود متقارن (Symmetric Constraints)	۲۶
۲۷	۲.۹ .۲ سنتز گلوروت (The Glorot Synthesis)	۲۷

۲۷	۳.۹	۳. واریانس ناشی از عمق (Depth-Induced Variance)
۲۸	۴.۹	۴. کران پایداری (Stability Bound)
۲۸	۵.۹	۵. تحلیل عددی

۲۹	۱۰ پرسش ۱۰ - یادگیری انتقال با شبکه‌های پیش‌آموزش دیده
----	--

۳۲	۱۱ مراجع
----	----------

فهرست تصاویر

۱۰	برازش چندجمله‌ای با درجات ۱، ۳ و ۹ بر روی داده‌های data_A	۱
۱۱	تغییرات MSE آموزش و اعتبارسنجی بر حسب درجه چندجمله‌ای	۲
۱۲	تغییرات MSE بر حسب پارامتر تنظیم λ (برای درجه ثابت $d = 10$)	۳
۳۰	روند کاهش خطای آموزش	۴
۳۰	روند افزایش دقت اعتبارسنجی	۵

فهرست جداول

این مجموعه سوال به بررسی جامع مبانی نظری و پیاده‌سازی عملی الگوریتم‌های یادگیری ماشین و یادگیری عمیق می‌پردازد. در بخش نخست، اصول تخمین درست‌نمایی بیشینه (MLE) و رگرسیون لجستیک تشریح شده و همگرایی روش‌های بهینه‌سازی مرتبه اول و دوم، نظیر گرادین کاهشی تصادفی و روش نیوتن، مورد تحلیل قرار می‌گیرد. در ادامه، مکانیسم‌های تعمیم‌پذیری و کنترل پیچیدگی مدل از طریق تحلیل مبادله بایاس-واریانس در رگرسیون چندجمله‌ای و تنظیم‌گر ریج (Ridge Regularization) واکاوی می‌شوند. بخش دوم به محاسبات عصبی اختصاص دارد که شامل بررسی محدودیت‌های هندسی پرسپترون، طراحی گراف‌های محاسباتی و اثبات ارتباط میان توابع هزینه آنتروپی متقاطع و درست‌نمایی است. همچنین، چالش‌های دینامیک آموزش در شبکه‌های عمیق، با استفاده از مقداردهی اولیه خاویر (Xavier Initialization)، فرمول‌بندی می‌شوند. در نهایت، اثرات سوگیری القایی (Inductive Bias) در معماری‌های کانولوشنی از طریق پیاده‌سازی یادگیری انتقال (Transfer Learning) با شبکه VGG-۱۱ بر روی مجموعه داده CIFAR-۱۰ و مقایسه آن با پرسپترون چندلایه ارزیابی می‌گردد.

پرسش 1 - تخمین درست‌نمایی بیشینه

در این مسأله، هدف یافتن تخمین‌گر درست‌نمایی بیشینه (MLE) برای پارامتر θ است. فرض می‌کنیم $x_1, x_2, \dots, x_n$ نمونه‌های مستقل و دارای توزیع یکسان (i.i.d) از توزیع احتمال زیر باشند:

$$P(x|\theta) = \theta x^{-\theta-1}, \quad \theta > 1, x \geq 1 \quad (1)$$

۱. تشکیل تابع درست‌نمایی (Likelihood Function)

تابع درست‌نمایی $L(\theta)$ برابر است با حاصل ضرب چگالی احتمال برای تمامی مشاهدات:

$$L(\theta) = \prod_{i=1}^n P(x_i|\theta) = \prod_{i=1}^n (\theta x_i^{-\theta-1}) \quad (2)$$

با ساده‌سازی عبارت فوق، داریم:

$$L(\theta) = \theta^n \left(\prod_{i=1}^n x_i \right)^{-\theta-1} \quad (3)$$

۲. تابع لگاریتم درست‌نمایی (Log-Likelihood)

برای تسهیل فرآیند مشتق‌گیری، از لگاریتم طبیعی تابع درست‌نمایی استفاده می‌کنیم. از آنجا که تابع لگاریتم صعودی اکید است، ماکسیم کردن آن معادل ماکسیم کردن تابع اصلی است:

$$\ell(\theta) = \ln L(\theta) = \ln \left(\theta^n \prod_{i=1}^n x_i^{-\theta-1} \right) \quad (4)$$

با استفاده از خواص لگاریتم، عبارت را بازنویسی می‌کنیم:

$$\begin{aligned}\ell(\theta) &= n \ln \theta + \sum_{i=1}^n \ln (x_i^{-\theta-1}) \\ &= n \ln \theta - (\theta + 1) \sum_{i=1}^n \ln x_i\end{aligned}\quad (5)$$

۳. بهینه‌سازی و یافتن تخمین‌گر

برای یافتن نقطه اکسترمم، از تابع $\ell(\theta)$ نسبت به θ مشتق گرفته و آن را برابر با صفر قرار می‌دهیم (شرط مرتبه اول):

$$\frac{\partial \ell(\theta)}{\partial \theta} = \frac{n}{\theta} - \sum_{i=1}^n \ln x_i = 0 \quad (6)$$

با حل معادله فوق برای θ :

$$\frac{n}{\theta} = \sum_{i=1}^n \ln x_i \implies \hat{\theta}_{\text{MLE}} = \frac{n}{\sum_{i=1}^n \ln x_i} \quad (7)$$

۴. بررسی شرط مرتبه دوم (Second-Order Condition)

برای اطمینان از اینکه نقطه به دست آمده یک ماکسیمم است، مشتق دوم را محاسبه می‌کنیم:

$$\frac{\partial^2 \ell(\theta)}{\partial \theta^2} = -\frac{n}{\theta^2} \quad (8)$$

از آنجا که $n > 0$ است، مشتق دوم همواره منفی خواهد بود ($-\frac{n}{\theta^2} < 0$). این نشان می‌دهد که تابع لگاریتم درست‌نمایی مقعر (Concave) است و نقطه به دست آمده یک ماکسیمم سراسری (Global Maximum) می‌باشد.

پاسخ نهایی: تخمین‌گر درست‌نمایی بیشینه برای پارامتر θ عبارت است از:

$$\boxed{\hat{\theta}_{\text{MLE}} = \frac{n}{\sum_{i=1}^n \ln x_i}} \quad (9)$$

پرسش ۲ - رگرسیون لجستیک با یک ویژگی

در این مسأله، هدف استخراج قاعده به‌روزرسانی گرادیان کاهشی تصادفی (SGD) برای پارامتر α است.

۱. تعریف مدل و تابع هزینه

طبق صورت سوال، احتمال پسین برای یک نقطه آزمون $z \in \mathbb{R}$ به صورت زیر مدل‌سازی می‌شود:

$$P(y = 1|z) = s(z - \alpha), \quad s(\gamma) = \frac{1}{1 + e^{-\gamma}} \quad (10)$$

حال برای یک نقطه داده آموزشی خاص با مقدار x و برچسب $y \in \{0, 1\}$ ، هدف ما یافتن α است که تابع هزینه (آنتروپی متقاطع) زیر را کمینه کند:

$$J(\alpha) = -y \ln s(x - \alpha) - (1 - y) \ln(1 - s(x - \alpha)) \quad (11)$$

۲. محاسبه گرادیان

برای به دست آوردن قاعده به‌روزرسانی، باید مشتق $J(\alpha)$ را نسبت به α محاسبه کنیم. فرض می‌کنیم $u = x - \alpha$ و از نماد اختصاری s برای $s(u)$ استفاده می‌کنیم. با استفاده از قاعده زنجیره‌ای (Chain Rule) داریم:

$$\frac{\partial J}{\partial \alpha} = \frac{\partial J}{\partial s} \cdot \frac{\partial s}{\partial u} \cdot \frac{\partial u}{\partial \alpha} \quad (12)$$

اکنون هر یک از اجزای مشتق را جداگانه محاسبه می‌کنیم:
گام اول: مشتق آرگومان نسبت به پارامتر

$$\frac{\partial u}{\partial \alpha} = \frac{\partial}{\partial \alpha}(x - \alpha) = -1 \quad (13)$$

گام دوم: مشتق تابع سیگموئید نسبت به آرگومان
می‌دانیم که مشتق تابع سیگموئید برابر است با $s'(u) = s(u)(1 - s(u))$:

$$\frac{\partial s}{\partial u} = s(1 - s) \quad (14)$$

گام سوم: مشتق تابع هزینه نسبت به s

$$\begin{aligned} \frac{\partial J}{\partial s} &= -\frac{y}{s} - (1 - y)\frac{-1}{1 - s} \\ &= \frac{-y(1 - s) + s(1 - y)}{s(1 - s)} \\ &= \frac{-y + ys + s - ys}{s(1 - s)} = \frac{s - y}{s(1 - s)} \end{aligned} \quad (15)$$

۳. ترکیب و قاعده به‌روزرسانی نهایی

با ضرب کردن سه عبارت محاسبه شده در بالا، گرادیان نهایی به دست می‌آید:

$$\begin{aligned} \frac{\partial J}{\partial \alpha} &= \left(\frac{s - y}{s(1 - s)} \right) \cdot (s(1 - s)) \cdot (-1) \\ &= -(s - y) \\ &= y - s \end{aligned} \quad (16)$$

بنابراین گرادیان تابع هزینه برابر است با:

$$\nabla_{\alpha} J = y - s(x - \alpha) \quad (17)$$

در روش گرادیان کاهشی، پارامتر در خلاف جهت گرادیان به‌روزرسانی می‌شود. با در نظر گرفتن نرخ یادگیری $\epsilon > 0$:

$$\alpha_{\text{new}} \leftarrow \alpha_{\text{old}} - \epsilon \nabla_{\alpha} J \quad (18)$$

با جایگذاری مقدار گرادیان:

$$\alpha \leftarrow \alpha - \epsilon(y - s(x - \alpha)) \quad (۱۹)$$

که می‌توان آن را به فرم استاندارد زیر نیز نوشت:

$$\alpha \leftarrow \alpha + \epsilon(s(x - \alpha) - y) \quad (۲۰)$$

پرسش ۳ - رگرسیون خطی با تنظیم L2 و روش نیوتن

در این سوال، قصد داریم نشان دهیم که با استفاده از روش نیوتن (Newton's Method) برای کمینه‌سازی تابع هزینه رگرسیون خطی با تنظیم L2، تنها با یک گام به‌روزرسانی از هر نقطه شروع دلخواه w_0 ، به جواب بهینه سراسری w^* می‌رسیم.

۱. تعریف تابع هدف و گرادیان

طبق صورت سوال، تابع هدف برای رگرسیون خطی با تنظیم L2 به صورت زیر است:

$$J(w) = \|Xw - y\|_2^2 + \lambda \|w\|_2^2 \quad (21)$$

این تابع را می‌توان به فرم ماتریسی بسط داد:

$$J(w) = (Xw - y)^\top (Xw - y) + \lambda w^\top w \quad (22)$$

برای استفاده از روش نیوتن، نیاز به محاسبه گرادیان (∇J) و ماتریس هسین (H) داریم.
گام اول: محاسبه گرادیان $(\nabla J(w))$

$$\begin{aligned} \nabla J(w) &= \frac{\partial}{\partial w} (w^\top X^\top Xw - 2y^\top Xw + y^\top y + \lambda w^\top w) \\ &= 2X^\top Xw - 2X^\top y + 2\lambda w \\ &= 2(X^\top X + \lambda I)w - 2X^\top y \end{aligned} \quad (23)$$

گام دوم: محاسبه ماتریس هسین (H)

ماتریس هسین برابر با مشتق دوم تابع هدف نسبت به w است:

$$H = \nabla^2 J(w) = \frac{\partial}{\partial w} (2(X^\top X + \lambda I)w - 2X^\top y) \quad (24)$$

از آنجا که عبارت داخل پرانتز نسبت به w خطی است، مشتق آن برابر با ضریب w خواهد بود:

$$H = 2(X^\top X + \lambda I) \quad (25)$$

نکته کلیدی این است که H یک ماتریس ثابت است و به w بستگی ندارد (چون $J(w)$ یک تابع درجه دو یا Quadratic است).

۲. اثبات همگرایی در یک گام

قانون به روزرسانی در روش نیوتن برای نقطه شروع w_0 به صورت زیر است:

$$w_1 = w_0 - H^{-1} \nabla J(w_0) \quad (26)$$

مقدار گرادیان در نقطه w_0 را می توان بر حسب H بازنویسی کرد:

$$\nabla J(w_0) = Hw_0 - 2X^\top y \quad (27)$$

حال این عبارت را در فرمول آپدیت جایگذاری می کنیم:

$$\begin{aligned} w_1 &= w_0 - H^{-1}(Hw_0 - 2X^\top y) \\ &= w_0 - (H^{-1}Hw_0 - H^{-1}2X^\top y) \\ &= w_0 - (Iw_0 - H^{-1}2X^\top y) \\ &= w_0 - w_0 + H^{-1}2X^\top y \\ &= H^{-1}2X^\top y \end{aligned} \quad (28)$$

۳. نتیجه گیری

اکنون مقدار $H = 2(X^\top X + \lambda I)$ را در رابطه بالا قرار می دهیم:

$$\begin{aligned} w_1 &= (2(X^\top X + \lambda I))^{-1} 2X^\top y \\ &= \frac{1}{2}(X^\top X + \lambda I)^{-1} 2X^\top y \\ &= (X^\top X + \lambda I)^{-1} X^\top y \end{aligned} \quad (29)$$

این عبارت دقیقاً همان فرم بسته جواب بهینه سراسری (w^*) است:

$$\boxed{w_1 = w^*} \quad (30)$$


بنابراین اثبات می شود که روش نیوتن برای این تابع هدف خاص، تنها در یک گام به جواب بهینه می رسد.

پرسش ۴: رگرسیون چندجمله‌ای و تنظیم Ridge

در این آزمایش، رفتار مدل‌های رگرسیون چندجمله‌ای با پیچیدگی‌های مختلف و تأثیر تنظیم‌گر L2 (Ridge) بر کنترل بیش‌برازش (Overfitting) مورد تحلیل قرار می‌گیرد.

الف) تحلیل داده‌های data_A.csv

مدل‌های رگرسیون چندجمله‌ای با درجات $d = 1, 3, 9$ بر روی داده‌های آموزشی برازش شده‌اند. نتایج در شکل ۱ نمایش داده شده است.



شکل ۱: برازش چندجمله‌ای با درجات ۱، ۳ و ۹ بر روی داده‌های data_A

تحلیل مشاهدات:


- درجه ۱ (خطی): منحنی قرمز ($d = 1$) قادر به مدل‌سازی ساختار غیرخطی داده‌ها نیست و دچار کم‌برازش (Underfitting) یا بایاس زیاد است.
- درجه ۳: منحنی سبز ($d = 3$) به خوبی روند کلی داده‌ها را دنبال می‌کند و تعادل مناسبی بین همواری و دقت برازش برقرار کرده است.

- **درجه ۹:** منحنی آبی ($d = 9$) از تمام نقاط داده عبور می‌کند، اما این کار به قیمت ایجاد نوسانات شدید در فواصل بین نقاط تمام شده است. این رفتار نشان‌دهنده بیش‌برازش (Overfitting) و واریانس بالای مدل است که نویز داده‌ها را به عنوان سیگنال یاد گرفته است.

ب) تحلیل داده‌های data_B.csv

۱. اثر درجه چندجمله‌ای

خطای میانگین مربعات (MSE) برای داده‌های آموزش و اعتبارسنجی به ازای درجات $d = 1$ تا 12 در شکل ۲ رسم شده است.



شکل ۲: تغییرات MSE آموزش و اعتبارسنجی بر حسب درجه چندجمله‌ای


تحلیل نمودار:

- **ناحیه کم‌برازش:** در درجات پایین ($d = 1, 2$)، هر دو خطای آموزش و اعتبارسنجی بالا هستند که نشان‌دهنده ناتوانی مدل در یادگیری الگوهای داده است.
- **ناحیه بهینه:** با افزایش درجه، خطای اعتبارسنجی کاهش یافته و در بازه $d \approx 7$ تا 9 به کمترین مقدار خود می‌رسد. این ناحیه بهترین تعمیم‌پذیری (Generalization) را ارائه می‌دهد.

- ناحیه بیش‌برازش: برای درجات بالاتر ($d \geq 10$)، در حالی که خطای آموزش همچنان کاهش می‌یابد (به سمت صفر میل می‌کند)، خطای اعتبارسنجی به طور ناگهانی افزایش می‌یابد. این شکاف عمیق بین دو منحنی، نشانه قطعی بیش‌برازش است.

۲. اثر تنظیم Ridge

برای بررسی اثر تنظیم‌گر، یک مدل با ظرفیت بالا ($d = 10$) که در بخش قبل دچار بیش‌برازش بود (انتخاب شده و پارامتر λ در بازه 10^{-6} تا 10^2 تغییر داده شده است) (شکل ۳).



شکل ۳: تغییرات MSE بر حسب پارامتر تنظیم λ (برای درجه ثابت $d = 10$)

تحلیل نمودار:

- λ بسیار کوچک (چپ نمودار): زمانی که $\lambda \rightarrow 0$ ، مدل مانند رگرسیون معمولی عمل کرده و دچار بیش‌برازش شدید است (خطای آموزش بسیار کم، خطای اعتبارسنجی زیاد).
- λ بهینه (میانه نمودار): با افزایش λ ، پهنای روی وزن‌ها اعمال شده و واریانس مدل کاهش می‌یابد. در حدود $\lambda \approx 10^{-2}$ تا 10^{-1} ، خطای اعتبارسنجی به حداقل می‌رسد. این نقطه نشان‌دهنده بهترین مصالحه بایاس-واریانس است.
- λ بسیار بزرگ (راست نمودار): اگر λ بیش از حد بزرگ شود، مدل بیش از حد ساده شده (وزن‌ها به صفر میل می‌کنند) و دچار کم‌برازش می‌شود که با افزایش همزمان خطای آموزش و اعتبارسنجی مشهود است.

نتیجه گیری نهایی

این آزمایش نشان می دهد که برای دستیابی به مدلی با خطای تعمیم پایین، دو راهبرد اصلی وجود دارد:

۱. انتخاب دقیق پیچیدگی مدل (درجه چندجمله ای) متناسب با حجم داده ها.
۲. استفاده از مدل های با ظرفیت بالا همراه با تنظیم گر **Regularization** مناسب. روش دوم (Ridge) به ما اجازه می دهد بدون نگرانی از انتخاب دقیق درجه، از مدل های پیچیده استفاده کنیم و با تنظیم پارامتر λ ، از بیش برآزش جلوگیری نماییم.

پرسش ۵ - پرسپترون

در این سوال، رفتار الگوریتم پرسپترون را بر روی یک مجموعه داده دوبعدی بررسی می‌کنیم. داده‌ها شامل دو کلاس هستند:

- کلاس منفی ($y = -1$): نقاط $[-1, 0]$, $[1, 0]$, $[0, 1]$

- کلاس مثبت ($y = +1$): نقاط $[-2, 0]$, $[2, 0]$, $[0, 2]$

۱. به‌روزرسانی بردار وزن

بردار وزن اولیه $w = [0, 5]$ است. نقطه داده $[0, 1]$ وارد می‌شود.

- پیش‌بینی: حاصل ضرب داخلی $w \cdot x = (0)(0) + (5)(1) = 5$ چون $5 > 0$ ، پرسپترون کلاس $+1$ را پیش‌بینی می‌کند.

- واقعیت: نقطه $[0, 1]$ متعلق به کلاس منفی ($y = -1$) است.

- به‌روزرسانی: چون پیش‌بینی اشتباه بوده است، وزن‌ها باید آپدیت شوند (با فرض نرخ یادگیری ۱):

$$w_{\text{new}} = w_{\text{old}} + y \cdot x = [0, 5] + (-1)[0, 1] = [0, 5] - [0, 1] = [0, 4] \quad (31)$$

بنابراین بردار وزن جدید $[0, 4]$ خواهد بود.

۲. همگرایی الگوریتم

داده‌های داده شده به صورت خطی تفکیک‌پذیر نیستند. نقاط کلاس منفی در فاصله‌ی ۱ از مبدأ و نقاط کلاس مثبت در فاصله‌ی ۲ از مبدأ قرار دارند (کلاس منفی توسط کلاس مثبت محاصره شده است). هیچ خط راستی در صفحه دوبعدی نمی‌تواند نقاط داخلی را از نقاط بیرونی جدا کند. بنابراین، الگوریتم پرسپترون هرگز همگرا نمی‌شود و بی‌پایان ادامه خواهد یافت.

پاسخ: ∞

۳. انتخاب تبدیل مناسب

ما به تبدیلی نیاز داریم که داده‌ها را در فضای جدید تفکیک‌پذیر خطی کند. گزینه‌ها را بررسی می‌کنیم:

- $[x, y] \rightarrow [y, x]$: تغییری در جداسازی ایجاد نمی‌کند.
- $[x, y] \rightarrow [x, y, 1]$: همان فضای دوبعدی با بایاس است، هنوز تفکیک‌ناپذیر است.
- $[x, y] \rightarrow [x, y, x^2, 1]$: این تبدیل کار می‌کند. ویژگی x^2 برای نقاط روی محور افقی تمایز ایجاد می‌کند (1 برای منفی و 4 برای مثبت) و ویژگی y نقاط روی محور عمودی را جدا می‌کند. با داشتن بایاس، می‌توان ابرصفحه‌ای یافت که آنها را جدا کند.
- $[x, y] \rightarrow [x, y, x^2 + y^2]$: این تبدیل بایاس (جمله ثابت 1) را ندارد. بدون بایاس، ابرصفحه باید از مبدأ مختصات بگذرد که برای این داده‌ها امکان جداسازی را فراهم نمی‌کند (اثبات ریاضی نشان می‌دهد که دستگاه نامعادلات حاصل تناقض دارد).

پاسخ صحیح: گزینه سوم: $[x, y] \rightarrow [x, y, x^2, 1]$

۴. بردار وزن پیشنهادی

برای تبدیل $[x, y, x^2 + y^2, 1]$ ، ویژگی سوم ($z = x^2 + y^2$) برابر مجذور فاصله از مبدأ است.

• برای نقاط کلاس منفی: $x^2 + y^2 = 1$

• برای نقاط کلاس مثبت: $x^2 + y^2 = 4$

ما می‌خواهیم $w \cdot \phi(x) < 0$ برای کلاس منفی و > 0 برای کلاس مثبت باشد. یک راه ساده استفاده از ویژگی شعاع و بایاس است، و صفر کردن ضرایب x و y :
فرض کنید $w = [0, 0, a, b]$.

$$\begin{cases} a(1) + b < 0 \implies a < -b \\ a(4) + b > 0 \implies 4a > -b \end{cases} \quad (32)$$

اگر $a = 1$ و $b = -2.5$ را انتخاب کنیم:

$$1(1) - 2.5 = -1.5 < 0 \quad (\text{صحیح}) \quad (33)$$

$$1(4) - 2.5 = +1.5 > 0 \quad (\text{صحیح}) \quad (34)$$

بنابراین یک بردار وزن ممکن عبارت است از: $w = [0, 0, 1, -2.5]$

۵. تبدیل جایگزین

هدف یافتن تابعی است که شعاع یا فاصله از مبدأ را کد کند. علاوه بر $x^2 + y^2$ ، استفاده از نرم اول (L1 Norm) یا قدر مطلق نیز می‌تواند کارساز باشد. تبدیل پیشنهادی:

$$[x, y] \rightarrow [x, y, |x| + |y|, 1] \quad (35)$$

در این حالت برای نقاط منفی $|x| + |y| = 1$ و برای نقاط مثبت $|x| + |y| = 2$ است که به راحتی با یک بایاس قابل تفکیک هستند.

پرسش ۶ - نمایش‌های شبکه عصبی

در این سوال، باید گراف‌های محاسباتی (G_1 تا G_7) را با توابع داده شده (a تا h) نظیر کنیم. برای گراف‌های G_1 تا G_5 ، مقادیر وزن‌ها و بایاس‌ها نیز محاسبه شده است.

تطبیق نمودارها و محاسبه پارامترها

۱. گراف $G_1 \leftarrow$ تابع (a)

- توضیح: این گراف تنها شامل یک ضرب وزن ($y = w \cdot x$) است و فاقد بایاس می‌باشد. بنابراین باید با تابعی خطی که از مبدأ مختصات می‌گذرد نظیر شود. تنها گزینه موجود تابع (a) با ضابطه $y = 2x$ است.

• مقادیر:

$$w = 2 \quad (36)$$

۲. گراف $G_2 \leftarrow$ تابع (b)

- توضیح: این گراف یک تابع خطی کامل شامل شیب و عرض از مبدأ ($y = w \cdot x + b$) است. تنها تابع خطی باقیمانده که از مبدأ نمی‌گذرد، تابع (b) با ضابطه $y = 4x - 5$ است.

• مقادیر:

$$w = 4, \quad b = -5 \quad (37)$$

۳. گراف $G_3 \leftarrow$ تابع (d)

- توضیح: این گراف یک واحد ReLU استاندارد است: $y = \text{ReLU}(wx + b)$.

ویژگی اصلی ReLU این است که خروجی آن برای مقادیر منفی ورودی، صفر می‌شود. تابع (d) برای $x > -2.5$ صفر است و برای $x < -2.5$ مقدار مثبت دارد (شیب منفی).

● محاسبه: تابع (d) برابر است با $\text{ReLU}(-2x - 5)$.

- اگر $x = -3$: عبارت داخل $-2(-3) - 5 = 1$ می‌شود (فعال).

- اگر $x = 0$: عبارت داخل -5 می‌شود (صفر/غیرفعال).

● مقادیر:

$$w = -2, \quad b = -5 \quad (38)$$

۴. گراف $G_4 \leftarrow$ تابع (b)

● توضیح: این گراف دارای دو لایه خطی متوالی بدون تابع فعال‌سازی غیرخطی

است. ترکیب دو تابع خطی، همچنان یک تابع خطی است $y = w_2(w_1x + b_1) + b_2$. از آنجا که تمام توابع خطی دیگر استفاده شده‌اند، این گراف نمایش دیگری (با پارامترهای اضافی) برای تابع (b) است.

● مقادیر پیشنهادی: می‌توانیم عملیات $4x - 5$ را بین دو لایه تقسیم کنیم. یک راه ساده این است که لایه اول همانی (*Identity*) باشد و لایه دوم کار اصلی را انجام دهد:

$$w_1 = 1, \quad b_1 = 0, \quad w_2 = 4, \quad b_2 = -5 \quad (39)$$

۵. گراف $G_5 \leftarrow$ تابع (e)

● توضیح: این گراف فرمول $y = w_2 \cdot \text{ReLU}(w_1x + b_1) + b_2$ را پیاده‌سازی

می‌کند. تابع (e) دارای یک بخش ثابت ($y = 1$) و یک بخش خطی با شیب منفی است. نقطه شکست در $x = 2$ قرار دارد.

● محاسبه:

- برای ایجاد شکست در $x = 2$ ، عبارت داخل ReLU باید $x - 2$ (یا ضربی از آن) باشد. پس $w_1 = 1, b_1 = -2$.

- تابع به صورت $w_2 \cdot \text{ReLU}(x - 2) + b_2$ در می‌آید.
 - برای $x < 2$ (بخش غیرفعال): خروجی باید ۱ باشد. پس $0 + b_2 = 1 \implies b_2 = 1$.

- برای $x > 2$ (بخش فعال): خروجی باید $-x + 3$ باشد.

$$w_2(x - 2) + 1 = -x + 3 \implies w_2x - 2w_2 = -x + 2$$

با مقایسه ضرایب، $w_2 = -1$ به دست می‌آید.

• مقادیر:

$$w_1 = 1, \quad b_1 = -2, \quad w_2 = -1, \quad b_2 = 1 \quad (40)$$

۶. گراف $G_6 \leftarrow \text{تابع } (h)$

• توضیح: این ساختار عمیق (Deep) با چندین لایه ReLU متوالی است $(f(g(h(x))))$.
 ترکیب توابع ReLU معمولاً توابع محدب (Convex) تکه‌ای خطی ایجاد می‌کند.
 تابع (h) یک تابع محدب است (ابتدا پایین می‌آید، سپس صاف می‌شود، سپس بالا می‌رود).

۷. گراف $G_7 \leftarrow \text{تابع } (f)$

• توضیح: این گراف مجموع موازی دو شاخه ReLU است (شبکه عریض). این ساختار اجازه می‌دهد با کم کردن یک ReLU از دیگری، توابع غیرمحدب یا "کلاه‌شکل" (Hat-shaped) بسازیم. تابع (f) تنها تابع غیرمحدب (ابتدا صعودی، سپس نزولی) در گزینه‌هاست که با ترکیب $y = \text{ReLU}(x) - \text{ReLU}(x - c)$ قابل ساخت است.

پرسش ۷ - تابع هزینه

در این سوال، ارتباط میان تخمین درست‌نمایی بیشینه (MLE) و توابع هزینه در شبکه‌های عصبی را بررسی می‌کنیم.

۱.۷. هم‌ارزی درست‌نمایی بیشینه و آنتروپی متقاطع

فرض کنید خروجی‌های شبکه $y_k(x, w)$ احتمال تعلق داده x به کلاس k را نشان می‌دهند $(P(t_k = 1|x) = y_k)$. توزیع احتمال هدف‌ها برای یک داده‌ی n ام از توزیع چندجمله‌ای پیروی می‌کند:

$$P(T_n|x_n, w) = \prod_{k=1}^K y_k(x_n, w)^{t_{kn}} \quad (41)$$

تابع درست‌نمایی (Likelihood) برای کل مجموعه داده برابر است با حاصل‌ضرب احتمالات برای تمام نمونه‌ها:

$$L(w) = \prod_{n=1}^N \prod_{k=1}^K y_k(x_n, w)^{t_{kn}} \quad (42)$$

لگاریتم درست‌نمایی (Log-Likelihood) برابر است با:

$$\ln L(w) = \sum_{n=1}^N \sum_{k=1}^K t_{kn} \ln y_k(x_n, w) \quad (43)$$

ماکسیم کردن این عبارت معادل مینیم کردن منفی آن است:

$$E(w) = -\ln L(w) = -\sum_{n=1}^N \sum_{k=1}^K t_{kn} \ln y_k(x_n, w) \quad (44)$$

این رابطه دقیقاً همان تابع خطای آنتروپی متقاطع (Cross-Entropy) است.

۲.۷. برچسب‌های نویزی (Noisy Labels)

در این حالت، احتمال ϵ وجود دارد که برچسب مشاهده شده t اشتباه باشد. اگر برچسب واقعی ۱ باشد، با احتمال $1 - \epsilon$ همان ۱ مشاهده می‌شود و با احتمال ϵ به ۰ تبدیل می‌شود (و بالعکس). بنابراین احتمال مشاهده برچسب $t = 1$ برابر است با:

$$P(t = 1|x) = (1 - \epsilon)y + \epsilon(1 - y) \quad (۴۵)$$

که در آن y خروجی شبکه (احتمال واقعی کلاس ۱) است. این رابطه را می‌توان ساده کرد:

$$\pi_n = y_n(1 - 2\epsilon) + \epsilon \quad (۴۶)$$

تابع هزینه (منفی لگاریتم درست‌نمایی) برای این حالت به صورت زیر خواهد بود:

$$E = - \sum_{n=1}^N \left(t_n \ln \pi_n + (1 - t_n) \ln(1 - \pi_n) \right) \quad (۴۷)$$

که در آن π_n احتمال تعدیل‌شده توسط نویز است. بررسی: اگر $\epsilon = 0$ باشد، آنگاه $\pi_n = y_n$ خواهد شد و فرمول به آنتروپی متقاطع استاندارد باز می‌گردد.

۳.۷. تابع هزینه برای اهداف $t \in \{-1, 1\}$

در اینجا خروجی شبکه $y \in [-1, 1]$ است. ما می‌توانیم احتمال کلاس مثبت $P(C_1|x)$ را به صورت خطی به بازه $[0, 1]$ نگاشت کنیم:

$$P(C_1|x) = \frac{1+y}{2}, \quad P(C_2|x) = \frac{1-y}{2} \quad (۴۸)$$

تابع درست‌نمایی برای یک نمونه با هدف t (که یا ۱ است یا -۱) به صورت زیر است:

$$P(t|x) = \left(\frac{1+y}{2} \right)^{\frac{1+t}{2}} \left(\frac{1-y}{2} \right)^{\frac{1-t}{2}} \quad (۴۹)$$

(نکته: توان‌ها نقش تابع نشانگر را دارند؛ اگر $t = 1$ باشد توان اول ۱ می‌شود و اگر $t = -1$ باشد توان دوم ۱ می‌شود).
با گرفتن لگاریتم طبیعی:

$$\ln P(t|x) = \frac{1+t}{2} \ln(1+y) + \frac{1-t}{2} \ln(1-y) - \ln 2 \quad (50)$$

این عبارت را می‌توان بسیار ساده‌تر نوشت. توجه کنید که اگر $t = 1$ باشد، عبارت برابر $\ln(1+y)$ و اگر $t = -1$ باشد برابر $\ln(1-y)$ است. این دو حالت را می‌توان در یک عبارت ادغام کرد:

$$\ln P(t|x) = \ln(1+ty) - \ln 2 \quad (51)$$

بنابراین تابع هزینه (با حذف ثابت‌ها) برابر است با:

$$E(w) = - \sum_{n=1}^N \ln(1 + t_n y_n) \quad (52)$$

تابع فعال‌سازی مناسب: برای اینکه خروجی y در بازه $[-1, 1]$ قرار گیرد و مشتق‌پذیر باشد، مناسب‌ترین تابع، **تانژانت هیپربولیک** ($\tanh$) است:

$$y = \tanh(a) = \frac{e^a - e^{-a}}{e^a + e^{-a}} \quad (53)$$

پرسش ۸ - پایداری تصادفی و Dead ReLU

در این سوال، رفتار آماری یک نورون با فعال سازی ReLU را بررسی می کنیم. مدل نورون به صورت $z = w^\top x + b$ و $a = \max(0, z)$ است. فرض می کنیم $x \in \mathbb{R}^n$ و $w \in \mathbb{R}^n$ بردارهای تصادفی مستقل با توزیع نرمال باشند:

$$x \sim \mathcal{N}(0, \sigma_x^2 I), \quad w \sim \mathcal{N}(0, \sigma_w^2 I)$$

۱.۸ اثبات توزیع (Distribution Proof)

متغیر پیش فعال سازی z برابر است با جمع وزن دار ورودی ها به اضافه بایاس:

$$z = \sum_{i=1}^n w_i x_i + b \quad (54)$$

طبق قضیه حد مرکزی (Central Limit Theorem)، وقتی n بزرگ باشد، مجموع تعداد زیادی متغیر تصادفی مستقل (حتی اگر خودشان توزیع نرمال نداشته باشند) به توزیع نرمال میل می کند. برای مشخص کردن توزیع $z \sim \mathcal{N}(\mu_z, \sigma_z^2)$ ، میانگین و واریانس آن را محاسبه می کنیم: محاسبه میانگین (μ_z) :

$$E[z] = E\left[\sum w_i x_i + b\right] = \sum E[w_i]E[x_i] + b = \sum (0)(0) + b = b \quad (55)$$

محاسبه واریانس (σ_z^2) : چون w_i و x_i مستقل هستند، واریانس مجموع برابر با مجموع واریانس هاست:

$$\text{Var}(z) = \sum_{i=1}^n \text{Var}(w_i x_i) \quad (56)$$

واریانس حاصل ضرب دو متغیر مستقل با میانگین صفر:

$$\text{Var}(w_i x_i) = E[w_i^2 x_i^2] - (E[w_i x_i])^2 = E[w_i^2] E[x_i^2] - 0 = \sigma_w^2 \sigma_x^2 \quad (57)$$

بنابراین واریانس کل برابر است با:

$$\sigma_z^2 = n \sigma_w^2 \sigma_x^2 \quad (58)$$

در نتیجه ثابت شد که $z \sim \mathcal{N}(b, n \sigma_w^2 \sigma_x^2)$.

۲.۸. ۲. احتمال فعال سازی (Activation Probability)

نورون زمانی فعال می شود که $a > 0$ یا معادل آن $z > 0$ باشد. با استفاده از تابع توزیع تجمعی نرمال استاندارد $\Phi(\cdot)$ ، احتمال $P(z > 0)$ را محاسبه می کنیم. ابتدا متغیر را استاندارد سازی می کنیم:

$$P(z > 0) = P\left(\frac{z - b}{\sigma_z} > \frac{0 - b}{\sigma_z}\right) = P\left(Z > \frac{-b}{\sigma_z}\right) \quad (59)$$

که در آن $Z \sim \mathcal{N}(0, 1)$ است. با توجه به تقارن توزیع نرمال $(P(Z > k) = 1 - \Phi(k) = \Phi(-k))$:

$$P(a > 0) = 1 - \Phi\left(\frac{-b}{\sigma_z}\right) = \Phi\left(\frac{b}{\sigma_z}\right) \quad (60)$$

۳.۸. ۳. آستانه 3σ

فرض کنید بایاس اولیه به صورت $b = -3\sigma_z$ تنظیم شده باشد. احتمال فعال شدن نورون برابر است با:

$$P(a > 0) = \Phi\left(\frac{-3\sigma_z}{\sigma_z}\right) = \Phi(-3) \quad (61)$$

با مراجعه به جداول آماری استاندارد، مقدار $\Phi(-3) \approx 0.00135$ است.

تعداد نورون‌های فعال: اگر لایه دارای $N = 1000$ نورون باشد، امید ریاضی تعداد نورون‌های فعال برابر است با:

$$\text{Active Expected} = N \times P(a > 0) = 1000 \times 0.00135 = 1.35 \quad (62)$$

بنابراین، تقریباً تنها ۱ یا ۲ نورون از ۱۰۰۰ نورون فعال خواهند بود و بقیه خاموش هستند.

۴.۸ اثبات گرادیان صفر (Dead ReLU)

تابع هزینه L را در نظر بگیرید. گرادیان نسبت به وزن‌ها با استفاده از قاعده زنجیره‌ای محاسبه می‌شود:

$$\frac{\partial L}{\partial w} = \frac{\partial L}{\partial a} \cdot \frac{\partial a}{\partial z} \cdot \frac{\partial z}{\partial w} \quad (63)$$

مشتق تابع فعال‌سازی ReLU برابر است با تابع نشانگر:

$$\frac{\partial a}{\partial z} = \mathbb{I}(z > 0) = \begin{cases} 1 & z > 0 \\ 0 & z \leq 0 \end{cases} \quad (64)$$

اگر برای تمام نمونه‌های موجود در یک مینی‌بچ (Mini-batch)، مقدار پیش‌فعال‌سازی $z \leq 0$ باشد، آنگاه برای تمامی نمونه‌ها $\frac{\partial a}{\partial z} = 0$ خواهد بود. در نتیجه گرادیان کل صفر می‌شود:

$$\frac{\partial L}{\partial w} = 0 \implies \Delta w = 0 \quad (65)$$

مفهوم ریاضی «احیا» (Resurrecting): وقتی گرادیان صفر شود، وزن‌ها به‌روزرسانی نمی‌شوند ($w_{new} = w_{old}$). اگر وزن‌ها تغییر نکنند، مقدار z برای ورودی‌های آینده نیز تغییر نخواهد کرد (مگر اینکه ورودی‌ها به شدت تغییر کنند، که بعید است بایاس منفی بزرگ را جبران کنند). این نورون در وضعیت «مرگ دائمی» گیر می‌کند و هیچ‌گاه یاد نمی‌گیرد. به این پدیده مرگ ReLU یا Dying ReLU می‌گویند.

پرسش ۹ - حفظ واریانس و مقداردهی اولیه خاویر (Xavier Initialization)

در این سوال، شرایط لازم برای حفظ واریانس سیگنال در گذر رو به جلو (Forward Pass) و گرادیان در گذر رو به عقب (Backward Pass) را بررسی کرده و مقداردهی اولیه خاویر را استخراج می‌کنیم.

۱.۹. ۱. قیود متقارن (Symmetric Constraints)

فرض کنید $y^{(l)} = W^{(l)}x^{(l)}$ که در آن $W \in \mathbb{R}^{n_{out} \times n_{in}}$ و $x \in \mathbb{R}^{n_{in}}$. مولفه‌های W و x مستقل از هم (Independent) و دارای میانگین صفر هستند ($E[W] = 0, E[x] = 0$). واریانس خروجی y_i برابر است با:

$$\begin{aligned} \text{Var}(y_i) &= \text{Var}\left(\sum_{j=1}^{n_{in}} W_{ij}x_j\right) \\ &= \sum_{j=1}^{n_{in}} \text{Var}(W_{ij}x_j) \quad (\text{چون مستقل هستند}) \\ &= \sum_{j=1}^{n_{in}} E[W_{ij}^2x_j^2] - (E[W_{ij}x_j])^2 \\ &= \sum_{j=1}^{n_{in}} E[W_{ij}^2]E[x_j^2] - 0 \\ &= n_{in} \cdot \text{Var}(W) \cdot \text{Var}(x) \end{aligned} \tag{۶۶}$$

برای حفظ واریانس سیگنال در گذر رو به جلو، باید $\text{Var}(y) = \text{Var}(x)$ باشد. بنابراین:

$$n_{in} \text{Var}(W) = 1 \implies \text{Var}(W) = \frac{1}{n_{in}} \tag{۶۷}$$

در گذر رو به عقب، گرادیان از طریق ماتریس ترانهاده W^T منتقل می‌شود. با استدلال مشابه، چون تعداد ورودی‌ها در مسیر بازگشت n_{out} است، برای حفظ واریانس گرادیان داریم:

$$n_{out} \text{Var}(W) = 1 \implies \text{Var}(W) = \frac{1}{n_{out}} \quad (68)$$

۲.۹. سنتز گلوروت (The Glorot Synthesis)

ما با دو قید متناقض روبرو هستیم: $\text{Var}(W) = \frac{1}{n_{in}}$ و $\text{Var}(W) = \frac{1}{n_{out}}$. برای برقراری تعادل بین این دو، گلوروت و بنجیو پیشنهاد کردند که واریانس باید عکسِ میانگین حسابی n_{in} و n_{out} باشد. به عبارت دیگر، واریانس باید شرط $\text{Var}(W) = 1/n_{avg}$ را ارضا کند که در آن $n_{avg} = \frac{n_{in} + n_{out}}{2}$.

$$\text{Var}(W) = \frac{1}{\frac{n_{in} + n_{out}}{2}} = \frac{2}{n_{in} + n_{out}} \quad (69)$$

بنابراین واریانس خاویر برابر است با:

$$\sigma^2 = \frac{2}{n_{in} + n_{out}} \quad (70)$$

۳.۹. واریانس ناشی از عمق (Depth-Induced Variance)

فرض کنید بهره لایه برابر $G = n \text{Var}(W)$ باشد. طبق رابطه بخش ۱، واریانس خروجی لایه l برابر است با:

$$\text{Var}(y^{(l)}) = G \cdot \text{Var}(y^{(l-1)}) \quad (71)$$

با اعمال بازگشتی این رابطه برای L لایه از ورودی $x^{(0)}$:

$$\text{Var}(y^{(L)}) = G \cdot G \cdot \dots \cdot \text{Var}(x^{(0)}) = G^L \text{Var}(x^{(0)}) \quad (72)$$

۴.۹ کران پایداری (Stability Bound)

فرض کنید مقداردهی اولیه دارای خطای کوچک ϵ باشد به طوری که $n\text{Var}(W) = 1 + \epsilon$. در این صورت بهره لایه $G = 1 + \epsilon$ است. واریانس خروجی برابر خواهد بود با:

$$\text{Var}(y^{(L)}) = (1 + \epsilon)^L \text{Var}(x^{(0)}) \quad (۷۳)$$

از آنجا که تابع نمایی برای پایه بزرگتر از یک صعودی است، با افزایش عمق شبکه (L) ، ضریب $(1 + \epsilon)^L$ به صورت نمایی رشد می‌کند. این پدیده منجر به انفجار سیگنال (اگر $\epsilon > 0$) یا محو شدن سیگنال (اگر $\epsilon < 0$) می‌شود.

۵.۹ تحلیل عددی

با فرض $L = 150$ و $\epsilon = 0.02$:

$$\text{Factor Amplification} = (1 + 0.02)^{150} = (1.02)^{150} \quad (۷۴)$$

مقدار عددی این عبارت برابر است با:

$$(1.02)^{150} \approx 19.49 \quad (۷۵)$$

بحث در مورد ریسک FP16: در فرمت ممیز شناور ۱۶ بیتی (FP16)، محدوده دینامیکی اعداد بسیار محدود است (ماکسیمم مقدار حدود 65,504). رشد ۱۹ برابری واریانس به تنهایی شاید باعث سرریز (Overflow) فوری نشود، اما در شبکه‌های عصبی این اثر در گرادیان‌ها نیز ضرب می‌شود. اگر گرادیان‌ها نیز با ضریب مشابهی تقویت شوند، یا اگر واریانس ورودی اولیه کمی بزرگ باشد، مقادیر سریعاً به NaN یا بی‌نهایت (Inf) میل می‌کنند. این ناپایداری عددی باعث شکست فرآیند آموزش در شبکه‌های عمیق می‌شود.

پرسش ۱۰ - یادگیری انتقال با شبکه‌های پیش‌آموزش‌دیده

در این بخش، عملکرد سه معماری مختلف (پرسپترون چندلایه، VGG منجمد، و VGG تنظیم دقیق شده) بر روی مجموعه داده CIFAR-10 مقایسه شده است.


۱. جزئیات پیاده‌سازی

- پیش‌پردازش: تصاویر نرمال‌سازی شده و به تنسور تبدیل شدند.
- معماری: **MLP** یک شبکه با ورودی مسطح (3072 گره)، دو لایه مخفی (512 و 256 واحد) و توابع فعال‌سازی ReLU.
- معماری: **VGG** از مدل VGG-11 پیش‌آموزش‌دیده روی ImageNet استفاده شد. کلاسیفایر نهایی برای ۱۰ کلاس خروجی تغییر یافت.
- روند آموزش: مدل‌ها برای ۱۰ اپوک با اندازه دسته (Batch size) ۵۱۲ و بهینه‌ساز Adam آموزش دیدند.


۲. نتایج تجربی

نمودارهای روند کاهش تابع هزینه (Loss) و افزایش دقت اعتبارسنجی (Validation Accuracy) در شکل‌های زیر نمایش داده شده است. مشاهدات کمی:

- مدل **MLP** کندترین همگرایی را دارد و دقت نهایی آن نسبتاً پایین است (معمولاً حدود ۵۰٪).
- مدل **VGG Frozen** با وجود اینکه لایه‌های کانولوشنی آن ثابت هستند، همگرایی بسیار سریع و پایداری دارد و به دقت بالاتری نسبت به MLP می‌رسد.



شکل ۴: روند کاهش خطای آموزش



شکل ۵: روند افزایش دقت اعتبارسنجی

- مدل **VGG Fine-Tuned** بهترین عملکرد را دارد، زیرا ویژگی‌های استخراج شده را با جزئیات خاص مجموعه داده جدید تطبیق می‌دهد.

۳. بحث و تحلیل (Discussion)

الف) همگرایی و پایداری (Convergence and Stability) مدل‌های پیش‌آموزش‌دیده (Pre-trained) همگرایی بسیار سریع‌تر و نرم‌تری نسبت به آموزش از صفر (From Scratch) دارند. دلیل این امر مقداردهی اولیه بهینه است. در مدل MLP (یا مدل آموزش از صفر)، وزن‌ها به صورت تصادفی مقداردهی می‌شوند و مدل باید ابتدا فیلترهای پایه (لبه‌یاب‌ها، بافت‌ها) را یاد بگیرد. اما در مدل پیش‌آموزش‌دیده، وزن‌ها قبلاً در یک "ناحیه مناسب" (Good Basin) از فضای تابع هزینه قرار

دارند که ویژگی‌های بصری غنی را استخراج می‌کنند. این باعث می‌شود مسیر بهینه‌سازی کوتاه‌تر و هموارتر باشد.

ب) شکاف تعمیم و سوگیری القایی (Generalization Gap & Inductive Bias) مدل Frozen VGG حتی با وزن‌های ثابت، عملکرد بهتری از MLP دارد. دلیل اصلی این پدیده سوگیری القایی فضایی (Spatial Inductive Bias) در شبکه‌های کانولوشنی (CNN) است.

● **CNN مثل VGG:** دارای فرضیات ساختاری مثل "تغییرناپذیری نسبت به انتقال" (Trans-Invariance) و "ارتباطات محلی" (Locality) است. این شبکه می‌داند که پیکسل‌های نزدیک به هم تشکیل اشیاء را می‌دهند و جابجایی یک شیء در تصویر نباید ماهیت آن را تغییر دهد.

● **MLP:** تصویر را Flatten می‌کند و تمام ارتباطات فضایی را از بین می‌برد. برای MLP، پیکسل گوشه بالا-چپ هیچ ارجحیت مکانی نسبت به پیکسل پایین-راست ندارد.

بنابراین، معماری CNN ذاتاً برای داده‌های تصویری مناسب‌تر است و حتی بدون آموزش روی داده‌های جدید، ویژگی‌های عمومی بسیار قوی‌تری نسبت به یک MLP آموزش دیده ارائه می‌دهد.

١. Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
٢. Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
٣. Glorot, X., & Bengio, Y. (2010). "Understanding the difficulty of training deep feed-forward neural networks". *Proceedings of AISTATS*.
٤. Simonyan, K., & Zisserman, A. (2014). "Very Deep Convolutional Networks for Large-Scale Image Recognition". *arXiv preprint arXiv:1409.1556*.
٥. PyTorch Documentation. "Transfer Learning for Computer Vision Tutorial".